

DOSSIER 00

COMMERCIAL · ENTERPRISE EDITION

Juin 2026 · v2

AI Solutions Brochure 2026

Enterprise AI Compute Platform
89% lower carbon · 72% lower energy cost

GPUs

1,798

COST ADV.

-40%

CARBON

-89%

LATENCY

8ms

00 TABLE DES MATIÈRES

N°	Section	Page
01	Executive Summary	3
02	Platform Overview	4
03	Sovereign AI Cloud	5
04	GPU Compute Services — Training	7
05	GPU Compute Services — Inference	9
06	GPU Compute Services — Fine-tuning	10
07	MLOps Studio	12
08	Industry Use Cases — Financial Services	14
09	Industry Use Cases — Healthcare	15
10	Industry Use Cases — Government	16
11	Industry Use Cases — Research	17
12	Industry Use Cases — Media	18
13	Performance Benchmarks (MLPerf)	20
14	Cost Comparison vs Hyperscalers	22
15	Carbon Advantage	24
16	Sovereign Security Framework	25
17	Data Residency (GDPR + CNDP)	26
18	Customer Onboarding Journey	27
19	Pricing Models	28
20	SLA & Support	29
21	Partnerships Ecosystem	30
22	Customer Success Stories	31
23	Roadmap 2026-2030	32
24	Contacts Sales & Disclaimer	33

Note de lecture

Cette brochure présente l'offre Enterprise AI Solutions de Harch Intelligence — plateforme compute AI souveraine pour entreprises et institutions. 1 798 GPUs NVIDIA H100/H200 sur 5 hubs au Maroc, PUE <1.15, carbon intensity 89% inférieure à la moyenne industrie, tarifs 30-40% inférieurs aux hyperscalers US/EU. Document destiné aux CTO/CIO entreprises, directions achats IT, et décideurs publics. Version 2.0 — Juin 2026. Classification : Commercial — Enterprise Edition.

01 EXECUTIVE SUMMARY

Harch Intelligence Enterprise — la plateforme AI souveraine

Harch Intelligence Enterprise est l'offre compute AI souveraine destinée aux grandes entreprises, institutions publiques, et labs de recherche. La plateforme combine 1 798 GPUs NVIDIA H100/H200 sur 5 hubs au Maroc, une stack logicielle MLOps complète (HarchOS), et un cadre de souveraineté juridique Maroc + UE (CNDP + RGPD). Conçue pour les organisations qui ne peuvent ou ne veulent pas dépendre exclusivement des hyperscalers US (AWS, Google, Azure) soumis au CLOUD Act américain.

La valeur proposée Harch Intelligence Enterprise repose sur 4 piliers : (i) Prix 30-40% inférieur aux hyperscalers EU (\$1.80-2.20/GPU-h H100 reserved vs \$3.10-3.45), (ii) Carbon footprint -89% vs industrie (47 gCO2/kWh vs 450), (iii) Latence 8ms vers Marseille pour expérience utilisateur EU indissociable d'un data center local, (iv) Souveraineté juridique Maroc + UE (données jamais soumise au CLOUD Act US). Cette combinaison est unique sur le marché européen et africain.

Métriques clés Enterprise

Métrique	Valeur	Benchmark / Source
GPUs disponibles Enterprise	1 798 (H100 + H200)	Capacité totale réseau
Hubs AI hyperscale	5 au Maroc	Dakhla, Ouarzazate, Benguerir, Tanger, Casablanca
Tarif H100 reserved 1y	\$1.80/GPU-h	vs \$3.40 AWS eu-west-1 (-47%)
Tarif H100 spot	\$0.95/GPU-h	vs \$1.50 AWS eu-west-1 (-37%)
Carbon intensity moyen	47 gCO2/kWh	vs 450 moyenne industrie (-89%)
PUE moyen	1.15	vs 1.20-1.25 industrie
Latence vers Marseille	8 ms	Indissociable data center EU
Disponibilité garantie	99.995% (Tier IV+)	Uptime Institute certified
Time-to-first-GPU	5-10 jours	vs 2-4 semaines hyperscalers
Clients cible 2030	350 enterprise	Mix EU + Maroc + Afrique
Revenu cible Enterprise 2030	\$285M	Mix reserved 60% + spot 25% + dedicated 15%
Account managers dédiés	45 (1 per 8 clients)	Premium support

Positionnement stratégique

Le partenaire AI souverain de l'Europe et de l'Afrique

Harch Intelligence Enterprise répond à un besoin croissant des organisations EU et africaines : disposer d'une plateforme compute AI haute performance qui ne soit pas soumise au CLOUD Act américain. Avec lajuridiction Maroc + UE, le carbon footprint le plus bas du marché (-89%), et des prix 30-40% inférieurs, Harch Intelligence devient le partenaire AI de référence pour les organisations soucieuses de souveraineté, d'ESG, et d'optimisation coûts. La plateforme est déjà utilisée par 12 clients entreprise pilotes en 2025.

02 PLATFORM OVERVIEW

Architecture plateforme Enterprise

La plateforme Enterprise Harch Intelligence est organisée en 4 couches : (i) Infrastructure (5 hubs AI hyperscale, GPUs H100/H200, fabric 400G InfiniBand), (ii) Orchestration (Kubernetes + Slurm, HarchOS carbon-aware scheduler), (iii) Services AI (Training, Inference, Fine-tuning, MLOps Studio), (iv) Customer layer (API, SDK Python/Node, dashboard web, billing). Cette architecture permet aux clients de consommer le compute AI à différents niveaux d'abstraction selon leur maturité ML.

Les 4 couches de la plateforme

Couche	Composants	Niveau abstraction	Clients cibles
Infrastructure	5 hubs, 1 798 GPUs, InfiniBand, storage 15 PB	Bare-metal GPU	Advanced ML teams
Orchestration	Kubernetes, Slurm, HarchOS Carbon Scheduler	Container/workload	DevOps + ML teams
Services AI	Training API, Inference API, Fine-tuning API	API endpoints	ML engineers + devs
Customer layer	Web dashboard, SDK Python/Node, billing, monitoring	Cloud-style	All enterprise

Modes de consommation

Les clients Enterprise peuvent consommer la plateforme selon 3 modes : (i) Self-service via API/SDK (déploiement code ML direct, type AWS SageMaker), (ii) Managed services (Harch Intelligence gère l'infrastructure, le client fournit le modèle et les données), (iii) Professional services (Harch Intelligence ML engineers accompagnent le client sur mesure : architecture, optimisation, fine-tuning, deployment).

Mode	Description	Prix	Time-to-value	Profil client
Self-service API	Client déploie via API/SDK	GPU-h + storage + egress	1h après signup	Mature ML teams
Managed service	Harch manage infra + framework	GPU-h + 25% managed	1-2 jours	Mid-maturity teams
Professional service	ML engineers Harch on-demand	\$300/h + GPU-h	1-4 semaines	Early-stage teams
Reserved capacity	Capacity garantie 24/7	GPU-h reserved -10%	5-10 jours onboarding	Production workloads
Dedicated hub	Hub dédié single-tenant	Custom (\$10M+/an)	3-6 mois setup	Strategic clients

Plateforme multi-tenant isolée

La plateforme Harch Intelligence Enterprise est multi-tenant avec isolation complète : chaque client dispose de (i) VPC dédié (network isolation), (ii) Kubernetes namespace isolé, (iii) storage buckets privés avec encryption AES-256 + customer-managed keys, (iv) IAM custom. Cette isolation garantit que les données et workloads clients ne sont jamais accessibles aux autres clients ni à Harch Intelligence (sauf consentement explicite). Conformité RGPD + CNDP + ISO 27001.

03 SOVEREIGN AI CLOUD

Le concept Sovereign AI

Le Sovereign AI Cloud Harch Intelligence est conçu pour les organisations qui exigent que leurs données, modèles, et workloads AI restent sous juridiction non-US. Cette exigence concerne particulièrement : (i) les gouvernements et administrations publiques EU et africaines, (ii) les entreprises stratégiques (défense, énergie, télécoms), (iii) les institutions financières soumises à DORA, (iv) les organismes de recherche avec données sensibles. Le CLOUD Act américain permet aux autorités US d'accéder aux données hébergées par toute entreprise US — y compris en dehors du territoire US.

Comparaison juridique

Opérateur	Juridiction principale	CLOUD Act applicable	RGPD compliant	Sovereign AI
Harch Intelligence	Maroc + UE	Non	Oui (adequacy 2025)	Oui
AWS EU	USA (parent)	Oui	Oui mais conflit CLOUD Act	Partiel
Google Cloud EU	USA (parent)	Oui	Oui mais conflit CLOUD Act	Partiel
Azure EU	USA (parent)	Oui	Oui mais conflit CLOUD Act	Partiel
Oracle Cloud EU	USA (parent)	Oui	Oui mais conflit CLOUD Act	Partiel
OVHcloud (France)	France	Non	Oui	Oui
Scaleway (France)	France	Non	Oui	Oui
Bleu (France)	France	Non (Capgemini+Supra)	Oui (Microsoft)	Oui (limited)
T-Systems (Germany)	Allemagne	Non	Oui	Oui

Garanties Sovereign AI Harch

Garantie	Description	Mécanisme	Audit
Données sous juridiction Maroc + UE	Maroc + UE. Hors UE/Maroc sans données	Data residency policy + tech controls	CNDP + Bureau Veritas
Pas de CLOUD Act	Harch Corp S.A. est société marocaine	Corporate structure non-US	Legal opinion annuelle
Encryption end-to-end	AES-256 at-rest + TLS 1.3 in-transit	Customer-managed keys (Vault)	ISO 27001 audit
No backdoors	Pas d'accès gouvernemental sans procédure légale	Transparency report annuel	Independent audit
Data portability	Export gratuit toutes données <30 jours	ES + Kubernetes manifests	ISO 27018 audit
Right to erasure	Suppression complète sur demande	Crypto-shredding + verification	RGPD audit
Subprocessors list	Liste publique + 30 jours notice	Vendor management program	SOC 2 audit
Breach notification	<72h notification violation	Incident response playbook	ISO 22301 audit

Sovereign AI — un marché en croissance explosive

Le marché Sovereign AI Cloud explose en Europe : la stratégie EU Sovereign Cloud (IPCEI) prévoit €1.2B d'investissement public 2024-2027, et le régulateur DORA impose des exigences souveraineté aux institutions financières (2025). Harch Intelligence est positionné comme l'alternative la plus compétitive (prix + CO2) au duopole OVHcloud + Scaleway, avec en plus l'avantage d'un mix énergétique 100% renouvelable dédiée. Marché adressable EU 2027 : €8B (Sovereign AI Cloud).

Source : *European Commission Adequacy Decision 2025, CLOUD Act 2018, DORA Regulation 2024, IPCEI Cloud 2024*

04 GPU COMPUTE SERVICES — TRAINING

Service Training

Le service Training Harch Intelligence Enterprise permet aux clients de entraîner leurs modèles AI (LLM, diffusion, vision, speech) sur GPUs NVIDIA H100/H200 avec scaling jusqu'à 500 GPUs en parallèle (hub Dakhla). Le service supporte distributed training (DeepSpeed ZeRO-3, Megatron-LM, FSDP), checkpoints automatiques sur NVMe (5 GB/s), et auto-resume en cas de failure. Stack complète pre-installed : PyTorch 2.4+, JAX 0.4.25+, DeepSpeed 0.14+, Megatron-LM 5.0+.

Capacités training

Capacité	Valeur	Benchmark / Commentaire
GPUs par job (max)	500 (hub Dakhla)	vs 256-512 AWS P5
GPUs par job (typique)	32-128	Fine-tuning + mid-size training
Frameworks supportés	PyTorch, JAX, TF, DeepSpeed, Megatron-LM, FSDP	Native MxNet
Distributed training	Data, Tensor, Pipeline parallel	Native NCCL 2.20
Checkpoint NVMe	5 GB/s write	Checkpoint 70B model en 50s
Auto-resume	<2 min	Après node failure
Multi-node scaling	Up to 8 nodes (64 GPUs)	Optimized InfiniBand 400G
Mixed precision	FP16, BF16, FP8, INT8	Transformer Engine
Max model size	400B params (sharded)	Avec ZeRO-3 + NVMe offload
Max dataset size	100 TB	Streaming from storage cluster

Tarification training

GPU type	Reserved 1y (\$/h)	Spot (\$/h)	Dedicated (\$/h)	Volume discount
H100 80GB (training)	1.80	0.95	2.40	Jusqu'à -20% (200k GPU-h/mois)
H200 141GB (training)	2.20	1.20	2.80	Jusqu'à -20% (200k GPU-h/mois)
A100 80GB (training legacy)	1.20	0.65	1.60	Jusqu'à -15%
L40S 48GB (vision training)	0.85	0.45	1.15	Jusqu'à -15%

Cas d'usage training typiques

- **Pre-training LLM 70B params** — 35 000 GPU-h (Llama-3 class, 15T tokens), durée 2.9 jours sur 500 H200 Dakhla, coût \$77k (reserved) vs \$146k AWS.
- **Fine-tuning SFT 7B params** — 500 GPU-h (1M exemples), durée 10h sur 50 H100, coût \$900 (reserved) vs \$1 700 AWS.
- **Fine-tuning RLHF 70B params** — 5 000 GPU-h (PPO + reward model), durée 4 jours sur 50 H100, coût \$9k vs \$17k AWS.
- **Training diffusion SD-3 class** — 8 000 GPU-h (image gen), durée 16h sur 500 H100, coût \$14.4k vs \$27k AWS.
- **Training speech Whisper-large** — 12 000 GPU-h (50k hours audio), durée 4 jours sur 128 H100, coût \$21.6k vs \$41k AWS.

- **Pre-training GPT-3 175B params** — 125 000 GPU-h (300B tokens), durée 10.4 jours sur 500 H200, coût \$275k vs \$525k AWS.

Cost saving training -47% vs AWS

Pour un training complet LLM 70B params (35 000 GPU-h), le coût sur Harch Intelligence est de \$77k (reserved H200) vs \$146k sur AWS eu-west-1 (p5.48xlarge) — soit une économie de \$69k (-47%). Pour 4 trainings par an, économie annuelle \$276k. À cela s'ajoute le carbon footprint réduit de 98% (3.4 tCO2 vs 165 tCO2 AWS). Cette double économie (coût + CO2) justifie la migration des workloads training vers Harch Intelligence.

05 GPU COMPUTE SERVICES — INFERENCE

Service Inference

Le service Inference Harch Intelligence Enterprise permet aux clients de déployer leurs modèles AI en production avec scaling automatique, SLA 99.95%+, et latence <30ms/token pour LLM. Frameworks supportés : vLLM, TGI, NVIDIA Triton, TensorRT-LLM. Déploiement en <5 min via Docker image ou HuggingFace model URI. Auto-scaling basé sur QPS, latency, ou custom metrics.

Capacités inference

Capacité	Valeur	Commentaire
Frameworks	vLLM, TGI, Triton, TensorRT-LLM	Pre-configured + optimized
Latence LLM	<30ms/token	Llama-3 8B sur H100
Throughput LLM	1 500 tokens/s/GPU	Batch optimal
Auto-scaling	0 → 100 GPUs in <2 min	Kubernetes HPA custom
Max context length	128k tokens	Llama-3 70B avec RoPE scaling
Concurrent requests	10 000+ per GPU	vLLM paged attention
Cold start	<60s	Model load NVMe 7 GB/s
SLA availability	99.95% (reserved)	99.99% (dedicated)
Custom endpoints	REST + gRPC + WebSocket	Native OpenAI-compatible API
A/B testing	Built-in	Traffic splitting 1%-100%

Tarification inference

GPU type	Reserved 1y (\$/h)	Spot (\$/h)	Dedicated (\$/h)	Per 1M tokens (estimé)
H100 80GB	1.80	0.95	2.40	\$0.30
H200 141GB	2.20	1.20	2.80	\$0.36
A100 80GB	1.20	0.65	1.60	\$0.20
L40S 48GB	0.85	0.45	1.15	\$0.14
A10 24GB	0.45	0.25	0.60	\$0.08

Cas d'usage inference typiques

- **LLM chatbot entreprise** — Llama-3 70B, 50M tokens/mois, 2 H100 reserved 24/7, coût \$2 600/mois vs \$5 000 AWS.
- **RAG entreprise** — Llama-3 8B + embeddings, 10M tokens/mois, 1 L40S reserved, coût \$620/mois vs \$1 200 AWS.
- **Voice AI real-time** — Whisper-large + LLM, 5M min/mois, 10 H100 spot, coût \$7 000/mois vs \$14k AWS.
- **Code completion** — CodeLlama 34B, 100M tokens/mois, 4 H100 reserved, coût \$5 200/mois vs \$10k AWS.
- **Image generation** — SDXL-Turbo, 1M images/mois, 8 L40S spot, coût \$2 200/mois vs \$4 400 AWS.

- **Vision analytics** — YOLOv8 + custom model, 100M inferences/mois, 4 A10 spot, coût \$720/mois vs \$1400 AWS.

Inference latence 8ms gateway Europe

Pour les workloads inference EU, le hub Tanger (8ms vers Marseille) offre une expérience utilisateur indissociable d'un data center EU local. Cas typique : chatbot customer service déployé sur hub Tanger, latence end-to-end <50ms pour user EU (network 8ms + model inference 30ms). Cette performance permet à Harch Intelligence de concurrencer directement AWS/Google/Azure sur les workloads inference production EU, avec 30-40% moins cher et 89% moins de carbone.

06 GPU COMPUTE SERVICES — FINE-TUNING

Service Fine-tuning

Le service Fine-tuning Harch Intelligence Enterprise permet aux clients d'adapter des modèles pré-entraînés (Llama-3, Mistral, Qwen) à leurs cas d'usage spécifiques avec datasets propriétaires. Techniques supportées : SFT (Supervised Fine-Tuning), RLHF (Reinforcement Learning from Human Feedback), DPO (Direct Preference Optimization), LoRA (Low-Rank Adaptation), QLoRA (Quantized LoRA), et PEFT (Parameter-Efficient Fine-Tuning).

Capacités fine-tuning

Capacité	Valeur	Commentaire
Techniques supportées	SFT, RLHF, DPO, LoRA, QLoRA, PEFT	TRL + PEFT libraries
Modèles pré-entraînés	Llama-3 (8B/70B), Mistral (7B/8x22B), Qwen2 (7B/72B), CodeLlama (34B), Whisper-large	Pre-cached sur NVMe
Dataset formats	JSONL, Parquet, HuggingFace datasets	Streaming pour >100GB
Max dataset size	1 TB	Streaming from storage
Fine-tuning LoRA speed	15 min pour 1M exemples (7B model)	Sur 8 H100
Fine-tuning full SFT speed	4h pour 1M exemples (70B model)	Sur 50 H100
Hyperparameter tuning	Optuna + Ray Tune integration	Native dans MLOps Studio
Model registry	MLflow + W&B integration	Auto-versioning
Evaluation	BLEU, ROUGE, MMLU, custom metrics	Automatique post-FT
Deployment	Auto-deploy to inference service	<5 min post-FT

Workflows fine-tuning

- Dataset preparation** — Client fournit dataset (JSONL, Parquet, HuggingFace format). Harch Intelligence validation automatique (schema, balancement, qualité). Stockage sur NVMe pour accès rapide pendant fine-tuning.
- Base model selection** — Choix parmi catalogue modèles pré-cached (Llama-3 8B/70B, Mistral 7B/8x22B, Qwen2 7B/72B, CodeLlama 34B, Whisper-large). Pas de download time.
- Technique selection** — Conseil Harch ML engineer sur technique optimale : LoRA (rapide, peu de data), QLoRA (rapide, peu de memory), SFT (qualité max, coûteux), RLHF (préférences humaines).
- Hyperparameter tuning** — Optuna + Ray Tune cherchent automatiquement meilleurs hyperparams (lr, batch size, LoRA rank, epochs) via budget GPU défini par client.
- Fine-tuning execution** — Run distribué sur GPUs H100/H200 avec checkpoints automatiques, auto-resume sur failure, monitoring temps réel via HarchOS dashboard.
- Evaluation** — Évaluation automatique post-FT sur dataset de validation (BLEU, ROUGE, MMLU, custom metrics). Comparaison vs base model.
- Deployment** — Auto-deploy du modèle fine-tuné vers inference service vLLM/TGI, accessible via API REST/gRPC OpenAI-compatible.

Fine-tuning entreprise — typique \$1k-\$20k

Un fine-tuning LoRA sur Llama-3 8B avec 100k exemples coûte typiquement \$500-\$1k (8 H100 spot, 2-4h).
Un fine-tuning SFT complet sur Llama-3 70B avec 1M exemples coûte \$5k-\$20k (50 H100 reserved, 4-8h).
Cette accessibilité permet aux PME EU de développer leurs propres modèles spécialisés sans dépendre d'APIs OpenAI/Anthropic (qui ne permettent pas de fine-tuning sur modèles frontier). Avantage souveraineté + coût.

07 MLOps STUDIO

Vue d'ensemble MLOps Studio

MLOps Studio est la plateforme logicielle propriétaire Harch Intelligence Enterprise qui orchestre le lifecycle ML complet : data preparation, training, fine-tuning, evaluation, deployment, monitoring. Développée par Harch Technology (60 ingénieurs, stack Python + Rust + Go + Kubernetes), elle intègre les meilleurs outils open source (MLflow, Kubeflow, Feast, Airflow) avec une UI custom qui simplifie l'expérience développeur.

Modules MLOps Studio

Module	Fonction	Technologie	Usage
Data Pipeline	Ingestion, validation, versioning datasets	DVC + Feast + custom	Data scientists
Experiment Tracker	Tracking runs, params, metrics, artifacts	MLflow + W&B integration	ML engineers
Training Orchestrator	Distributed training scheduling	Kubeflow + Ray Train	ML engineers
Hyperparameter Tuning	Auto-tuning optuna + Ray Tune	Optuna + Ray	ML engineers
Model Registry	Versioning models + lineage	MLflow Model Registry	MLOps
Evaluation Suite	Auto-eval BLEU/ROUGE/MMLU/custom	ml-evaluation-harness + custom	ML engineers
Deployment Manager	Deploy to inference (vLLM/TGI/Triton)	Kubernetes + ArgoCD	MLOps + DevOps
Monitoring & Observability	Drift detection, latency, throughput	Prometheus + Grafana + Evidently	MLOps
Carbon Tracker	Carbon footprint per workload	HarchOS Carbon Scheduler	ESG + sustainability
Cost Tracker	Cost per run + forecasting	Custom + Kubecost	Finance + engineering
Collaboration Hub	Notebooks, sharing, comments	JupyterHub + custom UI	All teams
API & SDK	Python + Node SDK, REST API	FastAPI + gRPC	Developers

Expérience développeur

MLOps Studio est conçue pour minimiser le time-to-value pour les développeurs ML. Concrètement : (i) notebooks Jupyterhub pré-configurés avec PyTorch/JAX + GPUs à la demande, (ii) SDK Python simple (harch.train(), harch.deploy(), harch.fine_tune()), (iii) dashboard web pour non-devs (business analysts, product managers), (iv) CLI pour power users. Cette approche multi-modal permet à toute l'entreprise d'utiliser la plateforme, pas seulement les ML engineers.

Interface	Usage	Audience	Time-to-first-result
Notebook JupyterHub	Exploration + prototypage	Data scientists	<5 min
SDK Python	Production pipelines	ML engineers	<30 min
Web dashboard	Monitoring + deployment	MLOps + PMs	<10 min
CLI	Automation + scripting	DevOps	<5 min
REST API	Integration avec stack existante	Developers	<1h
gRPC API	Low-latency integration	Backend devs	<1h

MLOps Studio — moat logiciel

MLOps Studio est un moat logiciel difficile à répliquer. Les concurrents (AWS SageMaker, Google Vertex AI, Azure ML) offrent des plateformes MLOps mais : (i) lock-in propriétaire fort, (ii) UX fragmentée (10+ services à orchestrer), (iii) pricing opaque (add-on pour chaque feature). MLOps Studio est intégrée nativement, transparente (open source les composants standards), et pricing inclus dans le GPU-h. Cette approche integrated est un argument commercial majeur pour clients entreprise lassés des hyperscalers.

08 INDUSTRY USE CASES — FINANCIAL SERVICES

Banque + assurance + asset management

Le secteur Financial Services est un client cible prioritaire Harch Intelligence Enterprise. Cas d'usage AI majeurs : (i) détection fraude temps réel, (ii) scoring crédit alternative data, (iii) chatbots customer service, (iv) robo-advisory, (v) analyse sentiment marché, (vi) AML/KYC automatisé. Ces workloads nécessitent (i) compliance DORA (règlement EU 2024), (ii) souveraineté données, (iii) audit trail complet, (iv) latence faible pour use cases temps réel.

Cas d'usage détaillés

Use case	Modèle	Volume	Latence requise	GPU type optimal	Coût mensuel H
Fraud detection	XGBoost + LLM explain	50M tx/jour	<50ms	L40S	\$3 200
Credit scoring	Llama-3 70B fine-tuned	100k dossiers/mois	<2s	H100	\$5 800
Chatbot customer service	Llama-3 70B + RAG	500k conv/mois	<500ms	H100	\$7 400
Robo-advisory	Llama-3 8B + custom	10k sessions/mois	<1s	L40S	\$1 200
Sentiment analysis marché	FinBERT + Llama-3	1M articles/mois	<5s	A100	\$2 100
AML/KYC automated	Llama-3 70B + vision	50k KYC/mois	<10s	H100 + L40S	\$8 900
Document intelligence	Llama-3 70B + OCR	1M pages/mois	<3s	H100	\$12 500

Compliance DORA

Le règlement DORA (Digital Operational Resilience Act) impose aux institutions financières EU des exigences strictes sur leurs services IT : (i) tier IV+ data centers, (ii) audit trail complet, (iii) subcontractors list transparency, (iv) incident reporting <4h, (v) ICT third-party risk management. Harch Intelligence Enterprise est conçu DORA-compliant avec : Tier IV+ certifié, SOC 2 Type II in progress, subprocessors list publique, incident response playbook <2h, ISO 27001 + ISO 22301 in progress.

Avantage souveraineté financière

Pour les banques européennes, l'enjeu de souveraineté AI est critique : (i) données clients sensibles (PII, transactions), (ii) stratégies trading propriétaires, (iii) modèles scoring propriétaires. AWS/Google/Azure (sociétés US) sont soumis au CLOUD Act qui permet aux autorités US d'accéder aux données. Harch Intelligence (société marocaine) n'est pas soumis au CLOUD Act, garantissant aux banques EU que leurs données et modèles restent sous juridiction EU/Maroc. Argument commercial majeur pour le secteur financier EU.

09 INDUSTRY USE CASES — HEALTHCARE

Hôpitaux + pharma + medical devices

Le secteur Healthcare utilise AI pour : (i) diagnostic medical imaging (radiologie, dermatologie, ophtalmo), (ii) drug discovery (protein folding, molecule generation), (iii) electronic health records (EHR) analysis, (iv) chatbots patient triage, (v) clinical trial recruitment. Ces use cases nécessitent (i) compliance HIPAA + RGPD, (ii) données patient ultra-sensibles, (iii) audit trail réglementaire, (iv) latence faible pour diagnostics temps réel.

Cas d'usage détaillés

Use case	Modèle	Volume	Latence requise	GPU type optimal	Coût mensuel H
Medical imaging diagnostic	UNET + ViT custom	1M scans/mois	<2s	L40S + H100	\$15 800
Drug discovery (protein folding)	AlphaFold2 + ESM-2	10k proteins/mois	<5 min	H100	\$22 400
EHR analysis + predictions	ClinicalBERT + custom	500k records/mois	<5s	A100	\$8 600
Patient triage chatbot	Llama-3 70B + medical RAG	50k consultations/mois	<1s	H100	\$6 200
Clinical trial matching	BioGPT + custom NER	10k trials × 1M patients	<10s	A100	\$4 800
Genomics analysis	Enformer + custom	1k genomes/mois	<30 min	H100	\$18 500
Medical document intelligence	Llama-3 70B + OCR	100k documents/mois	<5s	H100	\$5 400

Compliance HIPAA + RGPD Healthcare

Harch Intelligence Enterprise est conçu pour le secteur healthcare avec : (i) HIPAA compliance (Business Associate Agreement signed), (ii) RGPD pour données patient EU, (iii) ISO 27001 + 27018 in progress, (iv) encryption end-to-end AES-256, (v) audit trail complet (qui a accédé à quoi et quand), (vi) data residency EU/Maroc garantie. Les données patient ne sortent jamais de la juridiction. Pour les pharma EU, c'est critique pour les essais cliniques (réglementaire EMA strict).

Carbon footprint réduit — enjeu ESG pharma

L'industrie pharmaceutique EU est soumise à reporting ESG strict (CSRD 2025). L'empreinte carbone du compute AI pour drug discovery (typiquement 100-500 tCO2/projet sur AWS) est un poste significatif. Harch Intelligence réduit ce footprint de 89% (47 gCO2/kWh vs 316 AWS). Pour un programme drug discovery complet (5 ans, 50M GPU-h), économie carbone = 8 000 tCO2 — soit l'équivalent de 1 700 voitures/an. Argument commercial majeur pour pharma ESG-conscient.

10 INDUSTRY USE CASES — GOVERNMENT

Administrations + défense + sécurité

Le secteur Government est un client stratégique Harch Intelligence Enterprise. Cas d'usage : (i) automatisation administrative (chatbots citoyens, document processing), (ii) intelligence économique (OSINT, sentiment analysis), (iii) cybersécurité (détection anomalies, threat intel), (iv) smart cities (traffic, energy, surveillance), (v) défense (reconnaissance image, traduction, simulation). Ces use cases exigent (i) souveraineté absolue, (ii) clearance personnel, (iii) audit trail complet, (iv) certifications spécifiques.

Cas d'usage détaillés

Use case	Modèle	Volume	Sensibilité	GPU type optimal	Coût mensuel H
Chatbot citoyen multi-langue	Llama-3 70B + RAG admin	500k req/mois	Public	H100	\$7 800
Document processing administration	Llama-3 70B + OCR	1M docs/mois	Confidentiel	H100	\$12 500
OSINT intelligence économique	Llama-3 70B + NER custom	10M articles/mois	Confidentiel	A100	\$18 600
Cybersécurité anomaly detection	Custom GNN + LLM	1B events/jour	Secret	H100	\$24 800
Smart city traffic optimization	GNN + RL custom	10M sensors	Public	L40S	\$5 200
Défense reconnaissance image	YOLOv8 + ViT custom	1M images/mois	Secret défense	H100	\$32 400
Simulation militaire	Custom RL multi-agent	Continuous	Très secret	H100 + H200	\$58 600

Certifications gouvernementales

Harch Intelligence Enterprise poursuit les certifications spécifiques au secteur government : (i) ANSSI SecNumCloud (France, cible 2027), (ii) BSI C5 (Allemagne, cible 2027), (iii) ENS Alto (Espagne, cible 2027), (iv) NIS2 Directive EU (compliant 2025), (v) clearance personnel Marocains (DGST clearance). Pour les marchés gouvernementaux marocains et africains, Harch Intelligence est le seul opérateur AI hyperscale souverain local.

Sovereign AI — enjeu national

Pour les gouvernements EU et africains, l'enjeu Sovereign AI va au-delà du CLOUD Act : il s'agit de dépendance stratégique. Si un gouvernement dépend d'OpenAI/Anthropic/Google pour ses modèles AI, il perd sa souveraineté numérique. Harch Intelligence Enterprise permet aux gouvernements de : (i) déployer leurs propres modèles fine-tunés sur données souveraines, (ii) maintenir contrôle complet des infrastructures, (iii) développer une capacité AI nationale. Cette vision stratégique intéresse particulièrement France (SecNumCloud), Allemagne (GAIA-X), Maroc (Digital 2030).

11 INDUSTRY USE CASES — RESEARCH

Universités + labs publics + R&D; privé

Le secteur Research est un client early-adopter Harch Intelligence Enterprise. Cas d'usage : (i) pre-training modèles open source (Llama, Mistral, BigScience), (ii) recherche fondamentale AI (scaling laws, alignment, interpretability), (iii) scientific computing (climate modeling, protein folding, genomics), (iv) replication studies. Les labs recherche apprécient particulièrement (i) tarifs spot imbattables, (ii) carbon footprint réduit (ESG research reporting), (iii) accès capacity H200 rare.

Cas d'usage détaillés

Use case	Modèle	Volume GPU-h	Durée	GPU type	Coût Harch spot
Pre-training LLM 70B open source	Llama-3 class	35 000	2.9 jours (500 GPU)	H200	\$42k
Replication GPT-4 study	Custom 175B	125 000	10.4 jours (500 GPU)	H200	\$150k
Climate modeling regional	Custom climate model	50 000	2-3 semaines (128 GPU)	H100	\$47.5k
Protein folding mass	AlphaFold2 + ESM-2	15 000	1 semaine (64 GPU)	H100	\$14.3k
Alignment research RLHF	Custom 70B + RLHF	8 000	2 semaines (32 GPU)	H100	\$7.6k
Scaling laws study	Series of 1B-70B models	20 000	1 mois (50 GPU)	H100	\$19k
Interpretability research	Custom probe training	5 000	2 semaines (16 GPU)	H100	\$4.75k

Programme Academic Research

Harch Intelligence Enterprise propose un programme dédié Academic Research : (i) -30% discount sur tarifs spot pour universités et labs publics, (ii) capacity H200 garantie (réservée 20% Dakhla pour academic), (iii) support ML engineer gratuit (10h/projet), (iv) publication open access encouragée (Harch Intelligence cité dans acknowledgments). Objectif 2027 : 50 academic partners EU + Maroc + Afrique.

Programme	Eligibilité	Discount	Capacity garantie	Support
Academic Research Standard	Universités + labs publics	-30% spot	Non	5h ML eng
Academic Research Plus	Top-100 universities EU/Africa	-40% spot	20% Dakhla H200	10h ML eng
PhD Fellowship	PhD students AI/ML	-50% spot (10k GPU-h/an)	Non	20h ML eng
Open Source AI	Projets OSS (Llama, Mistral class)	-50% spot	20% Dakhla H200	20h ML eng
Climate Research Grant	Climate AI research	Gratuit (1M GPU-h/an)	Capacity dédiée	40h ML eng

Commitment open source + academic

Harch Intelligence Enterprise s'engage à soutenir la recherche AI académique et l'open source via (i) capacity H200 réservée academic (20% Dakhla), (ii) discounts jusqu'à -50% spot, (iii) programme Climate Research Grant gratuit pour la recherche climatique. Cet engagement reflète la mission Harch Corp de soutenir l'innovation AI souveraine et ESG-aligned. Les modèles open source entraînés sur Harch Intelligence (ex: Llama-3 variants) portent le label 'Trained on Harch Intelligence — 89% lower carbon'.

12 INDUSTRY USE CASES — MEDIA

Streaming + presse + gaming + advertising

Le secteur Media utilise AI pour : (i) content generation (images, video, music), (ii) recommendation engines, (iii) content moderation, (iv) automated dubbing + subtitling, (v) personalized advertising, (vi) virtual production. Ces use cases nécessitent (i) latence faible pour user experience, (ii) throughput élevé pour scale, (iii) cost-effectiveness pour marges publiques, (iv) carbon footprint réduit (ESG reporting media).

Cas d'usage détaillés

Use case	Modèle	Volume	Latence requise	GPU type optimal	Coût mensuel H
Image generation (marketing)	SDXL-Turbo + custom	1M images/mois	<3s	L40S	\$3 200
Video generation (shorts)	Stable Video Diffusion	100k videos/mois	<30s	H100	\$12 500
Music generation	AudioCraft + custom	50k tracks/mois	<10s	A100	\$5 400
Recommendation engine	Custom Two-Tower + LLM	500M req/jour	<100ms	A10	\$8 600
Content moderation	Llama-3 70B + vision	10M items/jour	<500ms	H100	\$15 800
Automated dubbing	Whisper-large + TTS + LLM	10k heures/mois	<5 min	H100	\$22 400
Personalized ads	Llama-3 8B + custom	100M impressions/jour	<50ms	L40S	\$18 600
Virtual production (gaming)	Custom diffusion + 3D	Continuous	<100ms	H100	\$45 800

Avantage prix + throughput media

Le secteur Media a des marges publiques relativement faibles (streaming 10-20%, presse 5-15%) et des volumes AI élevés. L'avantage prix Harch Intelligence (-30% à -40% vs AWS) est déterminant pour la rentabilité des use cases AI media. Exemple typique : content moderation sur 10M items/jour — coût Harch \$15.8k/mois vs AWS \$32k/mois (économie \$194k/an). Pour une plateforme streaming mid-size, l'économie annuelle atteint \$500k-\$2M selon volume AI.

13 PERFORMANCE BENCHMARKS (MLPerf)

MLPerf benchmarks

Harch Intelligence soumet ses configurations aux benchmarks MLPerf Training 4.0 et MLPerf Inference 4.0. Les résultats ci-dessous comparent les configurations Harch Intelligence (8 × H100 HGX sur hub Ouarzazate) aux configurations équivalentes AWS P5 (8 × H100 HGX) et Google A3 (8 × H100 HGX). Performance pure identique (même hardware), mais avec avantage carbon (-98%) et prix (-47%).

MLPerf Training 4.0 — 8 × H100 SXM5

Benchmark	Harch Intelligence (min)	AWS P5 (min)	Google A3 (min)	Avantage Harch
ResNet-50 (image classification)	3.8	3.8	3.8	— (même HW)
BERT-large (NLP)	3.2	3.2	3.2	— (même HW)
GPT-3 175B (LLM)	21.4	21.4	21.4	— (même HW)
Llama-2 70B (LLM)	5.7	5.7	5.7	— (même HW)
Stable Diffusion v2	4.2	4.2	4.2	— (même HW)
Mask R-CNN (segmentation)	2.9	2.9	2.9	— (même HW)
Retinanet (object detection)	3.5	3.5	3.5	— (même HW)
UNet-3D (medical imaging)	4.8	4.8	4.8	— (même HW)

MLPerf Inference 4.0 — 8 × H100 SXM5

Benchmark	Harch Intelligence	AWS P5	Google A3	Avantage Harch
ResNet-50 (offline)	185 000 samples/s	185 000	185 000	— (même HW)
ResNet-50 (server)	165 000 samples/s	165 000	165 000	— (même HW)
BERT-99 (offline)	52 000 seq/s	52 000	52 000	— (même HW)
GPT-3 175B (offline)	1 850 tokens/s	1 850	1 850	— (même HW)
Llama-2 70B (offline)	4 200 tokens/s	4 200	4 200	— (même HW)
Stable Diffusion v2	2 950 images/s	2 950	2 950	— (même HW)

Avantages Harch Intelligence au-delà du hardware

Avantage	Harch Intelligence	AWS P5	Google A3	Écart
Coût GPU-h (reserved 1y)	\$1.80	\$3.40	\$3.30	-47% à -45%
Carbon intensity (gCO2/kWh)		316	178	-85% à -74%
Latence gateway EU	8ms	N/A (Ireland)	N/A	Gateway EU direct
Time-to-first-GPU	5-10 jours	2-4 semaines	2-4 semaines	-66% à -75%
Sovereign (CLOUD Act)	Oui	Non	Non	Souveraineté
Support ML engineer	Inclus (5 sessions/mois)	\$300/h Add-on	\$300/h Add-on	Inclus
MLOps Studio	Inclus	SageMaker Add-on	Vertex AI Add-on	Inclus

Même hardware, meilleure expérience

Harch Intelligence utilise le même hardware NVIDIA H100/H200 que AWS P5 et Google A3 — donc performance MLPerf identique. La différenciation vient des avantages au-delà du hardware : (i) prix -47%, (ii) carbon -85%, (iii) latence gateway EU 8ms, (iv) souveraineté, (v) support inclus, (vi) MLOps Studio intégré. Cette combinaison fait d'Harch Intelligence la plateforme AI entreprise offrant le meilleur rapport performance/coût/souveraineté/ESG du marché.

Source : MLPerf Training 4.0 Results 2025, MLPerf Inference 4.0 Results 2025, NVIDIA HGX H100 Datasheet

14 COST COMPARISON VS HYPERSCALERS

Comparaison coût total (TCO)

La comparaison TCO entre Harch Intelligence Enterprise et les hyperscalers US/EU doit prendre en compte : (i) coût GPU-h (base), (ii) storage (NVMe/SSD/object), (iii) egress data (sortie traffic), (iv) support add-on, (v) MLOps platform (add-on vs inclus), (vi) compliance add-on. Sur 12 mois, l'économie typique est de 35-45% vs AWS, 30-40% vs Google, 35-50% vs Azure.

TCO comparé — workload type training

Composant coût (12 mois)	Harch Intelligence	AWS eu-west-1	Google europe-west1	Azure West EU
GPU-h (50 H100 reserved 24/7)	\$788k	\$1 489k	\$1 445k	\$1 511k
Storage NVMe 50 TB	\$108k	\$180k	\$150k	\$165k
Storage SSD 100 TB	\$114k	\$180k	\$150k	\$170k
Storage object 500 TB	\$15k	\$60k	\$50k	\$55k
Egress 100 TB/mois	\$0 (free internal)	\$95k	\$85k	\$90k
Support L3 premium	\$60k (inclus)	\$120k (Business)	\$120k	\$120k
MLOps platform	\$0 (inclus)	\$140k (SageMaker)	\$130k (Vertex)	\$140k (Azure ML)
Compliance add-on	\$0 (inclus)	\$50k (Audit support)	\$50k	\$50k
TCO 12 mois	\$1 085k	\$2 314k	\$2 230k	\$2 301k
Économie vs Harch	—	-53%	-51%	-53%
TCO total	\$1 085k	\$2 314k	\$2 230k	\$2 301k

TCO comparé — workload type inference

Composant coût (12 mois)	Harch Intelligence	AWS eu-west-1	Google europe-west1	Azure West EU
GPU-h (10 H100 spot 24/7)	\$83k	\$131k	\$126k	\$136k
Storage SSD 10 TB	\$11k	\$18k	\$15k	\$17k
Storage object 50 TB	\$1.5k	\$6k	\$5k	\$5.5k
Egress 10 TB/mois	\$0 (internal)	\$9.5k	\$8.5k	\$9k
Support L2 standard	\$0 (inclus)	\$30k	\$30k	\$30k
MLOps platform	\$0 (inclus)	\$35k	\$32k	\$35k
TCO 12 mois	\$95.5k	\$229.5k	\$216.5k	\$232.5k
Économie vs Harch	—	-58%	-56%	-59%
TCO total	\$95.5k	\$229.5k	\$216.5k	\$232.5k

Étude de cas — économie typique client

Profil client	Workload type	TCO AWS/an	TCO Harch/an	Économie annuelle	Économie 5 ans
Startup AI Series B	Training + inference	\$420k	\$235k	\$185k (-44%)	\$925k

Mid-size enterprise	Production inference	\$1.2M	\$680k	\$520k (-43%)	\$2.6M
Large enterprise	Hybrid training + inference	\$5.8M	\$3.2M	\$2.6M (-45%)	\$13M
Bank EU	Production AI compliance	\$3.4M	\$1.9M	\$1.5M (-44%)	\$7.5M
Pharma EU	Drug discovery + research	\$4.2M	\$2.3M	\$1.9M (-45%)	\$9.5M
Government EU	Sovereign AI projects	\$2.8M	\$1.5M	\$1.3M (-46%)	\$6.5M
University research lab	Academic research	\$850k	\$425k	\$425k (-50%)	\$2.1M

ROI migration AWS → Harch Intelligence

Pour un client entreprise type (mid-size), la migration des workloads AI d'AWS vers Harch Intelligence génère une économie annuelle de \$520k (-43%) — soit \$2.6M sur 5 ans. Cette économie suffit à financer (i) le recrutement d'un ML engineer senior (\$150k/an), (ii) les coûts de migration (one-time \$200-400k), (iii) une marge significative. ROI typique <12 mois. À cela s'ajoute le bénéfice ESG (carbon -89%) qui facilite la compliance CSRD et améliore le scoring ESG.

15 CARBON ADVANTAGE

Empreinte carbone comparée

L'empreinte carbone d'un workload AI dépend directement du carbon intensity du data center qui l'héberge. Harch Intelligence, avec 47 gCO2/kWh moyen (vs 316 AWS, 178 Google, 334 Azure), réduit le carbon footprint de 85-89%. Cette réduction est structurelle (énergie renouvelable dédiée) et vérifiable (audit Bureau Veritas 2027+, real-time reporting).

Carbon footprint par workload type

Workload	GPU-h	Énergie (kWh)	Harch CO2 (tCO2)	AWS CO2 (tCO2)	Économie CO2
Training Llama-3 70B	35 000	24 500	1.15	7.74	-6.59 (-85%)
Training GPT-3 175B	125 000	87 500	4.11	27.65	-23.54 (-85%)
Fine-tuning LoRA 7B	500	350	0.016	0.11	-0.094 (-85%)
Inference 1M tokens (LLM 70B)	100	0.35	0.000016	0.00011	-85%
Inference 1M images (SDXL)	18	5.6	0.00026	0.00177	-85%
Training Whisper-large	12 000	8 400	0.39	2.65	-2.26 (-85%)
Annual workload mid-size enterprise	50 000	35 000	1.65	11.06	-9.41 (-85%)

Reporting ESG + CSRD

Harch Intelligence Enterprise fournit à chaque client un carbon report détaillé par workload : (i) kWh consommés, (ii) carbon intensity du hub utilisé, (iii) CO2 total émis, (iv) comparaison vs AWS/Google/Azure (équivalent workload). Ce reporting est conforme aux exigences CSRD (Corporate Sustainability Reporting Directive) qui obligent les entreprises EU >250 employés à reporter scope 3 IT dès 2026. Le carbon report est généré automatiquement via HarchOS.




Figure : Carbon intensity par hub vs hyperscalers — argument commercial -89% vs AWS, -86% vs Azure

Carbon -89% — argument commercial majeur

Le carbon advantage -89% d'Harch Intelligence est un argument commercial majeur pour 3 raisons : (i) compliance CSRD 2026+ (entreprises EU >250 employés), (ii) engagement net-zero corporate (1000+ entreprises EU ont signé SBTi), (iii) préférence ESG-procurement (governments, banques, pharma). Pour un client entreprise mid-size, migrer 50 000 GPU-h/an d'AWS vers Harch économise 9.4 tCO2/an — l'équivalent de 2 voitures européennes/an. Cet argument est décisif dans 60-70% des deals entreprise EU.

16 SOVEREIGN SECURITY FRAMEWORK

Framework sécurité multi-couches

Harch Intelligence Enterprise déploie un framework sécurité 7 couches aligné avec NIST Cybersecurity Framework + ISO 27001 + SOC 2 : (i) Physical security (Tier IV+ sites, biometric access, 24/7 CCTV), (ii) Network security (VPC dedicated, WAF, DDoS protection), (iii) Identity & Access Management (SSO SAML, MFA, RBAC), (iv) Data protection (AES-256, KMS customer-managed), (v) Application security (SAST, DAST, pen-testing annuel), (vi) Monitoring (SIEM, anomaly detection), (vii) Incident response (playbook <2h, transparency report).

Composants sécurité par couche

Couche	Technologie	Certification	Audit
Physical security	Tier IV+, biometric, 24/7 guards + CCTV	Uptime Institute	Annual audit
Network security	VPC dedicated, WAF Cloudflare, DDoS protection	ISO 27001	Pen-test annuel
Identity & Access	SSO SAML, MFA TOTP, RBAC granular	ISO 27001	SOC 2 Type II
Data protection	AES-256 at-rest, TLS 1.3 in-transit, KMS Vault	ISO 27001 + 27018	Pen-test annuel
Application security	SAST SonarQube, DAST Burp, pen-test annuel	SOC 2	External audit
Monitoring & SIEM	Splunk + Elastic + custom anomaly detection	ISO 27001	Continuous
Incident response	Playbook <2h, transparency report, breach <72h notification	ISO 27001	Annual drill
Crypto-shredding	Customer-managed keys + crypto-delete on request	RGPD compliant	RGPD audit

Personnel & clearance

Rôle	Clearance requis	Background check	Accès données client
Account manager	Standard	Criminal + reference	Pas d'accès
Solutions architect	Standard + NDA	Criminal + reference + NDA	Accès sur demande client
ML engineer	Standard + NDA	Criminal + reference + NDA	Accès sur demande client
Support L1/L2	Standard + NDA	Criminal + reference	Accès logs uniquement
Support L3	Standard + NDA	Criminal + reference + NDA	Accès sur demande client
Site ops engineer	Marocain clearance DGS	DCST clearance Maroc	Pas d'accès données
Security team	ISO 27001 lead + NDA	Criminal + reference + NDA	Accès audit logs
Subcontractors	Selon contrat	BG check + NDA + transparency report	Sur approbation client

Zero-trust security — modèle entreprise

Harch Intelligence Enterprise applique un modèle zero-trust : aucun employé n'a accès par défaut aux données client. Tout accès est (i) explicitement autorisé par le client, (ii) audit trail complet (qui, quand, quoi), (iii) time-boxed (accès expire automatiquement), (iv) customer-visible (le client voit qui a accédé à ses données). Cette approche zero-trust est un standard entreprise bancaire/government rare chez les hyperscalers US qui ont des accès plus larges (notamment pour support).

17 DATA RESIDENCY (GDPR + CNDP)

Cadre légal double juridiction

Harch Intelligence Enterprise opère sous double juridiction : CNDP Maroc (Loi 09-08 sur la protection des données personnelles) et RGPD UE (Règlement 2016/679). Le Maroc a obtenu une adequacy decision partielle auprès de la Commission européenne en 2025 (full adequacy prévue 2026), permettant le transfert libre de données personnelles UE → Maroc. Pour les clients EU, Harch Intelligence applique les 2 frameworks en parallèle pour garantir compliance maximale.

Garanties data residency

Garantie	Description	Mécanisme	Audit
Data residency EU/Maroc	Données jamais hors UE/Maroc	VPC dedicated + geo-fencing	CNDP + RGPD
Pas de transfert US	Aucun sous-traitant US	Subprocessors list EU/Maroc only	Transparency report
Encryption at-rest	AES-256 customer-managed keys	HashiCorp Vault + HSM	ISO 27001 audit
Encryption in-transit	TLS 1.3 minimum	Auto-renewal + perfect forward secrecy	ISO 27001
Right to erasure	Suppression complète <30 jours	Crypto-shredding + verification	RGPD audit
Right to portability	Export gratuit toutes données	S3 + Kubernetes manifests	RGPD audit
Breach notification	<72h notification autorités + client	Incident response playbook	ISO 22301
DPO dedicated	Data Protection Officer Harch + optional DPOs	Dedicated or dedicated	RGPD compliant
Subprocessors list	Liste publique + 30 jours notice change	Vendor management program	SOC 2
Transparency report	Rapport annuel demandes gouvernementales	Legal opinion + audit	Annual

Cas spécifiques par secteur

Secteur	Réglementation spécifique	Harch compliance	Avantage vs hyperscalers US
Banque EU	DORA + RGPD + PSD2	DORA-compliant + CNDP + RGPD	Pas CLOUD Act
Assurance EU	Solvency II + RGPD	RGPD + CNDP + ISO 27001	Pas CLOUD Act
Pharma EU	EMA GxP + RGPD + HIPAA	RGPD + HIPAA BAA + CNDP	Pas CLOUD Act
Government EU	SecNumCloud / BSI C5 + RGPD	SecNumCloud in progress + RGPD	Pas CLOUD Act
Healthcare EU	RGPD + HIPAA + EHDS	RGPD + HIPAA BAA + EHDS-ready	Pas CLOUD Act
Government Maroc	CNDP + DGST clearance	CNDP compliant + DGST cleared	Sovereign local
Critical infrastructure	NIS2 Directive	NIS2 compliant 2025	Pas CLOUD Act

Double juridiction Maroc + UE

La double juridiction Maroc (CNDP) + UE (RGPD) est un avantage unique Harch Intelligence. Pour les clients EU, cela signifie : (i) données sous juridiction UE (RGPD), (ii) données également protégées par CNDP Maroc, (iii) pas de CLOUD Act US, (iv) pas de Patriot Act US, (v) pas de FISA 702 US. Cette double protection juridique est supérieure à celle d'OVHcloud/Scaleway (France only) qui ne bénéficient pas de la double juridiction. Argument décisif pour gouvernements EU + banques + pharma.

Source : European Commission Adequacy Decision Maroc 2025, CNDP Rapport Annual 2025, RGPD Regulation 2016/679

18 CUSTOMER ONBOARDING JOURNEY

Parcours client Enterprise

Le parcours d'onboarding Enterprise Harch Intelligence est conçu pour minimiser le time-to-value tout en assurant une compréhension profonde des besoins client. 4 phases sur 5-15 jours ouvrés (vs 4-8 semaines chez hyperscalers) : Discovery, Provisioning, First Workload, Production. Account manager + solutions architect + ML engineer dédiés sur toute la durée.

Phase 1 — Discovery (Jour 1-2)

- 1. Kickoff call (1h)** — Compréhension workloads client, use cases prioritaires, contraintes (latence, compliance, budget), équipe ML existante. Account manager + SA dédiés.
- 2. Technical assessment (2-4h)** — SA analyse stack ML existante, recommande architecture cible Harch Intelligence, identifie quick wins (workloads prioritaires à migrer).
- 3. Compliance review** — Vérification requirements réglementaires (RGPD, DORA, HIPAA, SecNumCloud) + signed agreements (DPA, BAA si healthcare, NDA).
- 4. Pricing proposal** — Quote personnalisée : mix reserved/spot/dedicated optimal, volume discounts, professional services. Négociation + signature <48h.

Phase 2 — Provisioning (Jour 3-5)

- 1. Account setup** — Création compte HarchOS, IAM + SSO SAML integration, VPC dedicated configuration, network setup (peering EU, VPN optionnel).
- 2. Capacity allocation** — Reserved capacity GPU-h allouée selon contract. Spot queues configurées. Dedicated hub si applicable (3-6 mois setup pour hub dédié).
- 3. Stack ML deployment** — Pre-installed PyTorch/JAX/TF + DeepSpeed/Megatron-LM + vLLM/TGI + MLflow/W&B.; Configuration selon preferences client (versions, env vars).
- 4. Training équipe client** — Session 4h : prise en main plateforme, SDK Python, dashboard web, CLI. Pour équipes ML matures, session advanced 8h.

Phase 3 — First Workload (Jour 6-10)

- 1. Workload selection** — Choix avec SA du premier workload (typiquement : fine-tuning simple ou inference pilote) pour valider plateforme et démontrer value.
- 2. Code deployment** — Client déploie code via Docker image ou HuggingFace model URI. SA assiste (pair programming 2-4h) si nécessaire.
- 3. Performance optimization** — SA + ML engineer Harch optimisent : batch size, gradient checkpointing, tensor parallelism, vLLM paged attention, quantization INT8/FP8.
- 4. Validation + carbon report** — Validation performance (latency, throughput, accuracy) + cost + carbon. Comparaison vs AWS/Google pour ROI quantifié.

Phase 4 — Production (Jour 11-15)

- 1. Production deployment** — Mise en production workload avec SLA (reserved 99.95%) ou best-effort (spot). Auto-scaling configuré (HPA custom metrics).
- 2. Monitoring + alerting** — Setup dashboards Grafana, alerting (Slack/Email/PagerDuty), SLO tracking, cost monitoring, carbon reporting.
- 3. Runbook + documentation** — Documentation runbook client (ops procedures, troubleshooting), formation équipe ops client (2h).
- 4. Quarterly Business Review** — SA + account manager trimestriel : review perf, cost, carbon, identification nouveaux use cases, optimisations.

Time-to-first-GPU 5-15 jours vs 4-8 semaines hyperscalers

Le time-to-first-GPU Harch Intelligence Enterprise est de 5-15 jours ouvrés (vs 4-8 semaines chez AWS/Google/Azure pour quota GPU H100). Cette rapidité est rendue possible par : (i) capacity GPU toujours disponible (pas de quota), (ii) stack ML pre-installed (pas de setup), (iii) account manager + SA + ML engineer dédiés (pas de support ticket), (iv) process onboarding industrialisé (templates, scripts, runbooks). Les clients enterprise apprécient particulièrement cette rapidité pour leurs projets AI time-sensitive.

19 PRICING MODELS

3 modèles de tarification

Harch Intelligence Enterprise propose 3 modèles de tarification pour s'adapter aux besoins et budgets clients : (i) Reserved (capacity garantie 24/7, commit 1-3 ans, prix le plus bas, pour production workloads), (ii) Spot (capacity best-effort, peut être preempted 2 min notice, prix 60% inférieur, pour batch/training), (iii) Dedicated (GPU dédié non partagé, prix premium, pour clients stratégiques avec SLA stricts).

Modèle Reserved

Paramètre	Reserved 1y	Reserved 3y	Commentaire
Prix H100 (\$/GPU-h)	1.80	1.65	-8% pour 3y commitment
Prix H200 (\$/GPU-h)	2.20	2.05	-7% pour 3y commitment
Capacity garantie	24/7	24/7	SLA 99.95%
Preemption possible	Non	Non	Capacity dédiée
Min commitment	50 GPU-h/mois	500 GPU-h/mois	Pour 3y commitment
Cancellation fee	30% reste contrat	50% reste contrat	Si early termination
Volume discount	Jusqu'à -20%	Jusqu'à -25%	200k GPU-h/mois+
Payment terms	Mensuel post-paid	Annuel pre-paid	1y pre-paid = -5%

Modèle Spot

Paramètre	Spot	Commentaire
Prix H100 (\$/GPU-h)	0.95	-47% vs reserved 1y
Prix H200 (\$/GPU-h)	1.20	-45% vs reserved 1y
Capacity garantie	Best-effort	Peut être indisponible
Preemption	2 min notice	Auto-save + checkpoint
Min commitment	Aucun	Pas d'engagement
Cancellation	À tout moment	Pas de fee
Volume discount	Jusqu'à -15%	Sur volume cumulé
Payment terms	Mensuel post-paid	Prélèvement auto

Modèle Dedicated

Paramètre	Dedicated	Commentaire
Prix H100 (\$/GPU-h)	2.40	+33% vs reserved 1y
Prix H200 (\$/GPU-h)	2.80	+27% vs reserved 1y
Capacity garantie	24/7 dédiée	GPU non partagé
Preemption	Jamais	GPU dédié au client
Min commitment	1 000 GPU-h/mois	Equivalent ~14 H100 full-time

Cancellation fee	60% reste contrat	Si early termination
Volume discount	Jusqu'à -10%	Sur 10k+ GPU-h/mois
Payment terms	Annuel pre-paid obligatoire	Setup \$25k one-time
Custom hub dédié	Custom (\$10M+/an)	Single-tenant hub complet

Recommandation par use case

Recommandation modèle selon use case : (i) Production inference avec SLA strict = Reserved 1y ou 3y, (ii) Training batch flexible (peut reprendre) = Spot, (iii) Fine-tuning interactive = Reserved ou Spot, (iv) Production stratégique avec SLA 99.99% = Dedicated, (v) R&D; exploration = Spot. Mix optimal typique pour client entreprise mid-size : 60% reserved + 30% spot + 10% dedicated. Account manager aide client à optimiser le mix selon workload portfolio.

20 SLA & SUPPORT

SLA Enterprise

Harch Intelligence Enterprise propose des SLA (Service Level Agreement) adaptés aux besoins entreprise : (i) Availability SLA (99.95% reserved, 99.99% dedicated), (ii) Latency SLA (<30ms/token LLM, <100ms API response), (iii) Throughput SLA (minimum tokens/s garanti), (iv) Support SLA (response time selon niveau). Credits automatiques si SLA non respecté.

SLA Enterprise par modèle

SLA	Reserved	Spot	Dedicated	Mécanisme credit
Availability	99.95% (≤22 min/an downtime)	Best-effort	99.99% (≤5 min/an)	10% credit si <99.95%
Latency LLM API	<30ms/token P95	Best-effort	<25ms/token P95	5% credit si >P95
Throughput	>1 500 tokens/s/GPU	Best-effort	>1 800 tokens/s/GPU	5% credit si <min
Cold start	<60s	Best-effort	<30s	5% credit si >60s
Network latency EU	<15ms (Tanger)	<15ms	<10ms (dedicated)	5% credit si >15ms
Support response L1	<4h	<8h	<1h	Credit support
Support response L2	<1h	<4h	<15 min	Credit support
Support response L3	Best-effort	Best-effort	<15 min 24/7	Credit support
Maintenance window	1/mois 2h scheduled	—	1/quarter 2h scheduled	15 jours notice

Niveaux de support

Niveau	Disponibilité	Response time	Channels	Prix	Inclus
L1 Basic	24/7 email + portal	<4h	Email + portal	Inclus	Tous clients
L2 Standard	24/7 + phone	<1h	Email + phone + portal	Inclus Reserved	Clients Reserved
L3 Premium	24/7 + Slack channel	<15 min	Phone + Slack + portal	\$5 000/mois	Add-on
L4 Dedicated TAM	Business hours + on-call	<15 min	Slack direct + monthly call	\$15 000/mois	Add-on
ML Engineer on-demand	On-demand	<2h	Slack + video	\$300/h	Add-on
Solutions Architect	Included 5 sessions/month	<1h	Email + video	Inclus	5 sessions/mois
Professional services	Project-based	—	Dedicated team	Custom quote	Custom

SLA 99.99% Dedicated — enterprise banking-grade

Le SLA 99.99% (≤5 min downtime/an) en mode Dedicated est comparable au meilleur SLA hyperscaler (AWS Enterprise Support 10% credit si <99.99%). Pour les clients à exigences maximales (banques, government, pharma), Harch Intelligence offre en plus : (i) dedicated TAM (Technical Account Manager), (ii) Slack channel direct, (iii) monthly business review, (iv) proactive monitoring. Cette qualité de support entreprise est rare chez les GPU clouds spécialisés (Lambda, CoreWeave).

21 PARTNERSHIPS ECOSYSTEM

Ecosystème partnerships

Harch Intelligence Entreprise a construit un écosystème de partnerships stratégiques pour enrichir son offre : (i) Technology partners (NVIDIA, IBM, Red Hat, Canonical), (ii) Integration partners (Accenture, Capgemini, Sopra, Inetum), (iii) Channel partners (MSP, VAR, system integrators EU/Afrique), (iv) Research partners (universities, labs publics), (v) Cloud partners (Cloudflare, OVHcloud interconnect).

Technology partners

Partner	Type	Périmètre	Statut	Bénéfices clients
NVIDIA	Premier AI partner	GPUs H100/H200, HGX, InfiniBand	Partner since 2024	Early access nouveau GPUs
IBM	Technology partner	Watsonx.ai integration, Power servers	Signed 2025	Hybrid AI deployments
Red Hat	OpenShift partner	OpenShift certified on HarchOS	Certified 2025	Enterprise OpenShift
Canonical	Ubuntu partner	Ubuntu Pro certified	Certified 2024	Ubuntu LTS support
HashiCorp	Technology partner	Vault, Consul, Terraform	Partner since 2024	Security + IaC
Cloudflare	Network partner	R2 storage + Workers + WAF	Partner since 2024	Edge compute + CDN
MongoDB	Database partner	Atlas integration	Partner since 2025	Vector search integration

Integration + channel partners

Partner	Type	Périmètre géographique	Spécialité	Statut
Accenture	Global SI	EU + Maroc + Afrique	AI transformation enterprise	Strategic partner
Capgemini	Global SI	EU + Maroc	AI + cloud migration	Strategic partner
Sopra Steria	European SI	France + EU	Sovereign AI + government	Strategic partner
Inetum	African SI	Maroc + Afrique francophone	Digital transformation Africa	Strategic partner
Deloitte	Big 4	EU + Maroc	AI strategy + audit	Preferred partner
PwC	Big 4	EU + Maroc	AI advisory + audit	Preferred partner
Local MSP Maroc	Channel	Maroc	SMB AI deployment	Channel partner
Local VAR EU	Channel	EU 5 pays	Mid-market AI	Channel partner

Research partners

Partner	Type	Périmètre	Contribution Harch	Bénéfices partner
UM6P (Maroc)	Université	Research + talent	GPUs gratuits academic	Research outputs + talents
ENS Paris-Saclay	Université	AI research	GPUs academic program	Research + publications
EPFL	Université	AI + climate research	Climate Research Grant	Publications + talents
ETH Zürich	Université	AI + scientific computing	GPUs academic program	Research outputs
Inria	Public lab	AI research	GPUs academic program	Research collaborations
CNRS	Public lab	Multi-disciplinary	GPUs academic program	Research collaborations

Max Planck Institute	Public lab	AI + scientific	GPUs academic program	Research outputs
----------------------	------------	-----------------	-----------------------	------------------

Channel partner program — expansion 2026-2027

Le programme channel partner Harch Intelligence Enterprise vise 50 partners actifs fin 2027 (MSP, VAR, SIs en EU + Maroc + Afrique). Commission : 15% sur revenu annuel client référencé (pendant 2 ans). Training partenaire gratuit (2 sessions/an). Co-marketing (events, webinaires, content). Ce programme vise à accélérer le go-to-market via partenaires locaux avec accès direct aux comptes entreprise EU/Afrique.

22 CUSTOMER SUCCESS STORIES

Success stories anonymisés

Les success stories ci-dessous sont anonymisées pour respecter les NDA clients. Elles illustrent les cas d'usage typiques et les bénéfices mesurés (coût, carbon, performance) de la migration vers Harch Intelligence Enterprise. Pour des références client détaillées, contacter sales@harchcorp.com.

Success Story 1 — Banque européenne Tier 2

Client: Banque européenne Tier 2 (5M clients, 8 pays EU). **Use case:** Chatbot customer service multi-langue + fraud detection temps réel. **Avant:** AWS eu-west-1, 24 H100 reserved, \$1.0M/an. **Après:** Harch Intelligence Tanger (latence 8ms), 24 H100 reserved + 8 H100 spot, \$580k/an. **Économie:** \$420k/an (-42%), 8.5 tCO2/an évitées (-89%), latence user 8ms (vs 0ms mais AWS Ireland). **Durée migration:** 8 semaines.

Success Story 2 — Pharma mid-size EU

Client: Pharma mid-size EU (2 500 employés, R&D; actif). **Use case:** Drug discovery (protein folding) + clinical trial matching. **Avant:** AWS + Google Cloud (mixed), sporadic GPU capacity. **Après:** Harch Intelligence Ouarzazate + Dakhla, 50 H100 spot + 8 H100 reserved, \$340k/an. **Économie:** \$480k/an (-58%), 22 tCO2/an évitées (-89%), capacity garantie. **Durée migration:** 6 semaines.

Success Story 3 — Government administration EU

Client: Government administration EU (pays <50M hab). **Use case:** Document processing administration + chatbot citoyen. **Avant:** AWS + Azure (mixed), données sous CLOUD Act. **Après:** Harch Intelligence Tanger + Casablanca (Sovereign AI), 16 H100 reserved + 32 A10 spot, \$280k/an. **Bénéfices:** Souveraineté juridique (+1 argument politique), \$420k/an économie (-60%), 6 tCO2/an (-89%), compliance DORA + SecNumCloud in progress. **Durée migration:** 12 semaines (compliance heavy).

Success Story 4 — Startup AI Series B

Client: Startup AI Series B EU (50 employés, LLM fine-tuning B2B). **Use case:** Fine-tuning Llama-3 70B pour clients enterprise + inference production. **Avant:** AWS p5 instances, quota GPU limité. **Après:** Harch Intelligence Dakhla + Ouarzazate, 32 H100 spot + 16 H100 reserved, \$95k/an. **Économie:** \$145k/an (-60%), 3.5 tCO2/an (-89%), capacity H200 garantie (rare chez AWS). **Durée migration:** 3 semaines.

Success Story 5 — Université research lab

Client: Université EU top-50, AI research lab. **Use case:** Pre-training LLM 70B open source + scaling laws research. **Avant:** Cluster H100 université (32 GPUs, limited capacity) + AWS spot sporadique. **Après:** Harch Intelligence Dakhla (500 H200 access via academic program), 50k GPU-h/an. **Économie:** \$725k/an vs AWS spot (-50% via Academic Research Plus), 18 tCO2/an (-89%), capacity H200 rare. **Durée migration:** 2 semaines.

Synthèse success stories

Client	Workload type	Économie annuelle	Carbon évité	Durée migration
Banque EU Tier 2	Chatbot + fraud	\$420k (-42%)	8.5 tCO2 (-89%)	8 semaines
Pharma mid-size EU	Drug discovery	\$480k (-58%)	22 tCO2 (-89%)	6 semaines
Government EU	Document AI + chatbot	\$420k (-60%)	6 tCO2 (-89%)	12 semaines

Startup AI Series B	LLM fine-tuning	\$145k (-60%)	3.5 tCO2 (-89%)	3 semaines
Université research	LLM pre-training	\$725k (-50%)	18 tCO2 (-89%)	2 semaines
Moyenne	—	\$438k (-54%)	11.6 tCO2 (-89%)	6.2 semaines

Économie moyenne -54% + carbon -89%

Sur 5 success stories représentatives, l'économie moyenne annuelle est de \$438k (-54%) avec carbon footprint réduit de 89%. La durée moyenne de migration est de 6 semaines (vs 8-16 semaines pour migrations entre hyperscalers). Ces résultats valident le positionnement Harch Intelligence Enterprise : compétitivité prix (-54% moyenne), leadership ESG (-89% carbon), et rapidité d'onboarding (6 semaines vs 8-16).

23 ROADMAP 2026-2030

Roadmap Enterprise 2026-2030

Le roadmap Harch Intelligence Enterprise 2026-2030 couvre 5 années critiques : expansion capacity (3.5k+ GPUs 2030), nouveaux hubs (Phase 2 extensions), certifications compliance (SecNumCloud, BSI C5), partnerships ecosystem (50+ channel partners), et expansion géographique (Afrique Ouest, Moyen-Orient). Chaque année a des jalons critiques.

Année	Capacity GPUs	Revenu Enterprise (M\$)	Jalons clés	Certifications
2026	1 798	\$45	MLOps Studio v2 + Hub Dakhla construction	SOC 17001, SOC 2 Type II
2027	2 200	\$85	Hub Dakhla opérationnel + academic SecNumCloud	SecNumCloud, BSI C5
2028	2 800	\$145	Hub Dakhla scale + dedicated hub 1e North	ENISA, HIPAA
2029	3 200	\$210	Hub Phase 4 launch + 50 channel partners	Free RAMP (optionnel)
2030	3 500+	\$285	Build-out final + expansion Afrique Ouest	ES Corp, full compliance
CAGR 2026-2030	+38%/an	+59%/an	—	—
2030	3 500+	\$285M	—	—

Jalons critiques transversaux

Jalon	Date cible	Condition	Impact si échec
Hub Dakhla 500 H200 opérationnel	Q4 2027	Construction + énergie dédiée	Bottleneck capacity AI
MLOps Studio v2 launch	Q2 2026	Dev Harch Technology 6 mois	Compétitivité platform
SecNumCloud certification	Q4 2027	Audit + process government	Marché government EU
50 channel partners signés	Fin 2029	Programme channel + sales ops	Go-to-market scale
Revenu Enterprise \$285M	2030	8 subsidiaries + 350 clients	IPO / strategic exit 2032+
Expansion Afrique Ouest	2030+	1er hub Sénégal ou Côte d'Ivoire	Limitation footprint
Carbon net-zero 2030	2030	100% renouvelable Harch Energy	Objectif ESG non atteint

Cible 2030 — \$285M revenu Enterprise, 350 clients

À l'horizon 2030, Harch Intelligence Enterprise vise \$285M de revenu (mix reserved 60% + spot 25% + dedicated 15%) avec 350 clients enterprise actifs (mix EU 60% + Maroc 25% + Afrique 15%). EBITDA marge cible 45% (vs 30-35% hyperscalers). Cette performance soutient la contribution Harch Intelligence au revenu consolidé Harch Corp (\$680M 2030) à hauteur de 42%. À valuation EBITDA multiple 12-15x (sectoriel AI infra), Harch Intelligence vaut \$1.5-1.9B à maturité 2030.

24 CONTACTS SALES & DISCLAIMER

Contacts Sales Enterprise

Contact	Rôle	Email	Téléphone
Sales Enterprise EU	Vente entreprise Europe	sales-eu@harchcorp.com	+33 1 76 38 00 10
Sales Enterprise Maroc	Vente entreprise Maroc	sales-ma@harchcorp.com	+212 5 22 00 00 30
Sales Enterprise Afrique	Vente entreprise Afrique	sales-af@harchcorp.com	+212 5 22 00 00 31
Solutions Architects	Pre-sales + onboarding	solutions@harchcorp.com	+212 5 22 00 00 22
Government Sales	Sector government	gov@harchcorp.com	+212 5 22 00 00 32
Financial Services Sales	Sector banque/assurance	finance@harchcorp.com	+212 5 22 00 00 33
Healthcare Sales	Sector pharma/healthcare	health@harchcorp.com	+212 5 22 00 00 34
Academic Research	Universités + labs publics	academic@harchcorp.com	+212 5 22 00 00 35
Channel Partner Program	MSP/VAR/SI partners	partners@harchcorp.com	+212 5 22 00 00 36
Professional Services	ML engineering on-demand	ps@harchcorp.com	+212 5 22 00 00 37

Support Enterprise

Niveau	Disponibilité	Channel	Contact
L1 Basic	24/7	Email + portal	support@harchcorp.com
L2 Standard	24/7	Email + phone	+212 5 22 00 00 40
L3 Premium	24/7	Slack + phone	Slack: harch-intel-premium
L4 Dedicated TAM	Business hours + on-call	Slack direct	TAM dédié
ML Engineer on-demand	On-demand	Slack + video	ml-eng@harchcorp.com
Security incidents	24/7	Phone + email	security@harchcorp.com

Présence digitale

Site web	harchcorp.com/intelligence/ai-solutions
Documentation	docs.harchcorp.com/enterprise
Pricing calculator	harchcorp.com/intelligence/pricing
Customer portal	portal.harchcorp.com
Status page	status.harchcorp.com
Real-time carbon	harchcorp.com/intelligence/carbon
Partner program	harchcorp.com/partners
Academic program	harchcorp.com/academic
LinkedIn	linkedin.com/company/harch-intelligence

Twitter/X	@harchintelligence
YouTube	youtube.com/@harchcorp
GitHub	github.com/HarchCorp/enterprise-examples

Disclaimer

Cette brochure est publiée par Harch Corp S.A. à titre commercial et informatif pour les clients entreprise, partenaires, et décideurs IT. Les informations présentées sont basées sur des spécifications internes, des sources publiques, et des projections. Elles ne constituent pas un conseil en investissement ni un engagement contractuel.

Les prix GPU indiqués (\$1.80-2.20/GPU-h H100 reserved) sont indicatifs et peuvent évoluer. Les discounts volume, bundles, et conditions spéciales sont négociés cas par cas. Les métriques techniques (PUE, carbon intensity, latence) seront auditées par cabinets indépendants (Bureau Veritas, Uptime Institute) à partir de 2026. Les certifications (ISO, SOC 2, SecNumCloud) sont en cours d'obtention selon calendrier indiqué.

Les success stories client sont anonymisées pour respecter les NDA. Les économies annoncées (-42% à -60% vs AWS) sont basées sur des cas réels mais peuvent varier selon workload, volume, et conditions. Pour un quote personnalisé, contacter sales-eu@harchcorp.com.

Licence & copyright

© 2026 Harch Corp S.A. Tous droits réservés. Cette brochure est classifiée Commercial — Enterprise Edition. Reproduction interdite sans autorisation écrite préalable. Pour toute demande de redistribution ou utilisation, contacter sales-eu@harchcorp.com.

Métadonnées publication

URL	harchcorp.com/intelligence/ai-solutions
Contact	sales-eu@harchcorp.com
Date de publication	Juin 2026
Version	2.0 (refonte complète)
Auteur	Harch Intelligence — Direction Enterprise
Validé par	Conseil d'Administration Harch Corp S.A.
Classification	Commercial — Enterprise Edition
Prochaine mise à jour	T4 2026 (post-Hub Dakhla commissioning)

Building in Public — Harch Intelligence Enterprise

Harch Intelligence publie ses métriques opérationnelles (PUE, carbon intensity temps réel, latence, disponibilité, pricing) en open data sur status.harchcorp.com et harchcorp.com/intelligence/pricing. Cette brochure est destinée aux clients entreprise EU, Maroc, et Afrique. Pour accéder aux dossiers research complets (AI, énergie, mining), visitez harchcorp.com/research. Pour toute question commerciale : sales-eu@harchcorp.com.