

DOSSIER 00

CONFIDENTIAL · TECHNICAL EDITION

Juin 2026 · v2

Harch Intelligence Datasheet 2026

*1,798 GPUs · 5 Hubs · PUE <1.15
89% below industry carbon intensity*

GPUs

1,798

HUBS

5

PUE

<1.15

CARBON

-89%

00 TABLE DES MATIÈRES

N°	Section	Page
01	Executive Summary	3
02	Platform Overview	4
03	Hub Dakhla — Flagship Training	5
04	Hub Ouarzazate — Training + Inference	7
05	Hub Benguerir — Hybrid Workloads	8
06	Hub Tanger — Gateway Europe	9
07	Hub Casablanca — HQ + Edge	10
08	GPU Specifications (H100 + H200)	12
09	Network Fabric 400G InfiniBand	14
10	Storage Tiers	15
11	Power Infrastructure	17
12	Cooling Systems	18
13	Network Connectivity (Submarine Cables)	20
14	Latency to Europe	21
15	Security & Compliance (Tier IV+)	23
16	Carbon-Aware Scheduling	25
17	PUE Benchmarking	26
18	Carbon Intensity vs Hyperscalers	27
19	AI Frameworks Support	28
20	Pricing (GPU-hour)	29
21	Customer Onboarding	30
22	ESG & Contacts	31

Note de lecture

Ce datasheet présente la filiale Harch Intelligence — opérateur du plus grand réseau africain de data centers AI hyperscale avec 5 hubs au Maroc (Dakhla, Ouarzazate, Benguerir, Tanger, Casablanca) totalisant 1 798 GPUs NVIDIA H100/H200. PUE <1.15, latence 8ms vers Europe, carbon intensity 89% inférieure à la moyenne industrie. Document destiné aux clients entreprise, partenaires techniques, et investisseurs. Version 2.0 — Juin 2026.

01 EXECUTIVE SUMMARY

Harch Intelligence en bref

Harch Intelligence est la filiale AI infrastructure du groupe Harch Corp S.A., opérant le plus grand réseau africain de data centers AI hyperscale. 5 hubs au Maroc (Dakhla, Ouarzazate, Benguerir, Tanger, Casablanca) totalisant 1 798 GPUs NVIDIA H100/H200, connectés via fabric 400G InfiniBand, alimentés à 100% en énergie renouvelable dédiée Harch Energy, et opérés sous la plateforme HarchOS. Conçus dès l'origine pour le compute AI (pas retrofit de data centers legacy), avec PUE <1.15 et carbon intensity 47 gCO2/kWh (vs 450 moyenne industrie).

Le positionnement Harch Intelligence combine 3 avantages structurels uniques : (i) intégration verticale avec Harch Energy (coût énergie 72% inférieur, 100% renouvelable dédiée), (ii) position géographique stratégique (latence 8ms vers Europe via 14 câbles sous-marins, juridiction CNDP compatible RGPD), (iii) stack technologique propriétaire (HarchOS carbon-aware scheduling, MLOps Studio). Cette combinaison permet des tarifs GPU 30-40% inférieurs aux hyperscalers européens (AWS, Google Cloud, Azure) avec 89% moins de carbone.

Métriques clés

Métrique	Valeur	Source / Justification
GPUs installés	1 798 (H100 + H200)	Mix NVIDIA H100 80GB + H200 141GB
Hubs data center	5 au Maroc	Dakhla, Ouarzazate, Benguerir, Tanger, Casablanca
Capacité totale	500 MW full build-out	435 MW active 2026
PUE (Power Usage Effectiveness)	<1.15	1.20-1.25 moyenne industrie
Carbon intensity	47 gCO2/kWh moyenne	450 moyenne industrie (-89%)
Latence vers UE	8 ms (Dakhla → Marseille)	<30 ms financiers EU
Network fabric	400 Gbps InfiniBand HDR	NVIDIA Quantum-2
Storage capacity	15 PB	NVMe + SSD + object
Tier rating	IV+ (Uptime Institute)	Plus haute disponibilité
CAPEX 2024-2030	\$1.14B	Equity + dette projet + subventions
Revenu cible 2030	\$285M	Mix reserved + spot + dedicated
EBITDA marge cible 2030	45%	vs 30-35% hyperscalers

Positionnement stratégique

Le plus grand réseau AI hyperscale d'Afrique

Harch Intelligence représente le premier réseau africain de data centers AI hyperscale conçu nativement pour le compute LLM. Contrairement aux opérateurs existants (Africa Data Centres, Teraco, Raxio) qui opèrent des data centers généralistes retrofités pour AI, Harch Intelligence a été conçu dès l'origine avec : power density 60-100 kW/rack (vs 8-15 kW legacy), cooling liquid-ready, fabric 400G InfiniBand natif, et énergie renouvelable dédiée co-localisée. Cette approche integrated est unique hors USA/Europe.

02 PLATFORM OVERVIEW

Architecture plateforme

La plateforme Harch Intelligence est organisée en 5 hubs interconnectés via backbone 400G InfiniBand national. Chaque hub est conçu pour un workload type (training LLM, inference, hybrid, edge) avec un mix GPU optimisé. Le tout est orchestré par HarchOS — plateforme logicielle propriétaire qui gère le carbon-aware scheduling, le monitoring temps réel, le MLOps Studio pour clients, et la facturation à l'heure.

Les 5 hubs AI

Hub	GPUs	Power (MW)	Renewable %	Carbon (gCO2/kWh)	Rôle stratégique	Statut
Dakhla	500	120	97.2%	18	Training LLMs (énergie la plus propre)	Construction Q4 2027
Ouarzazate	450	110	97.2%	18	Training + inference	Opérationnel 2025
Benguerir	350	85	88.5%	55	Hybrid workloads + storage	Opérationnel 2026
Tanger	200	50	82.1%	95	Gateway Europe (latence 8ms)	Opérationnel 2025
Casablanca	298	70	45%	210	HQ + dev + inference edge	Opérationnel 2025
Total	1 798	435	81.5% moy.	47 moy.	—	—
Total	1 798	435	81.5%	47	—	—

Stack technologique

Couche	Technologie	Capacité / Détail	Rôle
GPU compute	NVIDIA H100 80GB + H200 141GB	1 798 GPUs total	Training + inference LLM
Network fabric	NVIDIA Quantum-2 InfiniBand	400 Gbps port, fat-tree	Inter-GPU comms
Storage NVMe	Solidigm D7-P5520 + Samsung	5 PB NVMe direct-attach	Hot tier checkpoints
Storage SSD	Micron 7450 + WD Ultrastar	7 PB SSD cluster	Warm tier datasets
Storage object	Cloudflare R2 + MinIO on-prem	3 PB object	Cold tier + archives
Orchestration	Kubernetes 1.30 + Slurm	Multi-tenant GPU scheduling	Workload management
MLOps Studio	HarchOS (propriétaire)	MLflow + Kubeflow + custom	Client-facing platform
Monitoring	Prometheus + Grafana + Datadog	Real-time metrics	Observability
Security	HashiCorp Vault + Calico	Zero-trust network	Compliance + audit
Carbon-aware	HarchOS Carbon Scheduler	Real-time routing	Carbon optimization

Architecture intégrée HarchOS

HarchOS est la plateforme logicielle propriétaire qui orchestre l'ensemble du réseau Harch Intelligence. Développée par Harch Technology (60 ingénieurs, stack Python + Rust + Go + Kubernetes), elle intègre 4 modules clés : (i) Carbon-Aware Scheduler (routing temps réel vers hub le moins carboné), (ii) MLOps Studio (pipeline ML pour clients), (iii) Real-Time Monitor (télémétrie production + consommation), (iv) Finance Cockpit (facturation à l'heure + analytics). HarchOS est un moat technologique difficile à répliquer (3-5 ans pour un concurrent).

03 HUB DAKHLA — FLAGSHIP TRAINING

Vue d'ensemble

Le hub Dakhla est le flagship Harch Intelligence — le plus grand data center AI d'Afrique, dédié au training des LLMs les plus exigeants. 500 GPUs NVIDIA H200 141GB, 120 MW puissance, 100% énergie renouvelable dédiée (mix solaire + éolien hybride Harch Energy Dakhla, carbon intensity 18 gCO2/kWh — parmi les plus bas au monde). Construction Q1 2026, mise en service Q4 2027. Investissement \$285M.

Spécifications techniques

Paramètre	Valeur	Benchmark
GPUs	500 × NVIDIA H200 141GB	GPU LLM training haut de gamme
Racks	125 racks (4 GPUs/rack en HGX)	Density 60 kW/rack
Power total	120 MW (peak), 100 MW average	—
PUE	1.12 (cible)	1.20-1.25 industrie
Carbon intensity	18 gCO2/kWh	450 moyenne (-96%)
Renewable fraction	97.2%	<30% moyenne industrie
Network fabric	400 Gbps InfiniBand HDR	Fat-tree non-blocking
Storage NVMe	2 PB direct-attach	Checkpoints LLM
Cooling	Liquid cooling direct-to-chip + rear door	PUE optimized
Tier rating	IV+ (Uptime Institute)	99.995% disponibilité
CAPEX	\$285M	Construction 2026-2027
Mise en service	Q4 2027	Construction commencée Q1 2026

Cas d'usage principal

Dakhla est optimisé pour le training des LLMs 100B-400B paramètres (GPT-4 class, Claude class, Gemini class). 500 GPUs H200 141GB permettent d'entraîner un modèle 70B paramètres en 14 jours (vs 30+ jours sur 256 GPUs H100). Carbon footprint entraînement : 12 tCO2 pour un GPT-3 class (vs 552 tCO2 sur grid moyen US). Clients cibles : labs AI académiques, startups LLM, entreprises fine-tuning modèles propriétaires.

Workload type	GPU-h nécessaires	Temps Dakhla (500 GPUs)	CO2 émis (tCO2)	CO2 vs AWS
Training GPT-3 175B (scratch)	125 000	10.4 jours	12	-98%
Training Llama-3 70B (scratch)	35 000	2.9 jours	3.4	-98%
Fine-tuning Llama-3 70B (SFT)	5 000	10 heures	0.5	-98%
Inference GPT-3 class (1M tokens)	500	1 heure	0.05	-98%
Training Mixtral 8x7B	15 000	1.25 jour	1.5	-98%
Training diffusion model SD-3	8 000	16 heures	0.8	-98%

Le hub AI le plus propre au monde

Avec un carbon intensity de 18 gCO₂/kWh, le hub Dakhla est l'un des data centers AI les plus propres au monde — comparable uniquement aux sites islandais (geothermal) et norvégiens (hydro). Pour un client entreprise ESG-conscious, entraîner un LLM sur Dakhla réduit l'empreinte carbone de 96-98% vs AWS eu-west-1. Cette caractéristique est un avantage commercial majeur face aux contraintes CSRD européennes (reporting scope 3 obligatoire 2026+).

Source : NVIDIA H200 Datasheet 2025, IEA Data Center Energy 2024, Harch Intelligence Internal Specs

04 HUB OUARZAZATE — TRAINING + INFERENCE

Vue d'ensemble

Le hub Ouarzazate est le premier data center AI Harch Intelligence opérationnel (depuis Q4 2024). 450 GPUs NVIDIA H100 80GB, 110 MW, 100% énergie renouvelable dédiée via parc solaire Harch Energy Ouarzazate (350 MW co-localisé). Carbon intensity 18 gCO2/kWh. Mix workloads : 60% training LLM (clients académiques + startups), 40% inference production (clients entreprise). Investissement \$240M, opérationnel.

Spécifications techniques

Paramètre	Valeur
GPUs	450 × NVIDIA H100 80GB SXM5
Racks	113 racks HGX H100 4-GPU
Power total	110 MW (peak), 95 MW average
PUE	1.14 (mesuré 2025)
Carbon intensity	18 gCO2/kWh (solaire dédié)
Renewable fraction	97.2% (solaire Harch Energy)
Network fabric	400 Gbps InfiniBand HDR
Storage NVMe	1.5 PB direct-attach
Cooling	Air + rear door heat exchangers
Tier rating	IV+ (certifié Q1 2025)
CAPEX	\$240M
Mise en service	Q4 2024 (tranche 1), Q2 2025 (tranche 2)

Cas d'usage

Ouarzazate accueille une mixité de workloads : (i) training modèles 7B-70B paramètres pour startups AI françaises et marocaines (60% capacité), (ii) inference production pour clients enterprise (chatbots, RAG, code generation) — 40% capacité. La flexibilité workload est enabled par HarchOS qui route dynamiquement les jobs selon carbon intensity temps réel et priorité client.

Premier hub opérationnel — référence

Ouarzazate est le hub de référence Harch Intelligence — le seul opérationnel depuis 2024, validant le modèle intégré Harch Energy + Harch Intelligence. Les métriques mesurées (PUE 1.14, carbon 18 gCO2/kWh, latence 12ms vers Marseille) dépassent les spécifications initiales, validant la faisabilité technique du réseau 5 hubs. Le hub accueille déjà 8 clients entreprise et 4 labs académiques.

05 HUB BENGUERIR — HYBRID WORKLOADS

Vue d'ensemble

Le hub Benguerir est le hub hybride Harch Intelligence — optimisé pour les workloads mixtes training + inference + storage-heavy. 350 GPUs NVIDIA H100 80GB, 85 MW, alimenté par le parc solaire + stockage Harch Energy Benguerir (300 MW + 100 MWh batterie). Carbon intensity 55 gCO2/kWh (légèrement supérieur à Dakhla et Ouarzazate car stockage batterie requis pour profil intermittent). Opérationnel depuis Q1 2026. Investissement \$190M.

Spécifications techniques

Paramètre	Valeur
GPUs	350 × NVIDIA H100 80GB SXM5
Racks	88 racks HGX H100 4-GPU
Power total	85 MW (peak), 75 MW average
PUE	1.15 (mesuré 2026)
Carbon intensity	55 gCO2/kWh (solaire + stockage)
Renewable fraction	88.5% (solaire + batterie backup)
Network fabric	400 Gbps InfiniBand HDR
Storage NVMe + SSD	2.5 PB (cluster partagé)
Cooling	Air + adiabatic (dry cooler)
Tier rating	IV+ (certifié Q4 2025)
CAPEX	\$190M
Mise en service	Q1 2026

Hub hybride — flexibilité workload

Benguerir est positionné comme le hub polyvalent Harch Intelligence. Il accueille (i) les workloads storage-heavy (datasets ML, model checkpoints long terme), (ii) les workloads inference entreprise avec SLA stricts, (iii) le training de modèles 7B-13B paramètres (fine-tuning clients). Le stockage cluster 2.5 PB fait de Benguerir le hub de référence pour le data lake groupé Harch Intelligence.

06 HUB TANGER — GATEWAY EUROPE

Vue d'ensemble

Le hub Tanger est le gateway Harch Intelligence vers l'Europe — le hub à la latence la plus basse vers les IXPs européens (8ms Marseille, 12ms Paris, 15ms Francfort, 18ms Londres). 200 GPUs NVIDIA H100 80GB, 50 MW, alimenté par le parc éolien Harch Energy Tanger (200 MW). Carbon intensity 95 gCO2/kWh (supérieur aux hubs sud car éolien moins consistant, mais reste 79% inférieur à la moyenne industrie). Opérationnel depuis Q2 2025. Investissement \$115M.

Spécifications techniques

Paramètre	Valeur
GPUs	200 × NVIDIA H100 80GB SXM5
Racks	50 racks HGX H100 4-GPU
Power total	50 MW (peak), 42 MW average
PUE	1.16 (mesuré 2025)
Carbon intensity	95 gCO2/kWh (éolien)
Renewable fraction	82.1% (éolien + grid backup)
Network fabric	400 Gbps InfiniBand HDR
Storage NVMe	1 PB direct-attach
Cooling	Air (free-cooling exploitant climat Tanger)
Tier rating	IV+ (certifié Q2 2025)
Latence Marseille (Gernetix)	8 ms
CAPEX	\$115M

Cas d'usage gateway Europe

Tanger est le hub optimisé pour les clients européens nécessitant une latence faible : (i) inference production entreprise (chatbots, RAG, voice AI) — 70% capacité, (ii) edge training pour clients EU soucieux de data residency (juridiction Maroc CNDP compatible RGPD) — 30% capacité. La latence 8ms permet une expérience utilisateur indissociable d'un data center EU, avec 89% moins de carbone et 30-40% moins cher.

Destination EU	Latence Tanger (ms)	Latence AWS eu-west-1 (ms)	Avantage
Marseille (Gernetix IXP)	8	—	Gateway direct
Paris (France-IX)	12	0	12ms acceptable
Francfort (DE-CIX)	15	0	15ms acceptable
Londres (LINX)	18	0	18ms acceptable
Amsterdam (AMS-IX)	17	0	17ms acceptable
Madrid (Espanix)	11	0	11ms excellent
Milan (MIX)	21	0	21ms acceptable

Latence 8ms — indissociable d'un data center EU

Avec une latence de 8ms vers Marseille, le hub Tanger offre une expérience utilisateur indissociable d'un data center européen pour la majorité des applications (chatbots, RAG, code completion, voice AI). Cette caractéristique permet à Harch Intelligence de concurrencer directement AWS/Google/Azure sur les workloads inference EU, tout en offrant 89% moins de carbone et 30-40% moins cher. C'est le hub commercial principal pour clients EU.

Source : PeeringDB 2025, Submarine Cable Map 2025, Netflix ISP Speed Index

07 HUB CASABLANCA — HQ + EDGE

Vue d'ensemble

Le hub Casablanca est le siège Harch Intelligence et le hub edge inference. 298 GPUs NVIDIA H100 80GB, 70 MW, alimenté par grid ONEE (mix 45% renouvelable Maroc). Carbon intensity 210 gCO2/kWh (supérieur aux hubs dédiés car grid public, mais reste 53% inférieur à moyenne EU). Opérationnel depuis Q4 2024. Investissement \$140M. Hub principal pour inference edge et développement ML.

Spécifications techniques

Paramètre	Valeur
GPUs	298 × NVIDIA H100 80GB PCIe + SXM5
Racks	75 racks mixtes
Power total	70 MW (peak), 58 MW average
PUE	1.18 (mesuré 2025)
Carbon intensity	210 gCO2/kWh (grid ONEE)
Renewable fraction	45% (grid ONEE mix)
Network fabric	200 Gbps InfiniBand NDR + 100G Ethernet
Storage NVMe + SSD	3 PB cluster principal
Cooling	Air + adiabatic
Tier rating	IV+ (certifié Q4 2024)
CAPEX	\$140M
Mise en service	Q4 2024

Cas d'usage HQ + edge

Casablanca accueille (i) le siège Harch Intelligence et équipes engineering, (ii) l'inference edge pour clients marocains et africains (latence <5ms Maroc, <50ms Afrique Ouest), (iii) le développement ML interne Harch Technology, (iv) le MLOps Studio demo pour prospects. Hub principal pour le marché local et showcase technologique.

Hub Casablanca — edge + dev

Casablanca joue un rôle hybride : (i) inference edge pour clients marocains (banques, télécoms, government) nécessitant latence ultra-faible, (ii) hub de développement ML où Harch Technology teste les nouvelles versions HarchOS avant déploiement national, (iii) showroom pour prospects et investisseurs. Le carbon intensity supérieur (210 gCO2/kWh) est compensé par le routing carbon-aware des workloads vers les hubs sud lorsque possible.

08 GPU SPECIFICATIONS (H100 + H200)

Mix GPU Harch Intelligence

Harch Intelligence opère un mix de GPUs NVIDIA dernière génération : 1 350 NVIDIA H100 80GB SXM5 (75% parc) pour le training et inference production, 448 NVIDIA H200 141GB SXM5 (25% parc) pour le training des LLMs les plus exigeants (GPT-4 class). Le mix est réparti stratégiquement : Dakhla 100% H200 (training flagship), Ouarzazate 80% H100 + 20% H200, Benguerir 100% H100, Tanger 100% H100 (inference), Casablanca 100% H100.

NVIDIA H100 80GB SXM5

Paramètre	Valeur	Commentaire
Architecture	Hopper GH100	Successeur Ampere A100
CUDA cores	16 896	Compute général
Tensor cores	528 (4th gen)	Matrix multiply FP16/BF16
Transformer Engine	Oui	FP8 acceleration LLM
GPU memory	80 GB HBM3	3.35 TB/s bandwidth
Memory bandwidth	3.35 TB/s	vs A100 2.0 TB/s
FP64 performance	34 TFLOPS	Scientific compute
FP32 performance	67 TFLOPS	General compute
FP16/BF16 tensor	1 979 TFLOPS	LLM training
FP8 tensor	3 958 TFLOPS	Inference optimization
TDP	700 W	SXM5 socket
Interconnect	NVLink 4 (900 GB/s)	GPU-to-GPU direct
Form factor	SXM5 (HGX baseboard)	4-GPU/8-GPU baseboard
Prix public (référence)	~\$30 000	Harch: prix wholesale

NVIDIA H200 141GB SXM5

Paramètre	Valeur	vs H100
Architecture	Hopper GH100 (memory upgrade)	Même compute die
GPU memory	141 GB HBM3e	+76% memory
Memory bandwidth	4.8 TB/s	+43% bandwidth
FP16/BF16 tensor	1 979 TFLOPS	Identique
FP8 tensor	3 958 TFLOPS	Identique
TDP	700 W	Identique
Interconnect	NVLink 4 (900 GB/s)	Identique
LLM training speedup	+30 à +60%	Modèles >70B
Inference LLM speedup	+40 à +90%	Modèles >30B

Prix public	~\$36 000	+20% prix
Disponibilité Harch	Q4 2027 (Dakhla)	—

Pourquoi le mix H100 + H200

Le mix 75% H100 + 25% H200 optimise le rapport performance/coût selon workload : H100 suffit pour inference et training <70B, H200 nécessaire pour training 70B-400B (memory bottleneck). Le ratio 75/25 reflète la distribution attendue des workloads clients (75% inference + fine-tuning, 25% training large). Le hub Dakhla (500 GPUs H200) est réservé aux clients les plus exigeants — labs AI, startups LLM, entreprises training modèles propriétaires.

Source : NVIDIA H100 Datasheet 2025, NVIDIA H200 Datasheet 2025, MLPerf Training 4.0




Figure : Distribution GPUs NVIDIA par hub — 1 798 GPUs (75% H100 / 25% H200), Dakhla = flagship H200

09 NETWORK FABRIC 400G INFINIBAND

Architecture réseau InfiniBand

Chaque hub Harch Intelligence est équipé d'un fabric 400G InfiniBand HDR/NDR basé sur NVIDIA Quantum-2. Architecture fat-tree non-blocking 2-tiers qui garantit full bisection bandwidth entre tous les GPUs. Le fabric est conçu pour les workloads AI distribués (LLM training sur centaines de GPUs en parallèle) où la latence inter-GPU est critique (microsecondes). Ethernet est utilisé uniquement pour le trafic client (storage access, API, monitoring).

Spécifications fabric

Paramètre	Valeur	Benchmark Ethernet
Technology	NVIDIA Quantum-2 InfiniBand	Ethernet 400G
Port speed	400 Gbps (NDR)	400 Gbps
Switch ports	64 ports NDR par switch	32-64 ports
Topology	Fat-tree 2-tiers non-blocking	Spine-leaf
Latency port-to-port	0.5 µs	2-5 µs Ethernet
Bisection bandwidth	Full non-blocking	Oversubscribed
Routing	Adaptive routing	ECMP
Congestion control	DCQCN + InfiniBand CC	DCQCN
GPU-to-GPU bandwidth	900 GB/s NVLink	50-100 GB/s PCIe
Scale max par hub	8 192 GPUs	4 096 nodes typique
MTU	4 KB InfiniBand	9 KB jumbo frames
Reliability	CRC + FEC	CRC

Interconnexion inter-hubs

Les 5 hubs sont interconnectés via backbone national 400G Ethernet (dark fiber dédiée). Topologie full-mesh : chaque hub est connecté directement aux 4 autres via 2× 400G links (total 8× 400G par hub, 4 Tb/s bande passante inter-hub). Cette interconnexion permet (i) le carbon-aware scheduling (routing jobs vers hub le moins carboné temps réel), (ii) la résilience (failover automatique entre hubs), (iii) le distributed training inter-hub pour jobs très larges (rare, réservé à clients spécifiques).

Hub	InfiniBand intra-hub	Ethernet inter-hub	Total bandwidth
Dakhla	500 GPUs × 900 GB/s NVLink	8 × 400G (3.2 Tb/s)	—
Ouarzazate	450 GPUs × 900 GB/s NVLink	8 × 400G (3.2 Tb/s)	—
Benguerir	350 GPUs × 900 GB/s NVLink	8 × 400G (3.2 Tb/s)	—
Tanger	200 GPUs × 900 GB/s NVLink	8 × 400G (3.2 Tb/s)	—
Casablanca	298 GPUs × 900 GB/s NVLink	8 × 400G (3.2 Tb/s)	—
Total inter-hub	—	40 × 400G (16 Tb/s)	—

InfiniBand vs Ethernet — pourquoi le choix IB

InfiniBand est choisi vs Ethernet pour 3 raisons : (i) latence 0.5 μ s (vs 2-5 μ s Ethernet) — critique pour LLM training distribué, (ii) adaptive routing qui évite les congestions vs ECMP statique Ethernet, (iii) native GPU-to-GPU communication via NVLink over InfiniBand (95% efficiency vs 60-70% Ethernet). Cette choix est aligné avec les best practices NVIDIA AI factories (tous les grands clusters AI mondiaux utilisent IB).

Source : NVIDIA Quantum-2 Datasheet 2025, MLPerf Network Benchmark 2024, IBTA Specifications

10 STORAGE TIERS

Architecture 3-tiers

Harch Intelligence déploie une architecture storage 3-tiers optimisée pour les workloads AI : (i) NVMe direct-attach hot tier (5 PB) pour checkpoints LLM et datasets actifs, (ii) SSD cluster warm tier (7 PB) pour datasets modérément actifs et modèles entraînés, (iii) object storage cold tier (3 PB) pour archives, datasets bruts, et backups. Total 15 PB, accessible via protocols NFS, S3, et POSIX natif pour training frameworks.

Spécifications par tier

Tier	Technologie	Capacité	Bandwidth	Latency	Prix (\$/TB/an)
Hot NVMe	Solidigm D7-P5520 + Samsung PM9A3	5 PB	7 GB/s/node	<100 µs	\$180
Warm SSD	Micron 7450 + WD Ultrastar DC SN655	7 PB	3 GB/s/node	<1 ms	\$95
Cold object	Cloudflare R2 + MinIO on-prem	3 PB	500 MB/s/node	<10 ms	\$25
Backup	LTO-9 tape + AWS Glacier	2 PB	—	minutes-heures	\$12
Total	—	17 PB	—	—	—
Total	—	17 PB	—	—	—

Performance par workload

Workload	Tier utilisé	I/O pattern	Throughput	Commentaire
LLM training checkpoint	Hot NVMe	Sequential write 100GB	7 GB/s	Checkpoint 70B model
Dataset loading training	Hot NVMe + Warm SSD	Sequential read	5 GB/s	Streaming dataset
Model artifacts storage	Warm SSD	Random read/write	500 MB/s	Between training runs
Inference model load	Warm SSD	Sequential read 10GB	3 GB/s	Cold start
Long-term dataset archive	Cold object	Sequential read	500 MB/s	Lazy load
Backup & DR	Backup (tape + cloud)	Sequential write	100 MB/s	Nightly backups

Storage hot tier — bottleneck LLM training

Le hot tier NVMe est dimensionné pour éliminer le bottleneck I/O lors du LLM training. Un checkpoint d'un modèle 70B fait 350 GB (BF16 weights + optimizer states). Sur NVMe à 7 GB/s, checkpoint takes 50s — vs 5+ minutes sur SSD SATA. Cette différence est critique : un training run fait 100+ checkpoints, donc 7+ heures économisées par run sur NVMe. Le surcoût NVMe (\$180/TB vs \$95/TB SSD) est largement compensé par le gain compute.

Source : Solidigm D7 Datasheet 2025, Micron 7450 Datasheet 2025, Cloudflare R2 Pricing 2026

11 POWER INFRASTRUCTURE

Architecture power

Chaque hub Harch Intelligence dispose d'une infrastructure power redondée 2N+1 conçue pour Tier IV+ : (i) 2 feeds indépendants depuis Harch Energy (lignes privées 225 kV), (ii) UPS batterie pour bridge les transitions (5-10 min autonomy), (iii) générateurs diesel backup (24h fuel on-site) pour cas extrêmes, (iv) PDU redondants par rack (A/B feeds). Disponibilité garantie 99.995% (<26 min downtime/an).

Spécifications power par hub

Hub	Power total	Redundancy	UPS autonomy	Gensets	PUE mesuré
Dakhla	120 MW	2N+1	10 min	20 MW (2×)	1.12 (cible)
Ouarzazate	110 MW	2N+1	10 min	18 MW (2×)	1.14
Benguerir	85 MW	2N+1	8 min	15 MW (2×)	1.15
Tanger	50 MW	2N+1	8 min	8 MW (2×)	1.16
Casablanca	70 MW	2N+1	10 min	12 MW (2×)	1.18
Total réseau	435 MW	—	—	73 MW	1.15 moy.
Total	435 MW	—	—	73 MW	1.15 moy.

Densité power par rack

Hub	Densité moyenne (kW/rack)	Densité max (kW/rack)	GPU type	Cooling
Dakhla	60 kW/rack	100 kW/rack	H200 SXM5	Liquid direct-to-chip
Ouarzazate	55 kW/rack	80 kW/rack	H100 SXM5	Air + rear door HX
Benguerir	50 kW/rack	70 kW/rack	H100 SXM5	Air + adiabatic
Tanger	50 kW/rack	70 kW/rack	H100 SXM5	Air (free-cooling)
Casablanca	40 kW/rack	60 kW/rack	H100 mixte	Air + adiabatic
Bench industrial	8-15 kW/rack	20-30 kW/rack	—	Air standard

Densité AI-native — 4-7x supérieure aux DC legacy

Les hubs Harch Intelligence sont conçus nativement AI avec des densités 40-100 kW/rack — vs 8-15 kW/rack pour les data centers legacy (2010-2020). Cette densité supérieure (4-7x) permet : (i) réduire l'empreinte foncière (-70%), (ii) minimiser la longueur câbles (économie cuivre), (iii) améliorer NVLink topology (latence inter-GPU plus courte). Densité AI-native est un avantage structurel vs opérateurs legacy qui doivent retrofit (limité à 30 kW/rack sans reconstruction complète).

Source : Uptime Institute Tier Standard 2025, ASHRAE Data Center Power 2024

12 COOLING SYSTEMS

Stratégie cooling

Harch Intelligence déploie 4 technologies cooling adaptées à chaque hub selon densité power et climat local : (i) liquid cooling direct-to-chip (Dakhla, densité 100 kW/rack), (ii) rear door heat exchangers (Ouarzazate, 80 kW/rack), (iii) adiabatic cooling (Benguerir, Casablanca, climat semi-aride), (iv) free cooling air (Tanger, climat coastal). Cette diversité optimise le PUE global à 1.15 moyen — vs 1.20-1.25 industrie.

Technologies cooling par hub

Hub	Technology	Water usage (L/kWh)	PUE contribution	CAPEX (\$/kW)
Dakhla	Liquid direct-to-chip (CDU)	0.5	-0.10 vs air	\$280
Ouarzazate	Rear door HX (VX system)	1.2	-0.06 vs air	\$180
Benguerir	Adiabatic + dry cooler	0.8	-0.05 vs air	\$120
Tanger	Free cooling air + DX backup	0.3	-0.04 vs air	\$90
Casablanca	Adiabatic + dry cooler	1.0	-0.02 vs air	\$110
Moyenne réseau	Mix	0.8 moy.	PUE 1.15	\$155 moy.
Moyenne	—	0.8 moy.	1.15	\$155 moy.

Liquid cooling Dakhla — détail

Le hub Dakhla utilise du liquid cooling direct-to-chip (CDU - Coolant Distribution Unit) pour supporter la densité 100 kW/rack nécessaire aux GPUs H200. Le liquide (eau + glycol à 25°C) circule via cold plates sur GPU et CPU, captant 70-80% de la chaleur directement. Les 20-30% restants sont gérés par rear door HX. Cette approche permet PUE 1.12 (vs 1.25 en air cooling à densité équivalente). Investissement \$280/kW (vs \$120/kW air) compensé par économies énergie 5-8 ans.

Water usage — criticité ESG

Le water usage cooling est un enjeu ESG majeur pour les data centers AI. Harch Intelligence optimise via : (i) liquid cooling à Dakhla (0.5 L/kWh vs 1.8 L/kWh evaporative cooling), (ii) free cooling air à Tanger (0.3 L/kWh — coastal cool climate), (iii) recyclage eau 85% (vs <50% industrie), (iv) alimentation par eau dessalée Harch Water (pas de pression sur eau douce locale). Water usage moyen 0.8 L/kWh vs 1.5-2.5 L/kWh industrie (Google 1.8, Microsoft 2.2).

Source : ASHRAE Liquid Cooling Guidelines 2024, NVIDIA Liquid Cooling Reference Architecture 2025

13 NETWORK CONNECTIVITY (SUBMARINE CABLES)

Connexion internationale

Le Maroc dispose de 14 câbles sous-marins en opération ou en construction reliant l'Afrique à l'Europe et au Moyen-Orient. Harch Intelligence utilise 6 câbles principaux pour la connectivité internationale : 2Africa, Metiss, AWAS, EECL, MAROC Telecom Cable, et Atlas Offshore. Cette diversité garantit résilience (failover automatique) et latence optimale (<8ms vers Marseille via MarTel). Bande passante totale commandée : 12 Tb/s.

Câbles sous-marins utilisés

Cable	Destination	Capacité	Latence vers Marseille	Statut	Harch Intelligence
2Africa	Marseille + Europe	48 Tb/s	7 ms	Opérationnel 2024	44 Tb/s
Metiss	Marseille + Réunion	13 Tb/s	8 ms	Opérationnel 2022	22 Tb/s
AWAS (African West Asia System)	Marseille + Asie	18 Tb/s	9 ms	Opérationnel 2023	1 Tb/s
EECL (Europe India Gateway)	Marseille + Inde	3.84 Tb/s	10 ms	Opérationnel 2020	500 Gb/s
MAROC Telecom Cable	Marseille + Maroc	2.5 Tb/s	8 ms	Opérationnel 2018	1 Tb/s
Atlas Offshore	Marseille + Maroc	5 Tb/s	7 ms	Opérationnel 2024	2 Tb/s
Total BW internationale		—	<8 ms moy.	—	10.5 Tb/s
Total	—	—	<8ms	—	10.5 Tb/s

Peering points et IXPs

IXP / Peering	Localisation	Latence depuis Tanger	Type	Peering
Gernetix (FR)	Marseille	8 ms	Public IXP	Public + private
France-IX	Paris + Marseille	12 ms	Public IXP	Public
DE-CIX Frankfurt	Francfort	15 ms	Public IXP	Public
LINX London	Londres	18 ms	Public IXP	Public
AMS-IX Amsterdam	Amsterdam	17 ms	Public IXP	Public
Espanix Madrid	Madrid	11 ms	Public IXP	Public
AMS-IX Marseille	Marseille	8 ms	Public IXP	Public
NAPAfrica Johannesburg	Johannesburg	85 ms	Public IXP	Public

Diversité câbles — résilience 99.99%

L'utilisation de 6 câbles sous-marins indépendants (vers 4 destinations EU différentes) garantit la résilience connectivity : même si 2 câbles tombent en panne simultanément (rare), 4 câbles restent disponibles pour absorber le trafic. SLA Harch Intelligence : 99.99% network availability (vs 99.95% industrie). Cette diversité, combinée aux 8 peering points EU, fait du Maroc le hub de connectivité Afrique-Europe le plus robuste.

Source : Submarine Cable Map 2025, PeeringDB 2025, TeleGeography Global Bandwidth 2024

14 LATENCY TO EUROPE

Mesures latence réelles

Harch Intelligence mesure en continu la latence vers les principaux destinations EU via le backbone réseau. Les mesures ci-dessous (moyennes Q1 2026, 1 000 pings/h) confirment que le hub Tanger offre une latence indissociable d'un data center EU pour la majorité des applications interactives (chatbots, RAG, voice AI, code completion).

Latence hub Tanger vers destinations EU

Destination	Latence min (ms)	Latence moyenne (ms)	Latence P95 (ms)	Jitter (ms)	Packet loss
Marseille (Gernetix IXP)	6	8	11	0.5	0.01%
Paris (France-IX)	10	12	15	0.8	0.02%
Francfort (DE-CIX)	13	15	19	1.0	0.02%
Londres (LINX)	16	18	22	1.2	0.03%
Amsterdam (AMS-IX)	15	17	21	1.0	0.02%
Madrid (Espanix)	9	11	14	0.7	0.01%
Milan (MIX)	19	21	25	1.4	0.03%
Stockholm (Netnod)	32	35	42	2.0	0.04%
Dublin (INEX)	24	27	32	1.8	0.03%
Warsaw (PLIX)	28	31	37	2.1	0.04%

Latence depuis autres hubs Harch Intelligence

Hub Harch	Latence Marseille	Latence Paris	Latence Francfort	Latence Londres	Commentaire
Tanger	8 ms	12 ms	15 ms	18 ms	Gateway Europe
Casablanca	14 ms	18 ms	21 ms	24 ms	+6ms vs Tanger
Benguerir	17 ms	21 ms	24 ms	27 ms	+9ms vs Tanger
Ouarzazate	22 ms	26 ms	29 ms	32 ms	+14ms vs Tanger
Dakhla	24 ms	28 ms	31 ms	34 ms	+16ms vs Tanger

Latence 8ms — expérience utilisateur EU

Pour la majorité des applications interactives (chatbots, RAG, voice AI, code completion), une latence inférieure à 20ms est indissociable d'un data center local pour l'utilisateur final. Le hub Tanger (8ms vers Marseille, 12ms Paris, 15ms Francfort) permet une expérience utilisateur EU parfaite. Workloads compatibles : chatbots customer service, RAG enterprise, voice AI real-time, code completion (Copilot-class), API LLM production. Seuls les workloads ultra-low-latency (trading HFT <5ms) restent sur data center EU local.

Source : Harch Intelligence Network Monitoring Q1 2026, TeleGeography Latency 2025

15 SECURITY & COMPLIANCE (TIER IV+)

Tier IV+ Uptime Institute

Tous les hubs Harch Intelligence sont certifiés Tier IV+ par l'Uptime Institute — le plus haut niveau de disponibilité (99.995%, soit <26 min downtime/an). Cette certification requiert : (i) infrastructure 2N+1 (double everything + 1 backup), (ii) compartments■■■ isolation (fire, flood), (iii) continuous monitoring, (iv) commissioning tests. Tous les hubs ont été certifiés entre Q4 2024 et Q4 2025.

Certifications sécurité & compliance

Certification	Statut	Périmètre	Validité	Auditeur
Tier IV Design	Certifié	5 hubs	Permanent	Uptime Institute
Tier IV Constructed Facility	Certifié	4 hubs (Dakhla Q4 2027)	Permanent	Uptime Institute
ISO 27001 (Info Security)	In progress	5 hubs + HarchOS	Q1 2027	Bureau Veritas
ISO 27017 (Cloud Security)	Planned	5 hubs	Q3 2027	Bureau Veritas
ISO 27018 (PII Cloud)	Planned	5 hubs	Q3 2027	Bureau Veritas
ISO 22301 (Business Continuity)	Planned	5 hubs	Q4 2027	Bureau Veritas
SOC 2 Type II	In progress	Harch Intelligence complète	Q2 2027	Deloitte
PCI DSS Level 1	Planned (clients financiers)	5 hubs	Q4 2027	QSA Certified
HIPAA (clients healthcare)	Planned	Specific environments	Q4 2027	Compliance Officer
FedRAMP (clients US gov)	Not pursued	—	—	—

Compliance RGPD + CNDP Maroc

Harch Intelligence opère sous double juridiction : CNDP Maroc (Commission Nationale de Contrôle de la Protection des Données à Caractère Personnel) et RGPD UE (via adequacy decision et standard contractual clauses). Le Maroc a obtenu l'adequacy status partiel auprès de la Commission européenne en 2025, permettant le transfert libre de données personnelles UE → Maroc. Harch Intelligence applique les 2 frameworks en parallèle pour garantir compliance aux clients EU.

Framework	Statut	Exigences clés	Périmètre
CNDP Maroc (Loi 09-08)	Compliant	Declaration préalable, consentement, droits clients	Tous hubs
RGPD UE	Compliant	DPO, registre traitements, droit à l'oubli, portabilité	Clients UE
Adequacy decision UE	Partiel 2025 (full 2026)	Transferts UE → Maroc libres	Tous hubs
SCC (Standard Contractual Clauses)	Guaranteed	Transfer data UE → Maroc	Clients UE
Data residency Maroc	Guaranteed	Données Maroc + UE uniquement	5 hubs
Encryptage at-rest	AES-256	Toutes données storage	Tous hubs
Encryptage in-transit	TLS 1.3	Toutes communications	Tous hubs
Key management	HashiCorp Vault	Customer-managed keys option	Tous hubs

Sovereign AI — jurisdiction Maroc + UE

Harch Intelligence est le seul opérateur AI hyperscale offrant une juridiction souveraine Maroc + UE. Pour les clients EU soucieux de data residency (governments, healthcare, finance), cela signifie : (i) données jamais stockées aux USA (CLOUD Act non applicable), (ii) cadre RGPD-compliant via adequacy 2025, (iii) double juridiction Maroc (CNDP) + UE (RGPD). Cette caractéristique est un avantage unique vs hyperscalers US (AWS, Google, Azure) qui sont soumis au CLOUD Act américain.

Source : Uptime Institute Tier Standard 2025, CNDP Maroc Rapport 2025, European Commission Adequacy Decision 2025

16 CARBON-AWARE SCHEDULING

HarchOS Carbon Scheduler

HarchOS intègre un carbon-aware scheduler qui route dynamiquement les workloads AI vers le hub avec le carbon intensity le plus bas à l'instant t. Le scheduler reçoit télémétrie temps réel de Harch Energy (production solaire/éolien), prédit la production des 4 prochaines heures via ML, et ajuste les workloads toutes les 5 min. Résultat : 89% moins de carbone que la moyenne industrie sans surcoût, sans dégradation de SLA.

Algorithme de routing

- 1. Télémétrie temps réel** — Le scheduler reçoit toutes les 5 min la production renouvelable de chaque parc Harch Energy (solaire, éolien, stockage), le carbon intensity du grid ONEE local, et la charge GPU de chaque hub.
- 2. Prédiction ML** — Un modèle LSTM (développé Harch Technology) prédit la production solaire et éolienne des 4 prochaines heures avec précision 92% (vs 75% pour les prévisions MASEN).
- 3. Scoring carbon** — Chaque hub reçoit un score carbon (gCO2/kWh prédit) toutes les 5 min, basé sur le mix énergétique instantané et prévu.
- 4. Routing workloads** — Pour chaque nouveau job AI, le scheduler route vers le hub avec le meilleur score carbon parmi ceux ayant capacité disponible et respectant SLA client.
- 5. Migration workloads** — Pour les jobs longs (>4h), le scheduler peut migrer le job vers un autre hub si le carbon intensity devient plus favorable (rare, réservé aux jobs flexibles).
- 6. Carbon reporting** — Chaque job reçoit un carbon report détaillé (gCO2 total, mix énergétique utilisé, comparaison vs AWS/Google/Azure) pour reporting ESG client.

Impact mesuré

Métrique	Sans scheduler	Avec scheduler HarchOS	Gain
Carbon intensity moyen (gCO2/kWh)	95 (grid ONEE)	47	-50%
Renewable fraction	45%	81.5%	+36 pts
Workloads routed (jobs/jour)	—	850	—
SLA respect	99.5%	99.95%	+0.45 pts
Latence supplémentaire moyenne	—	<2 ms	Négligeable
Carbon offset annuel	1.6M tCO2	3.2M tCO2	+100%

Carbon-aware — moat technologique

Le carbon-aware scheduler HarchOS est un moat technologique difficile à répliquer : (i) nécessite intégration profonde avec Harch Energy (télémétrie temps réel), (ii) modèles ML propriétaires entraînés sur 2 ans de données, (iii) orchestration Kubernetes + Slurm custom. Concurrents nécessitent 3-5 ans pour répliquer. Cette capacité est un argument commercial majeur vs hyperscalers US qui annoncent du carbon-aware mais n'ont pas la production renouvelable dédiée.

Source : HarchOS Internal Documentation 2026, Google Carbon-Intelligent Computing 2024, Microsoft Carbon Aware SDK

17 PUE BENCHMARKING

PUE mesuré vs benchmarks

Le PUE (Power Usage Effectiveness) est le ratio puissance totale data center / puissance IT utile. Plus il est proche de 1.0, meilleur est l'efficacité. Harch Intelligence atteint un PUE moyen de 1.15 — vs 1.20-1.25 moyenne industrie et 1.15-1.20 hyperscalers leaders. Cette performance résulte de : (i) cooling optimisé (liquid, free cooling, adiabatic), (ii) climat Maroc favorable (sud sec, coastal Tanger), (iii) AI-native design (densité optimisée, minimal CRAC).

PUE par hub

Hub	PUE mesuré 2025	PUE cible 2030	Technology cooling	Benchmark industrie
Dakhla	1.12 (cible)	1.10	Liquid direct-to-chip	1.18 best-in-class
Ouarzazate	1.14	1.12	Air + rear door HX	1.20 industrie
Benguerir	1.15	1.13	Adiabatic + dry cooler	1.22 industrie
Tanger	1.16	1.14	Free cooling air	1.18 free-cooling
Casablanca	1.18	1.16	Adiabatic + dry cooler	1.25 industrie
Moyenne réseau	1.15	1.13	Mix	1.22 industrie
Moyenne	1.15	1.13	—	1.22 industrie

Benchmark vs hyperscalers

Opérateur	PUE moyen	Sites AI-native	Commentaire
Harch Intelligence	1.15	5/5 hubs	AI-native, all liquid-ready
Google Cloud	1.10	Some (Stadia DCs)	Industry leader mais opaque
Microsoft Azure	1.18	Some	Mix legacy + new
AWS	1.20	Some (P5 instances)	Mix legacy 1.25 + new 1.15
Meta/Facebook	1.10	Most	Free-cooling optimized
Equinix	1.35	Some (xScale)	Colocation legacy
Digital Realty	1.40	Some	Colocation legacy
Industrie moyenne (Uptime)	1.25	—	Legacy average

PUE 1.15 — top 5% industrie

Le PUE 1.15 d'Harch Intelligence place le réseau dans le top 5% mondial des opérateurs data centers AI — aux côtés de Google (1.10) et Meta (1.10). Cette performance est rendue possible par : (i) sites AI-native (pas retrofit legacy), (ii) cooling optimisé par climato local, (iii) densité power élevée (40-100 kW/rack vs 8-15 industrie), (iv) instrumentation fine HarchOS. L'écart de 0.05-0.10 PUE vs hyperscalers se traduit en économies OPEX \$5-10M/an réseau complet.

Source : Uptime Institute Data Center Industry Survey 2024, Google Environmental Report 2024, Microsoft Sustainability Report 2024

PUE benchmark Harch Intelligence vs hyperscalers — top 5% mondial




Figure : PUE benchmark Harch Intelligence vs hyperscalers — 1.15 (top 5% mondial) vs 1.55 industrie moyenne

18 CARBON INTENSITY VS HYPERSCALERS

Carbon intensity par hub

Le carbon intensity (gCO2/kWh) mesure les émissions carbone associées à chaque kWh consommé. Harch Intelligence atteint un carbon intensity moyen de 47 gCO2/kWh — vs 316 gCO2/kWh AWS eu-west-1, 178 Google Cloud, 334 Azure West EU. Soit un avantage de 85-86% vs hyperscalers. Le hub Dakhla (18 gCO2/kWh) est l'un des data centers AI les plus propres au monde.

Comparaison détaillée

Opérateur / Hub	Region	Carbon intensity (gCO2/kWh)	Renouvelable %	Écart vs Harch
Harch Dakhla	Dakhla Maroc	18	97.2%	Référence
Harch Ouarzazate	Ouarzazate Maroc	18	97.2%	0%
Harch Benguerir	Benguerir Maroc	55	88.5%	+206%
Harch Tanger	Tanger Maroc	95	82.1%	+428%
Harch Casablanca	Casablanca Maroc	210	45%	+1067%
Harch moy. réseau	—	47	81.5%	Référence
Google Finland	Hamina	14	100% hydro+wind	-26% (meilleur)
Google Iowa	Council Bluffs	470	32%	+900%
AWS eu-west-1	Ireland	316	42%	+572%
AWS us-east-1	Virginia	380	28%	+708%
Azure West EU	Netherlands	334	38%	+611%
Azure East US	Virginia	410	30%	+772%
GCP europe-west1	Belgium	178	56%	+279%
Oracle Cloud Frankfurt	Germany	308	40%	+556%
Industrie moyenne	—	450	<30%	+858%

Carbon advantage -89% vs industrie

Harch Intelligence offre un carbon advantage de 89% vs la moyenne industrie (47 gCO2/kWh vs 450). Cet avantage est structurel : (i) 100% énergie renouvelable dédiée Harch Energy (pas de PPA sleeve ou RECs comme hyperscalers), (ii) co-location parcs renouvelables + data centers (pas de pertes grid), (iii) carbon-aware scheduling HarchOS qui route vers hub le plus propre temps réel. Seul Google Hamina (Finland, hydro+wind) surpasse Harch Dakhla — mais avec capacity limitée.

Source : AWS Sustainability Report 2024, Google Environmental Report 2024, Microsoft Sustainability Report 2024, IEA Grid Carbon Intensity 2025




Figure : Carbon intensity par hub vs hyperscalers — Harch Dakhla/Ouarzazate 18 gCO2/kWh (-94% vs AWS eu-west-1)

19 AI FRAMEWORKS SUPPORT

Frameworks supportés nativement

Harch Intelligence supporte nativement tous les frameworks AI majeurs via intégration profonde CUDA/cuDNN/NCCL optimisée NVIDIA. Clients peuvent déployer sans modification leur code PyTorch, TensorFlow, JAX, ou frameworks custom. Le support inclut également les frameworks distributed (DeepSpeed, Megatron LM, FSDP) et inference (vLLM, TGI, Triton).

Training frameworks

Framework	Version	Support	Optimisations	Workload type
PyTorch	2.4+	Native	CUDA 12.4, cuDNN 9, NCCL 2.20	Training LLM/diffusion
TensorFlow	2.16+	Native	CUDA 12.4, XLA	Training + production
JAX	0.4.25+	Native	TPU-agnostic, pjit	Research + training
DeepSpeed	0.14+	Optimized	ZeRO-3, NVMe offload	LLM training distribué
Megatron-LM	5.0+	Optimized	TP/PP/DP	Training 100B+ params
FSDP (PyTorch)	2.4+	Native	Full sharded	Training 70B+ params
HuggingFace Accelerate	0.30+	Native	Multi-GPU + multi-node	Fine-tuning
Ray + Ray Train	2.20+	Native	Distributed training	Hyperparameter tuning

Inference frameworks

Framework	Version	Support	Latence optimal	Workload type
vLLM	0.5+	Optimized	<50ms/token	LLM inference production
TGI (Text Generation Inference)		Optimized	<60ms/token	LLM serving
NVIDIA Triton	24.10+	Native	<30ms/token	Multi-model serving
TorchServe	0.10+	Native	<80ms/token	PyTorch models
TensorRT-LLM	0.10+	Optimized	<40ms/token	LLM inference optimized
SGLang	0.3+	Native	<60ms/token	LLM with structured output
Ollama	0.3+	Native	<100ms/token	Dev + small models
llama.cpp	b3000+	Native	<100ms/token	Quantized inference

MLOps & orchestration

Tool	Support	Intégration HarchOS	Usage
Kubeflow	Native	Pipelines intégrés	ML pipeline orchestration
MLflow	Native	Tracking server dédié	Experiment tracking
Weights & Biases	Native	Integration API	Experiment tracking
DVC	Native	Storage backend S3-compatible	Data versioning
Feast	Native	Online/offline store	Feature store

Airflow	Native	DAG orchestration	Workflow scheduling
Prefect	Native	Flow orchestration	Workflow scheduling
Determined AI	Native	Distributed training	Hyperparameter tuning

Stack AI complet — zero friction

Harch Intelligence fournit une stack AI complète pre-installed sur tous les hubs : PyTorch, TensorFlow, JAX, DeepSpeed, Megatron-LM, vLLM, Triton, MLflow, W&B, Kubeflow. Les clients peuvent déployer leur code en <5 min via Docker ou Kubernetes manifest, sans installation ni configuration. Cette approche 'zero friction' élimine les frictions typiques onboarding hyperscalers (1-2 jours setup), et permet aux clients de se concentrer sur leur code ML plutôt que sur l'infrastructure.

Source : NVIDIA NGC Catalog 2025, PyTorch Compatibility 2025, vLLM Releases 2025

20 PRICING (GPU-HOUR)

Modèles de tarification

Harch Intelligence propose 3 modèles de tarification GPU-hour : (i) Reserved (capacity garantie 24/7, commit 1-3 ans, prix le plus bas), (ii) Spot (capacity best-effort, peut être preempted avec notice 2 min, prix 60% inférieur), (iii) Dedicated (GPU dédié non partagé, prix premium). Tous les prix sont en \$/GPU-h, facturés à la minute, sans engagement minimum (sauf Reserved).

Prix GPU par modèle

GPU type	Reserved 1y	Reserved 3y	Spot	Dedicated	AWS eu-west-1 (réf)
NVIDIA H100 80GB	\$1.80	\$1.65	\$0.95	\$2.40	\$3.40 (p5.48xlarge)
NVIDIA H200 141GB	\$2.20	\$2.05	\$1.20	\$2.80	N/A (rare)
NVIDIA A100 80GB (legacy)	\$1.20	\$1.10	\$0.65	\$1.60	\$3.10 (p4d.24xlarge)
NVIDIA L40S 48GB	\$0.85	\$0.75	\$0.45	\$1.15	\$1.95 (g6.48xlarge)
NVIDIA A10 24GB	\$0.45	\$0.40	\$0.25	\$0.60	\$0.85 (g5.12xlarge)

Bundles et discounts volume

Bundle	Volume GPU-h/mois	Discount additionnel	Engagement	Commentaire
Startup AI	>5 000 GPU-h	-10%	12 mois	Startups <50 employés
Enterprise Standard	>50 000 GPU-h	-15%	24 mois	Entreprises >500 employés
Enterprise Plus	>200 000 GPU-h	-20%	36 mois	Top 100 AI labs
Academic Research	>10 000 GPU-h	-30%	12 mois	Universités + labs publics
Government / Strategic	Custom	-25%	36 mois	Gouvernements marocains + UE
Harch Corp internal	—	Transfer price	—	Subsidiaries Harch Corp

Comparaison prix vs hyperscalers

Opérateur	H100 reserved 1y (\$/h)	H100 spot (\$/h)	Écart vs Harch	CO2 (gCO2/kWh)
Harch Intelligence	1.80	0.95	Référence	47
AWS eu-west-1 (Ireland)	3.40	1.50	+89%	316
AWS us-east-1 (Virginia)	3.10	1.30	+72%	380
Google Cloud A3 (Europe)	3.30	1.45	+83%	178
Azure NDv5 (Europe)	3.45	1.55	+92%	334
Oracle Cloud (Frankfurt)	3.80	1.70	+111%	308
Lambda Labs (US)	1.99	1.10	+11%	470
CoreWeave (US)	2.20	1.20	+22%	410

Avantage prix 30-40% + CO2 -89%

Harch Intelligence offre un avantage prix de 30-40% vs hyperscalers européens (AWS, Google, Azure) sur GPU H100 reserved — tout en réduisant le carbon footprint de 85-89%. Cette combinaison prix + CO2 est unique sur le marché. Lambda Labs et CoreWeave (US GPU clouds) offrent des prix comparables mais avec carbon intensity 8-10x supérieure (470 et 410 gCO2/kWh respectivement). Seul Harch Intelligence combine compétitivité prix + leadership CO2.

Source : AWS Pricing Calculator 2026, Google Cloud Pricing 2026, Azure Pricing 2026, Lambda Labs Pricing 2026

21 CUSTOMER ONBOARDING

Processus onboarding

Harch Intelligence propose un parcours d'onboarding client en 4 étapes sur 5-10 jours ouvrés (vs 2-4 semaines chez hyperscalers). Le processus est conçu pour minimiser le time-to-first-GPU et maximiser la valeur client dès le premier workload. Account manager dédié + solutions architect + ML engineer à disposition pendant tout l'onboarding.

Étapes onboarding

- 1. **Jour 1 — Kickoff call (1h)** — Compréhension workloads client, choix modèle tarification (reserved/spot/dedicated), estimation volume GPU-h, identification use cases prioritaires. Account manager + solutions architect dédiés.
- 2. **Jour 2-3 — Provisioning** — Création compte HarchOS, allocation capacity (reserved) ou setup spot queues, configuration IAM + network (VPC dedicated ou shared), déploiement stack ML pré-installée (PyTorch, vLLM, MLflow).
- 3. **Jour 4-5 — Premier workload** — Solutions architect ML assiste client pour déployer premier workload (training ou inference). Validation performance + cost + carbon. Optimisations initiales (batch size, gradient checkpointing, tensor parallelism).
- 4. **Jour 6-10 — Production-ready** — Mise en production workload client avec SLA (reserved) ou best-effort (spot). Setup monitoring + alerting + cost tracking + carbon reporting. Documentation + training équipe client (2 sessions 4h).
- 5. **Jour 11+ — Support continu** — Account manager monthly check-in, solutions architect quarterly review, ML engineer on-demand pour optimisations. Support 24/7 L1, business hours L2/L3.

SLA et support

Niveau support	Disponibilité	Response time	Channels	Prix
L1 Basic	24/7	<4h	Email + portal	Inclus
L2 Standard	24/7	<1h	Email + phone + portal	Inclus reserved
L3 Premium	24/7	<15 min	Phone + Slack + portal	\$5 000/mois
L4 Dedicated TAM	Business hours	<15 min	Slack direct + monthly	\$15 000/mois
ML Engineer on-demand	On-demand	<2h	Slack + video	\$300/h
Solutions Architect	Included onboarding	<4h	Email + video	Inclus 5 sessions/mois

Time-to-first-GPU <10 jours

Le time-to-first-GPU Harch Intelligence est de 5-10 jours ouvrés (vs 2-4 semaines chez hyperscalers). Cette rapidité est rendue possible par : (i) stack ML pré-installée (pas de setup), (ii) account manager + SA + ML engineer dédiés (pas de support ticket), (iii) process onboarding industrialisé (templates, scripts, runbooks). Les clients apprécient particulièrement la rapidité vs AWS/Google/Azure où ils doivent souvent attendre des semaines pour quota GPU H100.

22 ESG & CONTACTS

Indicateurs ESG Harch Intelligence 2030

Indicateur	Valeur 2030	Benchmark industrie	Avantage
Carbon intensity (gCO2/kWh)	47 (moy. réseau)	450	-89%
Renewable fraction	81.5%	<30%	+51 pts
PUE	<1.15	1.20-1.25	Excellent
Water usage (L/kWh)	0.8	1.5-2.5	-50% à -68%
Recyclage e-waste	95%	<50%	+45 pts
Net-zero target	2030	2050	20 ans avance
Emplois directs locaux	90% Maroc	—	Impact économique
Gender diversity (cible)	40% femmes	20% tech	+20 pts
Certifications	ISO 27001, 27017, 27018, SOC 2, Tier IV+		Best practices

Contacts Harch Intelligence

Contact	Rôle	Email	Téléphone
Direction Harch Intelligence	CEO Harch Intelligence	intelligence@harchcorp.com	+212 5 22 00 00 20
Sales Enterprise	Vente GPU compute entreprise	sales@harchcorp.com	+212 5 22 00 00 21
Solutions Architects	Pre-sales + onboarding	solutions@harchcorp.com	+212 5 22 00 00 22
Support L3 Premium	Support 24/7 premium	support@harchcorp.com	+212 5 22 00 00 23
ML Engineering	Optimisation workloads	ml-eng@harchcorp.com	+212 5 22 00 00 24
Investor Relations	Investisseurs Harch Intelligence	ir-intelligence@harchcorp.com	+212 5 22 00 00 25
Security & Compliance	ISO/SOC/PCI/audits	security@harchcorp.com	+212 5 22 00 00 26
Press & Media	Relations presse AI	press-intelligence@harchcorp.com	+212 5 22 00 00 27

Sites data centers

Hub	Adresse	Région	Statut
HQ Casablanca	Casablanca Finance City, Twin Center	Casablanca-Settat	Opérationnel
Hub Casablanca DC	Casablanca Nearshore Park	Casablanca-Settat	Opérationnel
Hub Tanger	Tanger Tech Park	Tanger-Tétouan	Opérationnel
Hub Ouarzazate	Ouarzazate Solar Complex	Drâa-Tafilalet	Opérationnel
Hub Benguerir	Benguerir Green City	Marrakech-Safi	Opérationnel
Hub Dakhla	Dakhla Atlantic Tech Park	Dakhla-Oued Ed-Dahab	Construction

Présence digitale

Site web	harchcorp.com/intelligence
Documentation	docs.harchcorp.com
Status page	status.harchcorp.com
Pricing calculator	harchcorp.com/intelligence/pricing
Real-time carbon	harchcorp.com/intelligence/carbon
LinkedIn	linkedin.com/company/harch-intelligence
Twitter/X	@harchintelligence
GitHub	github.com/HarchCorp/intelligence-examples

Disclaimer

Ce datasheet est publié par Harch Corp S.A. à titre informatif pour les clients entreprise, partenaires techniques, et investisseurs. Les informations présentées sont basées sur des spécifications internes et des sources publiques. Elles ne constituent pas un conseil en investissement ni un engagement contractuel.

Les métriques techniques (PUE, carbon intensity, latence) sont issues de mesures internes et seront auditées par cabinets indépendants (Bureau Veritas, Uptime Institute) à partir de 2026. Les certifications (ISO, SOC 2, Tier IV+) sont en cours d'obtention selon calendrier indiqué. Les prix GPU sont indicatifs et peuvent évoluer; contacter sales@harchcorp.com pour quote personnalisée.

Licence & copyright

© 2026 Harch Corp S.A. Tous droits réservés. Ce datasheet est classifié Confidentiel — Technical Edition. Reproduction interdite sans autorisation écrite préalable. Pour toute demande de redistribution ou utilisation, contacter press-intelligence@harchcorp.com.

Métadonnées publication

URL	harchcorp.com/intelligence
Contact	intelligence@harchcorp.com
Date de publication	Juin 2026
Version	2.0 (refonte complète)
Auteur	Harch Intelligence — Direction Engineering
Validé par	Conseil d'Administration Harch Corp S.A.
Classification	Confidentiel — Technical Edition
Prochaine mise à jour	T4 2026 (post-Dakhla commissioning)

Harch Intelligence publie ses métriques opérationnelles (PUE, carbon intensity temps réel, latence, disponibilité) en open data sur status.harchcorp.com. Ce datasheet est destiné aux clients entreprise et partenaires techniques. Pour accéder aux dossiers research complets (AI, énergie, mining), visitez harchcorp.com/research. Pour toute question technique : solutions@harchcorp.com.