

DOSSIER 00

TECHNICAL - PLATFORM EDITION

Juin 2026 - v2

Harch Platform Sovereign AI Infra Whitepaper 2026

Carbon-aware scheduling
5 GPU hubs - 1,798 accelerators - 81.5% renewable

GPUs

1,798

RENEWABLE

81.5%

CARBON

47 gCO2/kWh

LATENCY

8ms UE

00 TABLE DES MATIERES

N	Section	Page
01	Executive Summary	3
02	The AI Compute Challenge - GPU Scarcity	4
03	The AI Compute Challenge - Carbon Crisis	5
04	The AI Compute Challenge - Sovereignty Gap	6
05	Platform Architecture Overview (4-Layer)	7
06	Five GPU Hubs Deep-Dive	9
07	Carbon-Aware Scheduling (Real-Time)	13
08	Storage Architecture	16
09	Network Fabric (InfiniBand, RoCE)	18
10	Submarine Cable Systems	20
11	Sovereign Security Framework	22
12	AI Platform Services (Training, Fine-tuning, Inference, MLOps, SDK)	24
13	Sustainable Compute Economics (TCO, Pricing)	27
14	Competitive Landscape (AWS, GCP, Azure, OVH, Scaleway)	29
15	Customer Engagement Models	31
16	Roadmap & Future Phases	33
17	Use Cases - Banking	34
18	Use Cases - Healthcare, Gov, Research	36
19	Performance Benchmarks (MLPerf)	38
20	Conclusion	40
21	Sources & References	41
22	Disclaimer	42

Note de lecture

Ce whitepaper presente l'architecture technique complete de la plateforme Harch Platform - couche logicielle sovereign AI qui orchestre 5 hubs GPU (1,798 accelerators), le carbon-aware scheduler real-time, les services AI (training, inference, MLOps), et le framework securite souverain. Le document s'adresse aux CTOs, architectes infrastructure, heads of AI, et DPOs evaluant des alternatives souveraines aux hyperscalers. Version 2.0 - Juin 2026. Classification : Technique - Platform Edition.

01 EXECUTIVE SUMMARY

Harch Platform en bref

Harch Platform est la couche logicielle sovereign AI qui orchestre l'infrastructure compute de Harch Intelligence - 5 hubs GPU au Maroc (Dakhla, Ouarzazate, Benguerir, Tanger, Casablanca) totalisant 1,798 accelerators NVIDIA H100/H200. La plateforme offre une experience developpeur unifiee pour training, fine-tuning, inference, et MLOps - le tout sur une infrastructure 81.5% renouvelable, avec carbon intensity 47 gCO2/kWh et latence 8 ms vers l'Europe.

Concue par Harch Technology (60 ingenieurs), Harch Platform s'appuie sur des technologies open source (Kubernetes, PyTorch, vLLM, Triton, MLflow) avec une couche proprietarielle minime (carbon-aware scheduler, sovereign identity, dashboards consolides). Aucun lock-in API - les workloads sont portables vers/depuis n'importe quel environnement compatible K8s. Cette philosophie open standards est centrale au positionnement souverain.

Metriques cles

Metrique	Valeur	Source / Justification
GPUs orchestres	1,798 (H100 + H200)	5 hubs au Maroc
Renewable fraction	81.5%	Harch Energy dedie
Carbon intensity	47 gCO2/kWh (vs 450 industrie)	89% vs moyenne
PUE consolide	1.14 (vs 1.20+ hyperscalers)	Free cooling 94% heures
Latence vers UE	8 ms (Tanger - Marseille)	Via 14 cables sous-marins
InfiniBand fabric	400 Gbps HDR non-bloquant	NVIDIA Quantum-2
Storage total	15 PB (3 tiers)	Hot NVMe + Warm NVMe-oF + Cold HDD/S3
Carbon-aware scheduler	Real-time, 5-min cadence	HarchOS proprietaire
SLA garanti	99.95% (reserved)	Multi-hub failover
Tarif GPU H100	\$1.80-2.20/h (vs \$3.50 AWS E4)	49% cout on-demand

Positionnement

Une plateforme sovereign AI par construction

Harch Platform est la premiere plateforme AI compute au monde combinaant (i) juridiction souveraine non-US/non-UE (Maroc, CNDP), (ii) energie renouvelable physiquement dediee (pas de RECs), (iii) carbon-aware scheduler real-time base sur telemetry physique (pas sur forecasts), (iv) open standards sans lock-in proprietary. Pour les organisations souverainete-sensibles (gouvernements, finance, sante, defense), c'est la seule alternative credible aux hyperscalers US/UE sur l'ensemble de ces 4 dimensions.

02 THE AI COMPUTE CHALLENGE - GPU SCARCITY

Une demande qui explose

Le marche mondial des accelerateurs AI est passe de \$15B (2022) a \$95B (2024), avec projection \$250B (2027) selon NVIDIA - CAGR 38%. Cette explosion resulte de l'adoption massive des LLMs, modeles multimodaux, et inference at scale. La demande depasse la capacite mondiale de production TSMC (process 4nm/5nm), SK Hynix (HBM3/HBM3e), et TSMC CoWoS packaging - creant une penurie structurelle avec delais 26-52 semaines pour H100 et allocations prioritaires aux top hyperscalers.

Capacite mondiale AI compute 2024-2026

Acteur	GPUs 2024	GPUs 2026	Share 2026	Allocation priority
Meta	350,000	600,000	9.5%	Top tier NVIDIA
Microsoft	300,000	550,000	8.7%	Top tier NVIDIA
Google	250,000	500,000	7.9%	Top tier NVIDIA
Amazon AWS	200,000	450,000	7.1%	Top tier NVIDIA
Oracle	100,000	250,000	4.0%	Tier 2
Tesla	85,000	200,000	3.2%	Tier 2
China Big Tech	180,000	400,000	6.3%	Sanctions restricted
xAI / Bytedance / others	150,000	400,000	6.3%	Tier 2
Harch Intelligence	1,798	1,798	0.03%	Contract \$340M NVIDIA
Total mondial	1,617,000	3,350,000	100%	—
Total	1.62M	3.35M	100%	—

Harch Intelligence : \$340M contrat-cadre NVIDIA

Harch Intelligence a secu risse un contrat-cadre \$340M avec NVIDIA (signe T2 2024) garantissant livraison de 1,798 GPUs H100/H200 selon calendrier fixe 2024-2028. Ce contrat permet d'echapper aux allocations prioritaires hyperscalers et d'offrir une visibilite de capacite aux clients. Sans ce contrat, les delais H100 pour un provider emergent seraient 18-24 mois au lieu de 0-3 mois.

03 THE AI COMPUTE CHALLENGE - CARBON CRISIS

AI compute : une crise carbone emergente

L'IEA estime que le data center AI compute mondial representait 35 TWh (2022), 110 TWh (2024), et atteindra 460 TWh (2026) - plus que la consommation electrique annuelle de la France. A un carbon intensity moyen de 450 gCO2/kWh, cela represente 207 millions de tonnes CO2/an en 2026 - soit 0.5% des emissions mondiales et 3x les emissions du Maroc. Cette explosion force les entreprises a chercher des providers AI compute vertueux.

Pression reglementaire

L'EU Corporate Sustainability Reporting Directive (CSRD, effective 2024) impose le reporting Scope 1+2+3 pour 50,000+ entreprises europeennes, incluant emissions AI cloud. Le Science Based Targets initiative (SBTi) exige des reductions absolues (pas d'offsets). Les investisseurs europeens penalisent les entreprises sans plan decarbonise credible. Les frameworks TCFD et GRI imposent une transparence radicale sur les emissions.

Carbon intensity par provider (gCO2/kWh)

Provider	Region	Carbon intensity	Renewable %	vs Harch
Harch Intelligence	Maroc (5 hubs moy.)	47	81.5%	Reference
Google Cloud	europe-north1 (Finland)	65	90%	+38%
OVHcloud	Gravelines (France)	58	78%	+23%
Scaleway	Paris (France)	62	72%	+32%
Google Cloud	europe-west1 (Belgique)	178	56%	+279%
AWS	eu-west-1 (Ireland)	316	42%	+572%
Azure	West Europe (Netherlands)	334	38%	+611%
AWS	us-east-1 (Virginia)	392	35%	+734%
Azure	East US (Virginia)	441	29%	+838%
Alibaba Cloud	Hangzhou	528	20%	+1023%
Tencent Cloud	Beijing	612	15%	+1202%
Average industry	—	450	30%	+857%

Harch Platform : 89% moins de carbone que la moyenne industrie

Le carbon intensity consolide de Harch Platform est de 47 gCO2/kWh, contre 450 gCO2/kWh en moyenne industrie. Soit -89%. Cet avantage resulte du mix energetique Harch Energy (81.5% renouvelable physiquement dedie, pas de RECs), du PUE excellent (1.14), et du carbon-aware scheduler real-time qui route dynamiquement les workloads vers les hubs les plus propres a chaque instant.

04 THE AI COMPUTE CHALLENGE - SOVEREIGNTY GAP

Le risque de dependance cloud US

L'AI compute mondial est domine par 4 hyperscalers US (AWS, Microsoft Azure, Google Cloud, Oracle) captant 78% du marche AI cloud 2024 (Synergy Research). Pour les organisations non-US - gouvernements europeens, finance, defense, sante - cette dependance represente un risque strategique : exposition au CLOUD Act US (acces FBI aux donnees), sanctions US secondary, volatilite politique (tarifs Trump 2025), risque d'interruption de service. La souverainete numerique devient une priorite geopolitique.

Initiatives souverainete AI par region

Region	Initiative	Budget	GPUs cible	Statut
UE	AI Factories	EUR 5B	100,000+	Lancement 2024
UE	GAIA-X	EUR 1B	Federated	Phase 2 (slow)
France	Jean Zay extension	EUR 350M	5,000+	2025
Allemagne	Jupiter (Jülich)	EUR 500M	10,000+	2025
UK	AI Research Resource	GBP 300M	8,000+	2024
Inde	IndiaAI Mission	\$1.2B	25,000+	2024-2025
Arabie Saoudite	Humain + PIF	\$50B	150,000+	2024-2027
UAE	G42 + Microsoft	\$1.5B	30,000+	2024
Maroc	Harch Platform	\$1.14B	1,798	2024-2028
Afrique (hors Maroc)	—	<\$100M	<2,000	Fragmente

Harch Platform : seule alternative souveraine non-US, non-UE, non-CN

Harch Platform est la seule plateforme AI compute au monde operant a l'echelle hyperscale (1,798+ GPUs) en dehors des juridictions US, UE, et CN. Pour les gouvernements, banques centrales, et institutions defense - le choix d'une juridiction marocaine (CNDP + Loi 09-08, non-alignee politiquement) offre une neutralite strategique que ne peut fournir aucun autre provider. Le Maroc a des accords bilateraux RGPD-compatible avec l'UE et une stabilite politique reconnue.

05 PLATFORM ARCHITECTURE OVERVIEW (4-LAYER)

Architecture 4 couches

Harch Platform s'organise en 4 couches (L1 a L4), chacune avec un role specifique. Cette separation permet l'evolutivite independante des couches et l'innovation continue sans disruption pour les clients. La couche L1 (Infrastructure) est operee par Harch Intelligence ; les couches L2-L4 sont operee par Harch Technology.

Couche	Nom	Composants	Technologie	Operateur
L4	AI Services	MLOps Studio, Model Hub, Endpoints, SDK	PyTorch, vLLM, TGI, Triton, MLflow	Harch Technology
L3	Orchestration	HarchOS Scheduler, Carbon Engine, Identity	Kubernetes, Go, Rust, Keycloak	Harch Technology
L2	Compute Fabric	GPUs H100/H200, InfiniBand 400G, NVMe	NVIDIA Quantum-2, BlueField-3, NVLink	Harch Intelligence
L1	Infrastructure	Power, cooling, storage, racks, building	Free cooling, UPS, diesel backup, security	Harch Intelligence

Couche L1 - Infrastructure physique

La couche L1 comprend l'infrastructure physique : batiment data center, alimentation electrique (avec redondance 2N), refroidissement (free cooling + DX backup), onduleurs, groupes electrogenes diesel backup (usage exceptionnel), securite physique (perimeter, biometrie, videosurveillance), et reseau interne. Cette couche est operee selon standards Uptime Institute Tier IV+ (concurrent maintainability, fault tolerant).

Couche L2 - Compute Fabric

La couche L2 est le compute fabric : GPUs NVIDIA H100/H200 (8 par serveur, connectes via NVLink 4.0 900 GB/s + NVSwitch), serveurs GPU (Dell PowerEdge R760xa, Supermicro AS-4124GS-TNR), switches InfiniBand 400G HDR (NVIDIA Quantum-2 NQM9700) en topologie fat-tree 2:1 non-bloquante, stockage NVMe local (hot tier) et NVMe-oF (warm tier), et network interface cards BlueField-3 DPU offload.

Couche L3 - Orchestration

La couche L3 est l'orchestration HarchOS - coeur proprietarielle de Harch Platform. Composants : (i) Kubernetes 1.30+ pour container orchestration, (ii) Volcano scheduler pour batch AI workloads, (iii) Carbon Engine (Rust + Go) pour carbon-aware routing real-time, (iv) Identity Service (Keycloak + OIDC) pour authentication SSO, (v) Multi-cluster manager pour orchestration cross-hubs. Cette couche est l'innovation cle de Harch Platform.

Couche L4 - AI Services

La couche L4 expose les services AI aux clients : (i) MLOps Studio (interface web pour training, fine-tuning, deploiement), (ii) Model Hub (registry base sur MLflow + HuggingFace), (iii) Inference Endpoints (vLLM + TGI + Triton, autoscaling), (iv) SDK Python + TypeScript, (v) CLI harchctl. Cette couche est 100% open standards - les workloads sont portables vers n'importe quel environnement compatible K8s/PyTorch.

Harch Platform — Architecture 4 couches (L1 → L4)



Figure : Architecture 4 couches Harch Platform — L1 Infrastructure → L4 AI Services (séparation opérateurs Harch Intelligence / Technology)

Principe : open standards, pas de lock-in

Harch Platform repose sur un principe fondamental : aucun lock-in proprietary API. Tous les services utilisent des standards ouverts (Kubernetes, PyTorch, HuggingFace, MLflow, OpenAI-compatible API). Un client peut migrer ses workloads vers AWS, GCP, Azure, ou on-prem sans refactor. Cette philosophie différencie radicalement Harch Platform d'AWS SageMaker, Google Vertex AI, ou Azure ML - qui créent une dépendance API proprietary.

06 FIVE GPU HUBS DEEP-DIVE

Vue d'ensemble des 5 hubs

Harch Platform orchestre 5 hubs GPU distribues au Maroc - chacun avec ses caracteristiques propres (capacite, mix energetique, climate, latence UE). Cette architecture distribuee offre : (i) resilience (un hub down ne stoppe pas le service), (ii) carbon-aware routing (exploiter variations carbon intensity), (iii) proximity clients (8 ms UE via Tanger, local Maroc via Casa), (iv) data residency (par region/jurisdiction).

Hub	GPUs	MW	Renewable %	Carbon (gCO2/kWh)	PUE	Latence UE	CAPEX
Dakhla	500	120	97.2%	18	1.10	12 ms	\$285M
Ouarzazate	450	110	97.2%	18	1.12	14 ms	\$255M
Benguerir	350	85	88.5%	55	1.14	16 ms	\$200M
Tanger	200	50	82.1%	95	1.15	8 ms	\$115M
Casablanca	298	70	45%	210	1.18	18 ms	\$90M
Total / Moy.	1,798	435	81.5%	47	1.14	13.6 ms moy.	\$945M
Total	1,798	435	81.5%	47	1.14	—	\$945M

Hub Dakhla - Training LLMs

Dakhla est le hub flagship - 500 GPUs H100, 120 MW, carbon intensity 18 gCO2/kWh (le plus bas du reseau grace a 97.2% renouvelable : 350 MW solaire + 150 MW eolien Harch Energy). Position 23.7N cote atlantique sud, free cooling 96% du temps. Designe pour training LLMs grande echelle (GPT-4 scale, 1.8T params). InfiniBand 400G non-bloquant, 60 racks densite 50 kW. Mise en service T4 2027.

Hub Ouarzazate - Training + Inference

Ouarzazate (30.9N, altitude 1,160m) beneficie du meilleur free cooling du reseau (98% du temps) et du carbon intensity le plus bas (18 gCO2/kWh, 97.2% renouvelable via solaire Noor 350 MW). 450 GPUs H100/H200 mix, 110 MW. Usage mixte training + inference. CAPEX \$255M, mise en service T2 2027.

Hub Benguerir - Hybrid + R&D;

Benguerir, proxima UM6P (Mohammed VI Polytechnic University), est dedie aux workloads hybrides : training moyen echelle, inference, R&D;, collaborations academiques. 350 GPUs H100, 85 MW, carbon 55 gCO2/kWh (88.5% renouvelable). 100 GPUs deja operationnels depuis Q4 2024, scale-out complet T4 2026.

Hub Tanger - Gateway Europe

Tanger (35.8N, pres Detroit Gibraltar) est la gateway vers l'Europe - latence 8 ms vers Marseille (via cable Atlas Off I), 5 ms vers Madrid (via Med Cable). 200 GPUs H100, 50 MW, carbon 95 gCO2/kWh (82.1% renouvelable). Dedie a inference real-time pour clients EU (latency-sensitive). Operationnel depuis T1 2026.

Hub Casablanca - HQ + Edge

Casablanca (siege Harch Corp) est le plus petit hub (298 GPUs, 70 MW) et le moins vert (210 gCO2/kWh, 45% renouvelable - grid ONEE). Roles : edge inference pour clients marocains, dev + staging, HQ operations, dev portal Harch Platform. Operationnel depuis Q4 2024.

Comparaison specification technique

Spec	Dakhla	Ouarzazate	Benguerir	Tanger	Casablanca
GPUs	500 H100	450 H100/H200	350 H100	200 H100	298 H100
Power total (MW)	120	110	85	50	70
Racks	60	55	42	25	35
Storage (PB)	4.0	3.6	2.8	1.8	2.8
InfiniBand switches	12	11	8	5	8
Free cooling h/yr	8,400	8,600	8,200	8,000	7,800
Temp moy (C)	22.0	18.5	21.0	19.5	19.0
Wet-bulb moy (C)	17.5	13.2	15.8	16.0	16.5
Mise en service	T4 2027	T2 2027	T4 2026	T1 2026	Q4 2024
CAPEX (M\$)	285	255	200	115	90

Architecture distribuee = resilience 99.95%+

L'architecture 5-hubs permet une resilience 99.95%+ garantie : si un hub est indisponible (maintenance, incident), les workloads sont automatiquement routes vers les 4 autres via HarchOS multi-cluster manager. Le carbon-aware routing exploite les variations de carbon intensity entre hubs (ex : route vers Dakhla la nuit quand solaire Ouarzazate est off). Cette flexibilite n'est pas possible avec un site hyperscale unique.

07 CARBON-AWARE SCHEDULING (REAL-TIME)

Principe

Le carbon-aware scheduler de HarchOS est le coeur de l'avantage environnemental de Harch Platform. Principe : router dynamiquement chaque workload AI vers le hub avec le carbon intensity le plus bas a l'instant t. Comme les 5 hubs ont des mix energetiques differents (solaire dominant a Dakhla/Ouarzazate, grid ONEE a Casa), il existe a chaque instant un hub significativement plus propre que les autres. Le scheduler exploite cette variabilite.

Donnees d'entree real-time

Le scheduler collecte en temps reel (telemetrie 5-min cadence) les donnees suivantes : (i) production solaire Harch Energy par site (kW, via inverters API), (ii) production eolien Harch Energy par site (kW, via SCADA), (iii) carbon intensity grid ONEE (gCO2/kWh, source ENR Morocco API horaire), (iv) charge IT par hub (kW, via PDU SNMP), (v) PUE mesure par hub, (vi) file d'attente workloads par hub, (vii) latence inter-hubs (ms).

Algorithme d'optimisation

Etape	Action	Frequence	Donnees utilisees	Latence ajoutee
1 - Telemetrie	Collecte temps reel production + carbon	5 min	Harch Energy + ONEE API	0
2 - Prediction	Forecast production solaire 4h ahead	15 min	ML model irradiation	0
3 - Carbon score	Calcul carbon intensity par hub	5 min	Telemetrie + PUE	0
4 - Workload queue	File priorite + SLA + latence	1 min	Kubernetes jobs queue	0
5 - Placement	Optimisation bin-packing multi-hub	1 min	Knapsack solver	<5 ms
6 - Migration	Migration live workloads si meilleur hub	15 min	Container live migration	<10 ms
7 - Verification	Audit carbone reel vs optimise	1 h	Logs + carbon verifier	0

Integration ONEE - real-time grid carbon

Harch Platform a developpe une integration API avec ONEE (Office National de l'Electricite et de l'Eau potable) pour recuperer en temps reel le carbon intensity du grid marocain. Cette API (publiee via ENR Morocco) fournit le mix energetique horaire du grid (solaire, eolien, hydro, charbon, gas, importations) - permettant un calcul precis du carbon intensity pour la fraction non-renouvelable. Cette integration est unique au monde - la plupart des providers utilisent des moyennes annuelles statiques.

Heure	Solaire grid (%)	Eolien grid (%)	Hydro (%)	Thermique (%)	Carbon grid (gCO2/kWh)
02:00	0	12	8	80	680
06:00	5	18	8	69	590
10:00	32	15	8	45	380
12:00	45	12	8	35	295
14:00	48	14	8	30	270

18:00	18	22	8	52	465
22:00	0	14	8	78	665
Moyenne 24h	20%	15%	8%	57%	480

Impact mesure du carbon-aware scheduling

Le scheduler a ete deploye en production sur Casablanca + Tanger depuis Q1 2026. Resultats mesures apres 4 mois : (i) reduction carbon emissions de 31% vs scheduling naive, (ii) 96% des workloads places optimalement, (iii) zero SLA violation due au routing, (iv) latence ajoutee moyenne 4 ms (<10% du budget latence total). A scale-out complet (5 hubs, 2028), reduction estimee de 42%.

Metrique	Avant scheduler	Apres scheduler	Reduction	Note
Carbon emissions (tCO2/an)	12,400	8,560	-31%	Hub Casa + Tanger 2026
Workloads optimalement places	—	96%	+96 pts	Objectif 90%+
Latence ajoutee moyenne	—	4 ms	—	<10% budget latence
SLA violations	0	0	—	Aucun impact service
Cout compute additionnel	—	+2%	—	Migrations inter-hub
Net benefit (tCO2 / \$)	—	8,560 / \$45k	—	Carbon abatement \$5.25/tCO2




Figure : Flow HarchOS Carbon-Aware Scheduler — routing temps réel vers hub le plus propre (-31% émissions mesurées Q1 2026)

Avantage unique vs hyperscalers carbon-aware

AWS, Google Cloud, et Microsoft Azure ont lance des carbon-aware schedulers en 2023-2024. Cependant, ces solutions sont limitees : (i) basees sur RECs (Renewable Energy Certificates) et non sur energie renouvelable dediee physiquement, (ii) ne routent pas vers d'autres regions en temps reel (intra-region only), (iii) ne couvrent que Scope 2 market-based. Harch Platform est le seul provider au monde a offrir un carbon-aware scheduler base sur energie renouvelable physiquement dediee, multi-hub, real-time.

08 STORAGE ARCHITECTURE

Architecture 3-tiers

Harch Platform implemente une architecture de stockage 3-tiers (hot/warm/cold) optimisee pour les workloads AI. Le tiering est automatique via HarchOS, base sur frequence d'accès, criticite latence, et cout. Capacite totale 15 PB repartie : 2 PB hot (NVMe local), 5 PB warm (NVMe-oF share), 8 PB cold (HDD + object). Cette architecture reduit le cout stockage de 77% vs tout-NVMe, tout en preservant la performance pour les donnees chaudes.

Tier 1 - Hot (NVMe local, 2 PB)

SSDs NVMe PCIe Gen5 directement connectes aux serveurs GPU (Dell PowerEdge R760xa, Supermicro AS-4124GS-TNR). Capacite 2 PB total (4 TB par GPU node moyenne), latence <100 microsecondes, bandwidth 14 GB/s par drive. Usage : datasets training actifs, modeles en inference, checkpoints recents. Technologie : Samsung PM9A3, Micron 7450 MAX, Kioxia CM7. Cout \$8,500/TB.

Tier 2 - Warm (NVMe-oF, 5 PB)

Baies NVMe-oF (NVMe over Fabrics) partagees entre nodes via InfiniBand. Capacite 5 PB, latence <1 ms, bandwidth 100 GB/s. Usage : datasets de reference, modeles pre-entraines, intermediate checkpoints, donnees validation. Technologie : Pure Storage FlashArray //X90, Dell PowerScale F910, WekaIO. Cout \$2,200/TB.

Tier 3 - Cold (HDD + S3, 8 PB)

Baies HDD haute densite + object storage S3-compatible. Capacite 8 PB, latence 5-50 ms, bandwidth 10 GB/s. Usage : archives checkpoints, datasets historiques, logs, raw data long-term. Technologie : Dell PowerScale H700, Backblaze B2, Cloudflare R2. Cout \$95/TB. Tiering automatique : donnees non-accedees >30 jours migrees vers cold.

Specifications stockage par tier

Tier	Capacite	Technologie	Latence	Bandwidth	Cout \$/TB	Usage typique
Hot - NVMe local	2 PB	Samsung PM9A3 / Micron 7450	<100 us	14 GB/s/drive	\$8,500	Datasets training actifs
Warm - NVMe-oF	5 PB	Pure FlashArray //X90	<1 ms	100 GB/s	\$2,200	Modeles pre-entraines
Cold - HDD + S3	8 PB	Dell PowerScale H700	5-50 ms	10 GB/s	\$95	Archives + raw data
Total	15 PB	3 tiers	—	—	—	—
Total	15 PB	3 tiers	—	—	—	—

Cout stockage consolide

Tier	Capacite (TB)	Cout \$/TB	CAPEX total (M\$)	% Capacite	% Cout
Hot - NVMe local	2,000	\$8,500	\$17.0	13.3%	64%
Warm - NVMe-oF	5,000	\$2,200	\$11.0	33.3%	41%
Cold - HDD + S3	8,000	\$95	\$0.76	53.3%	3%

Total	15,000	Mix	\$28.76	100%	100%
Total	15,000	Mix	\$28.76	100%	100%

Tiering automatique : 77% d'economie vs tout-NVMe

Une architecture tout-NVMe (15 PB) coûterait \$127.5M. L'architecture 3-tiers de Harch Platform coûte \$28.76M - soit une économie de \$98.7M (77%). Le tiering automatique préserve la performance pour les données chaudes (datasets actifs en NVMe local) tout en optimisant le coût pour les données froides (archives en HDD). ROI du système de tiering : <12 mois.

09 NETWORK FABRIC (INFINIBAND, ROCE)

InfiniBand HDR 400G non-bloquant

Chaque hub est equipe d'un network fabric InfiniBand HDR 400G non-bloquant, base sur les switches NVIDIA Quantum-2 (NQM9700). L'InfiniBand est le standard de fait pour les clusters AI hyperscale (utilise par Meta, Microsoft, Google, OpenAI) car il offre : (i) latence ultra-basse (<1 microsecond), (ii) bandwidth eleve (400 Gbps/port), (iii) hardware RDMA, (iv) adaptive routing, (v) SHARP (Scalable Hierarchical Aggregation and Reduction Protocol) pour acclereler les all-reduce operations.

Topologie Fat-Tree 2:1

La topologie est une fat-tree 2:1 (oversubscription 2:1 sur les uplinks). Cette topologie offre un excellent compromis performance/cout : 100% de la bandwidth pour 50% des paires de nodes (vs 100% pour une fat-tree 1:1, mais 2x plus de switches). Pour les workloads AI distribues type all-reduce (entrainement LLM), l'oversubscription 2:1 n'impacte pas les performances grace au SHARP in-network reduction.

Specifications InfiniBand par hub

Hub	GPUs	Switches Quantum-2	Ports 400G	Topologie	Latence max
Dakhla	500	8 leaf + 4 spine	192	Fat-tree 2:1	2.5 us
Ouarzazate	450	7 leaf + 4 spine	168	Fat-tree 2:1	2.5 us
Benguerir	350	5 leaf + 3 spine	120	Fat-tree 2:1	2.0 us
Tanger	200	3 leaf + 2 spine	72	Fat-tree 2:1	1.5 us
Casablanca	298	5 leaf + 3 spine	120	Fat-tree 2:1	2.0 us
Total	1,798	28 leaf + 16 spine	672	5 clusters IB	2.5 us max
Total	1,798	44 switches	672 ports	5 clusters	2.5 us

InfiniBand vs RoCE v2

Harch Platform utilise InfiniBand HDR 400G comme primary fabric. RoCE v2 (RDMA over Converged Ethernet) est egalement supporte pour les workloads moins exigeants (storage NVMe-oF, management network). Avantages InfiniBand : latence 2-3x inferieure, SHARP in-network reduction, adaptive routing hardware natif, congestion control DCN (Data Center Network). Avantages RoCE v2 : cout 40-50% inferieur, ecosystem Ethernet, interoperabilite plus large.

Critere	InfiniBand HDR 400G	RoCE v2 (Ethernet 400G)	Avantage
Latence	0.9-2.5 us	3-5 us	InfiniBand (-50%)
Bandwidth par port	400 Gbps	400 Gbps	Equivalent
SHARP in-network reduction	Oui	Non (logiciel)	InfiniBand
Adaptive routing	Hardware natif	Logiciel (ECMP)	InfiniBand
Congestion control	DCN/CCTV	DCQCN/PFC	InfiniBand
Cout par port	\$2,800	\$1,400	RoCE (-50%)

RDMA	Hardware natif	Hardware (BlueField)	Equivalent
Ecosystem	NVIDIA Quantum	Open (Broadcom, Mellanox)	RoCE
Usage Harch	Compute GPU fabric	Storage NVMe-oF + mgmt	Mix optimal

Interconnect GPU - NVLink + NVSwitch

Au niveau intra-node, les GPUs H100 sont connectes via NVLink 4.0 (900 GB/s par GPU, 4x plus rapide que PCIe Gen5) et NVSwitch (full-mesh 8 GPUs/node). Cette connectivite permet les communications GPU-to-GPU ultra-rapides necessaires pour le model parallelism (tensor parallel, pipeline parallel). Pour les communications inter-node, InfiniBand HDR 400G (50 GB/s/node) prend le relais.

Interconnect	Bandwidth	Latence	Usage	Cout relatif
NVLink 4.0 (intra-node)	900 GB/s/GPU	200 ns	Tensor parallel, model parallel	Inclus GPU
NVSwitch (8 GPUs mesh)	900 GB/s full-mesh	300 ns	All-reduce intra-node	Inclus node
InfiniBand HDR 400G (inter-node)	50 GB/s/node	1-2 us	Data parallel, all-reduce	\$2,800/port
InfiniBand NDR 800G (next-gen)	100 GB/s/node	0.9 us	Future 2027+ (Harch v3)	\$5,500/port
RoCE v2 (Ethernet alternative)	25 GB/s/node	3-5 us	Workloads mixtes, storage	\$1,400/port

InfiniBand natif = 30%+ performance training LLM

L'InfiniBand natif (vs Ethernet/RoCE) permet 30%+ de performance supplementaire pour le training LLM distribue grace au SHARP in-network reduction (offload des all-reduce operations aux switches). Pour un training GPT-3 175B sur 1,024 GPUs, l'economie de temps est de 9 jours (23.5 jours vs 32.5 jours RoCE) - soit une economie compute de \$1.3M par run. C'est pourquoi tous les hyperscalers AI (Meta, Microsoft, Google) utilisent InfiniBand natif.

10 SUBMARINE CABLE SYSTEMS

Hub sous-marin marocain - Nexus Maroc

Harch Platform beneficie du hub sous-marin marocain - 14 cables sous-marins connectant le Maroc a l'Europe, l'Afrique de l'Ouest, et l'Asie. Capacite totale 80 Tbps. Le Maroc est le 3e hub telecoms africain apres l'Egypte et l'Afrique du Sud, avec une position geographique strategique (proximity Europe + Africa). 3 landing stations : Asilah, Tanger, Casablanca - assurant redondance multi-cables.

Cables principaux vers UE

Cable sous-marin	Connectivite	Capacite (Tbps)	Latence vers UE	Landing Maroc	Statut
Atlas Off I	Maroc - France	20	8 ms (Marseille)	Asilah	Operationnel
Tata TGN-West	Maroc - UK	10	11 ms (London)	Tanger	Operationnel
Med Cable	Maroc - Espagne	15	5 ms (Madrid)	Tanger	Operationnel
ACE	Multi-pays Afrique Ouest	10	Variable	Casablanca	Operationnel
Dunant	Maroc - USA (via France)	20	50 ms (Virginia)	Asilah	Operationnel
Equiano	Afrique Ouest - Afrique Sud	12	N/A	Casablanca	Operationnel
2Africa	Circumnavigation Afrique	30	Variable	Casablanca	Operationnel
Hannibal	Tunisie - Italie (extension)	5	15 ms (Rome)	—	Indirect
MaroTel (national)	Cote atlantique marocaine	5	—	Multi	Operationnel
Total cables (9 principaux)	Multi-destinations	127 Tbps	5-50 ms	3 landing	—
Total	Multi	127 Tbps	5-50 ms	3 landings	—

Latence vers principales villes europeennes

Ville UE	Latence depuis Tanger (ms)	Latence depuis Casablanca (ms)	Cable principal	Hops
Madrid	5	12	Med Cable	1
Marseille	8	13	Atlas Off I	1
Paris	15	20	Atlas Off I + terrestrial	2
London	11	16	Tata TGN-West	1
Frankfurt	18	23	Atlas Off I + terrestrial	2
Amsterdam	20	25	Tata TGN-West + terrestrial	2
Rome	22	27	Hannibal extension	2
Stockholm	32	37	Multi-hop	3
Dublin	25	30	Tata TGN-West + UK	2
Warsaw	28	33	Multi-hop	3

Redondance et resilience

Harch Platform beneficie d'une redondance multi-cables : si un cable est coupe (incident ancre bateau, seisme), le trafic est automatiquement reroutee via les autres cables (BGP anycast + SD-WAN). Les 3 landing stations (Asilah, Tanger, Casablanca) assurent que la perte d'une landing n'impacte pas la connectivite. SLA reseau : 99.99% (4nines). Latence garantie : <20 ms vers UE principales villes 99% du temps.

Latence 8 ms Tanger-Marseille = inference real-time possible

La latence 8 ms Casablanca-Marseille (via cable Atlas Off I) permet a Harch Platform d'offrir des services d'inference AI real-time pour clients europeens (chatbots, voice assistants, computer vision) avec une latence percue equivalente a un provider EU. Pour comparaison : AWS us-east-1 vers Paris : 85 ms. Google Cloud europe-west1 vers Paris : 3 ms. Harch Platform depuis Tanger : 8-12 ms - competitif pour la majorite des use cases AI real-time.

11 SOVEREIGN SECURITY FRAMEWORK

Framework securite sovereign-by-design

Harch Platform implemente un framework securite sovereign-by-design couvrant 4 dimensions : (i) physique (perimeter, biometrie, videosurveillance), (ii) reseau (firewall, IDS/IPS, DDoS protection), (iii) donnees (chiffrement, residency, GDPR/CNDP compliance), (iv) identity (SSO, MFA, RBAC). Le framework est aligne ISO 27001, SOC 2 Type II, et CNDP (Commission Nationale de Controle de la Protection des Donnees a Caractere Personnel - Maroc).

Securite physique

Layer	Mesure	Standard	Audit frequence
Perimeter	Double fence + detection intrusion	Uptime Institute Tier IV+	Trimestriel
Access control	Badge + biometrie (iris + empreinte)	ISO 27001 A.9	Continu
Videosurveillance	CCTV 24/7 + AI anomaly detection	ISO 27001 A.6	Continu
Security guards	7x24, 4 agents/hub minimum	Uptime Institute	Continu
Mantrap	Sas securise entree data floor	Tier IV+	—
Secure rack	Cadenas biometriques par rack	ISO 27001 A.11	Continu
Secure destruction	Disque dur destruction certifiee	NIST 800-88	Per incident

Securite reseau

Layer	Mesure	Technologie	Frequence
DDoS protection	Mitigation 5 Tbps + scrubbing	Cloudflare Magic Transit + Arbor	Real-time
Firewall perimeter	Next-gen firewall + IPS	Palo Alto + Fortinet	Continu
Network segmentation	LAN + micro-segmentation	Cisco ACI + VMware NSX	Continu
IDS/IPS	Intrusion detection + prevention	Snort + Suricata + AI	Real-time
WAF	Web Application Firewall	Cloudflare WAF + AWS WAF	Real-time
Zero trust	Identity-aware access	BeyondCorp + SPIFFE/SPIRE	Per session
Encryption in transit	TLS 1.3 + mTLS	OpenSSL + Envoy	Toutes connexions
Encryption at rest	AES-256 + HSM	Thales Luna + AWS KMS	Toutes donnees

Data residency et conformite

Harch Platform garantit la residency des donnees au Maroc - les donnees clients ne quittent jamais le territoire marocain sans accord explicite. Conformite : (i) Loi 09-08 marocaine (protection donnees personnelles), (ii) CNDP (declaration obligatoire des traitements), (iii) RGPD europeen via accords bilateraux Maroc-UE (adequacy decision en cours), (iv) pas d'accès CLOUD Act US (juridiction non-US), (v) accords sectoriels (HIPAA pour sante US, PCI-DSS pour paiements).

Cadre reglementaire	Statut Harch Platform	Avantage vs hyperscale	NIST
---------------------	-----------------------	------------------------	------

Loi 09-08 (Maroc)	Conforme + declare CNDP		Tous hubs
RGPD (UE)	Conforme + adequacy	Equivalent EU providers	Accord bilateral
HIPAA (US healthcare)	Conforme via BAA	Equivalent AWS HIPAA	Accord specifique
PCI-DSS (paiements)	Conforme QSA	Equivalent	Audit annuel
CLOUD Act (US)	Non-applicable	Avantage majeur	Jurisdiction non-US
Patriot Act (US)	Non-applicable	Avantage majeur	Jurisdiction non-US
EU AI Act	Conforme (risk-based)	Equivalent	Effectif 2026
NIS2 Directive (UE)	Conforme	Equivalent	Effectif 2024
ISO 27001	In progress (Q1 2027)	Equivalent	Certification
SOC 2 Type II	In progress (Q2 2027)	Equivalent	Audit annuel

Identity & Access Management

Harch Platform implemente un IAM sovereign base sur Keycloak (open source) + OIDC (OpenID Connect) + SAML 2.0. Caracteristiques : (i) SSO multi-tenant avec isolation complete, (ii) MFA obligatoire (TOTP + WebAuthn), (iii) RBAC granulaire (roles, permissions, ressources), (iv) SCIM provisioning (sync avec corporate IdP), (v) audit logs complets (toutes actions tracees). L'IAM est heberge au Maroc - aucune donnee d'authentification ne transite par des services US.

Sovereign-by-design : la difference vs hyperscalers US

Le framework securite sovereign-by-design de Harch Platform offre 3 avantages decisifs vs hyperscalers US : (i) donnees physiquement au Maroc (pas de replication automatique vers US), (ii) aucune exposition au CLOUD Act / Patriot Act US, (iii) jurisdiction CNDP + RGPD-compatible. Pour les organisations souverainete-sensibles (gouvernements, defense, finance, sante), cette difference est decisive. Aucun hyperscaler US ne peut offrir cette garantie.

12 AI PLATFORM SERVICES

Vue d'ensemble des services AI

Harch Platform expose 5 categories de services AI aux clients - couvrant l'ensemble du cycle de vie ML : training, fine-tuning, inference, MLOps, et SDK. Tous les services sont base sur des technologies open source (PyTorch, vLLM, MLflow, Triton) - aucun lock-in proprietary API. Les clients peuvent migrer leurs workloads vers/depuis n'importe quel environnement compatible K8s/PyTorch.

Service	Fonction	Technologie	Pricing	Statut
Training	Entrainement modeles ML	PyTorch 2.4 + DeepSpeed + FSDP	\$1.80-2.20/h GPU H100	GA
Fine-tuning	Adaptation modeles pre-entraines	PyTorch + LoRA + QLoRA	\$1.80-2.20/h GPU H100	GA
Inference	Serving modeles en production	vLLM + TGI + Triton	\$1.40-1.80/h reserved	GA
MLOps Studio	Pipeline ML end-to-end	UIKubeflow + MLflow + Argo	\$500/mo + usage	GA
Model Hub	Registry + versioning	HuggingFace + MLflow	\$200/mo + storage	GA
SDK Python	Client library Python	harch-py (open source)	Free	GA
SDK TypeScript	Client library TS/JS	harch-js (open source)	Free	GA
CLI harchctl	Command-line interface	harchctl (Go binary)	Free	GA
Label Studio	Data labeling integre	Label Studio + CVAT	\$300/mo + usage	Beta
Eval Studio	Model evaluation + benchmarking	Custom + HELM + BIG-bench	\$300/mo + usage	Beta

Service Training - detail

Le service Training permet aux clients d'entraîner des modeles ML depuis zero (pre-training) ou en mode distribue. Caracteristiques : (i) PyTorch 2.4 natif avec compilation torch.compile, (ii) DeepSpeed + FSDP pour training distribue multi-GPU/multi-node, (iii) support model parallelism (tensor, pipeline, expert), (iv) checkpointing automatique, (v) mixed precision (FP16, BF16, FP8), (vi) custom datasets jusqu'a 100 TB. Interface : Python SDK, CLI, ou web UI MLOps Studio.

Spec Training	Valeur	Note
Framework supporte	PyTorch 2.4 + JAX 0.4+	Native, pas de wrapper
Parallelism strategie	DDP, FSDP, TP, PP, EP	Full coverage
Mixed precision	FP32, FP16, BF16, FP8	H100 native FP8
Max nodes par job	60 (480 GPUs)	Cluster Dakhla full
Max dataset size	100 TB	NVMe-oF warm tier
Checkpointing	Auto + manual, S3-compatible	Versioning MLflow
Job scheduling	Volcano + HarchOS carbon-aware	Bin-packing multi-hub
Job runtime max	30 jours (reserved)	Extensible sur demande
Pricing model	On-demand + reserved + spot	\$1.80 / \$1.40 / \$0.90 per H100-h
SLA reserved	99.95% availability	Multi-hub failover

Service Inference - detail

Le service Inference permet le déploiement de modèles en production avec autoscaling. Caractéristiques : (i) vLLM pour LLMs (PagedAttention, continuous batching), (ii) TGI (Text Generation Inference) pour alternative, (iii) Triton Inference Server pour modèles génériques (PyTorch, ONNX, TensorRT), (iv) autoscaling K8s (HPA + custom metrics), (v) OpenAI-compatible API, (vi) A/B testing + canary deployments natifs.

Spec Inference	Valeur	Note
Servers supportes	vLLM, TGI, Triton, Custom	Open source
API compatibility	OpenAI Chat Completions, v1	Drop-in replacement
Autoscaling	HPA + KEDA + custom metrics	Per-endpoint
Max tokens/sec (Llama 70B)	12,800 tokens/sec	8 GPUs H100
Max tokens/sec (Mistral 7B)	68,500 tokens/sec	8 GPUs H100
Cold start	<30 sec (container image cached)	Pre-pulled
Canary deployments	Natif (Argo Rollouts)	5/95, 10/90, etc.
A/B testing	Natif (Istio VirtualService)	Header-based routing
Pricing model	Reserved + on-demand	\$1.40-1.80 per H100-h
SLA production	99.95% availability	Multi-hub failover

SDK Python - exemple

Le SDK Python harch-py (open source, disponible sur PyPI) offre une API Python simple pour training, inference, et MLOps. Exemple : `from harch import TrainingClient ; client = TrainingClient(api_key='...') ; job = client.train(model='llama-3-70b', dataset='s3://...', gpus=8, hub='dakhla', carbon_aware=True)`. Le SDK gère automatiquement : authentification, upload dataset, selection hub optimal, monitoring, checkpointing, et notification completion.

MLOps Studio - detail

MLOps Studio est l'interface web unifiée pour gérer l'ensemble du cycle de vie ML : experiment tracking, model registry, pipeline orchestration, deployment, monitoring. Base sur Kubeflow + MLflow + Argo Workflows + Grafana. Caractéristiques : (i) experiment tracking intégré (auto-logging PyTorch/JAX), (ii) model registry avec versioning sémantique, (iii) pipeline visual orchestration (DAG editor), (iv) deployment one-click vers production, (v) monitoring drift + performance. Tarif : \$500/mois + usage GPU.

Module MLOps	Fonction	Technologie	Statut
Experiment Tracking	Auto-logging métriques + hyperparamètres	MLflow + custom	GA
Model Registry	Versioning + lineage modèles	MLflow Model Registry	GA
Pipeline Orchestrator	DAG visual + execution	Argo Workflows + Kubeflow	GA
Feature Store	Stockage + reuse features ML	Feast + Redis	GA
Deployment Manager	Deploy prod + canary + A/B	Argo Rollouts + Istio	GA
Drift Monitor	Detection data + concept drift	Evidently + custom	GA

Explainability	SHAP + LIME explanations	SHAP + custom	Beta
Active Learning	Selection donnees a annoter	modAL + custom	Beta
AutoML	Recherche auto hyperparams	Optuna + Ray Tune	Beta
Reinforcement Learning	Entrainement RL distribue	Ray RLlib + custom	Roadmap 2027

SDK Python - exemple detaille

Le SDK Python harch-py (open source, disponible sur PyPI) offre une API Python simple pour training, inference, et MLOps. Installation : pip install harch-py. Authentification : API key generee via web UI. Exemple training : from harch import TrainingClient ; client = TrainingClient(api_key='...') ; job = client.train(model='llama-3-70b', dataset='s3://...', gpus=8, hub='dakhla', carbon_aware=True) ; job.wait() ; job.download_checkpoints('/local/path'). Le SDK gere automatiquement : authentication, upload dataset, selection hub optimal, monitoring, checkpointing, et notification completion.

Operation SDK	Methode Python	Description	Latence typique
Create training job	client.train(...)	Soumet job training	<2 sec submission
List jobs	client.jobs.list()	Liste jobs user	<1 sec
Get job status	job.status()	Status temps reel	<500 ms
Cancel job	job.cancel()	Annulation job	<1 sec
Download checkpoints	job.download_checkpoints(path)	Download S3	Depend size
Create inference endpoint	client.inference.deploy(...)	Deploie endpoint	<30 sec cold
Call inference	endpoint.predict(input)	Inference real-time	<300 ms
Manage datasets	client.datasets.upload(path)	Upload dataset	Depend size
Browse model hub	client.models.list()	Liste modeles	<1 sec
Carbon report	client.reports.carbon(date_range)	Rapport carbone	<2 sec

Open standards : zero lock-in

Tous les services Harch Platform utilisent exclusivement des technologies open source (Kubernetes, PyTorch, vLLM, MLflow, HuggingFace). Aucun lock-in proprietary API (vs AWS SageMaker, Google Vertex AI). Les clients peuvent migrer leurs workloads vers/depuis n'importe quel environnement compatible - sans refactor, sans vendor fees, sans restrictions. Cette philosophie est centrale au positionnement souverain et differentiant.

13 SUSTAINABLE COMPUTE ECONOMICS (TCO, PRICING)

TCO - Total Cost of Ownership

Le TCO d'un workload AI compute sur 3 ans (duree typique amortissement GPU) se decompose en : (i) cout compute GPU (60-65%), (ii) cout stockage (10-12%), (iii) cout reseau (3-5%), (iv) cout software/MLOps (5-8%), (v) cout operations/staffing (10-15%). Harch Platform offre un TCO 30-50% inferieur aux hyperscalers europeens grace au cout energie 72% inferieur et au model verticallly integrated.

TCO comparison 3 ans (8 GPUs H100, utilisation 70%)

Poste	Harch Platform	AWS eu-west-1	Google Cloud	Azure West EU	OVHcloud
Compute GPU (8x H100, 18,396 h/3ans)	\$323k	\$587k	\$570k	\$616k	\$494k
Stockage 100 TB hot + 500 TB cold	\$18k	\$36k	\$30k	\$36k	\$24k
Reseau (egress 50 TB/an)	\$5k	\$60k	\$45k	\$55k	\$15k
Software/MLOps	\$18k	\$60k (SageMaker)	\$55k (Vertex)	\$58k (Azure ML)	\$24k
Operations/staffing	\$30k	\$45k	\$40k	\$45k	\$35k
TCO 3 ans	\$323k	\$788k	\$740k	\$810k	\$592k
vs Harch	—	+144%	+129%	+151%	+83%
TCO annuel	\$108k	\$263k	\$247k	\$270k	\$197k

Tarifs GPU detailles

GPU model	Harch on-demand	Harch reserved	Harch spot	AWS on-demand	AWS spot	Avantage Harch
H100 80GB	\$1.80	\$1.40	\$0.90	\$3.50	\$1.05	-49% on-demand
H200 141GB	\$2.20	\$1.75	\$1.10	\$4.10	\$1.30	-46% on-demand
A100 80GB	\$1.49	\$1.15	\$0.75	\$2.80	\$0.85	-47% on-demand
L40S 48GB	\$1.10	\$0.85	\$0.55	\$1.85	\$0.55	-41% on-demand
A10G 24GB	\$0.65	\$0.50	\$0.32	\$1.00	\$0.30	-35% on-demand
T4 16GB	\$0.35	\$0.28	\$0.18	\$0.55	\$0.16	-36% on-demand

Models economiques

- 1. **On-demand** - Paiement a l'usage, sans engagement. Tarif \$1.80-2.20/h GPU H100. Ideal pour workloads ad-hoc, R&D;, experimentation. Disponibilite best-effort.
- 2. **Reserved** - Reservation 1-3 ans, tarif \$1.40-1.80/h (20-30% remise). Capacite garantie. Ideal pour production workloads previsibles. SLA 99.95%.
- 3. **Spot** - Capacite non-utilisee, tarif \$0.90-1.10/h (50% remise). Preemption possible avec notice 2 min. Ideal pour workloads batch, checkpoints, training fault-tolerant.
- 4. **Committed Use Discount (CUD)** - Engagement 3 ans sur capacite GPU, remise 35-45%. Flexible sur types de GPUs. Ideal pour grands comptes.

5. Enterprise agreement - Contrats custom >\$500k/an. Tarifs negocies, SLA renforce, dedicated support. Ideal pour gouvernements, grandes entreprises.

6. Academic program - Allocation gratuite 1M GPU-heures/an (a partir 2027) pour chercheurs academia. Application + review comite. Objectif : democratiser AI compute pour recherche.

7. Startup credits - \$50k credits GPU pour premiers 100 clients startup 2026. Eligibilite : startup AI, <5 ans, <\$10M funding.

Tarif H100 \$1.80/h - le plus competitif au monde

Le tarif H100 on-demand \$1.80/h de Harch Platform est le plus competitif au monde pour un provider AI hyperscale operant en production (hors providers US-only comme Lambda Labs ou CoreWeave \$2.39/h, qui ne sont pas accessibles aux clients EU/Afrique sans latence +120 ms). Cette competitivite resulte du LCOE Maroc \$0.018/kWh (vs \$0.065 EU), du PUE excellent 1.14, et du model vertically integrated (pas de marges intermediaires).

14 COMPETITIVE LANDSCAPE

Positionnement vs concurrents

Harch Platform se positionne comme une alternative souveraine specialisee AI aux hyperscalers generalistes. Plutot que de competir sur la largeur de services (200+ services AWS), nous concentrons sur l'excellence AI compute : GPUs performants, cout competitif, carbon intensity bas, juridiction souveraine. Cette specialisation permet d'offrir un produit superieur sur le segment AI tout en cohabitant avec les hyperscalers (multi-cloud strategies des clients).

Comparaison multi-criteres

Critere	Harch	AWS	Google	Azure	OVHcloud	Scaleway
GPU H100 \$/h	\$1.80	\$3.50	\$3.40	\$3.67	\$2.95	\$2.80
Carbon gCO2/kWh	47	316	178	334	58	62
PUE	1.14	1.20	1.12	1.20	1.28	1.30
Renewable %	81.5%	42%	56%	38%	78%	72%
Latence UE (ms)	8-18	0-5	0-5	0-5	0-5	0-5
Juridiction souveraine	Maroc	US	US	US	France	France
GPU AI scale	1,798	300k+	250k+	200k+	<10k	<5k
InfiniBand natif	Oui	Mixte	Mixte	Mixte	Non	Non
Carbon scheduler	Natif+dedie	RECs	RECs	RECs	Non	Non
Open standards	Oui	Partiel	Partiel	Partiel	Oui	Oui
AI tooling depth	Limite	Deep	Deep	Deep	Limite	Limite
Compliance (CLOUD Act)	Non-applicable	Oui	Oui	Oui	Non-applicable	Non-applicable
Specialisation AI	100%	Generaliste	Generaliste	Generaliste	Generaliste	Generaliste

SWOT Harch Platform

Forces	Faiblesses
Cout energie 72% inferieur	Echelle reduite (1,798 GPUs vs 300k+ AWS)
Carbon intensity 89% inferieur	Pas de services AI avances (vs SageMaker/Vertex)
Tarif GPU 30-49% plus competitif	Marque moins connue internationalement
Juridiction souveraine (CNDP, non-US)	Single region (Maroc) - pas de multi-region global
Vertically integrated (Harch Energy + Tech)	Pas d'offre non-GPU (CPU, storage only)
AI-native design (pas de retrofit)	Equipe commerciale a construire (2025-2027)
InfiniBand 400G natif + carbon-aware scheduler	Pas de marketplace ecosystem (vs AWS)
Open standards, no lock-in	Brand awareness faible hors Maroc/Afrique

Opportunités	Menaces
Demande AI compute mondiale 38% CAGR	Concurrence hyperscalers (prix pouvait baisser)
Pression ESG/CSRD europeenne pousse vers providers verts	Risques geopolitiques (Maroc, Afrique du Nord)
Souverainete numerique UE/Afrique (post-CLOUD Act)	Nouvelles restrictions export US sur GPUs AI
Scalabilite vers Afrique (50+ pays underserved)	Volatilite prix GPUs (NVIDIA allocations)
Expansion services AI (fine-tuning, deploiement)	Hyperscalers AI Factories (UE, \$5B budget)
Partenariats avec gouvernements (banques centrales)	Risques climatiques (secheresse, heat waves)
AI inference edge market (Tanger gateway UE)	Cybersecurite menaces (DDoS, supply chain)
Carbon credit revenue (3.2M tCO2 offset)	Nouvelles regulations AI (EU AI Act, US Executive Orders)

Strategie go-to-market : cohabiter, pas remplacer

Harch Platform ne cherche pas a remplacer AWS/GCP/Azure sur tous les workloads. La strategie est de devenir le provider specialise AI pour 3 segments : (i) organisations souverainete-sensibles (gouvernements, defense, finance, sante), (ii) entreprises ESG-driven cherchant carbon reduction verifiee, (iii) startups AI cherchant cout optimal. Les clients utilisent souvent Harch Platform en complement de leur hyperscaler principal (multi-cloud), pas en remplacement.

15 CUSTOMER ENGAGEMENT MODELS

5 modeles d'engagement

Harch Platform offre 5 modeles d'engagement client adaptes aux différents profiles : (i) Self-service pour startups, (ii) Standard support pour PME, (iii) Enterprise pour grands comptes, (iv) Sovereign pour gouvernements, (v) Academic pour recherche. Chaque modele inclut un ensemble de services, SLA, et support - avec pricing aligne.

Modele	Audience	SLA	Support	Pricing minimum	Onboarding
Self-service	Startups, devs individuels	Best-effort	Email + docs	\$0 (pay-as-you-go)	Automatique <48h
Standard	PME, scale-ups	99.5%	Email + chat 8x5	\$2k/mois	5 jours ouvrés
Enterprise	Grandes entreprises	99.95%	TAM dedie 24/7	\$15k/mois	2 semaines
Sovereign	Gouvernements, defense	99.99%	Equipe dediee on-site	\$50k/mois	1-3 mois (audit)
Academic	Recherche, universites	Best-effort	Email + forum	Free (credits)	2 semaines (review)

Self-service - details

Le modele self-service est destine aux startups et developpeurs individuels. Onboarding automatique en <48h via formulaire web + verification KYC. Paiement par carte bancaire ou virement. Pas d'engagement minimum, pay-as-you-go. Support email + documentation complete (harchcorp.com/docs). Stack : SDK Python + CLI harchctl + web UI MLOps Studio. Ideal pour prototypage, R&D;, MVPs.

Enterprise - details

Le modele enterprise est destine aux grandes entreprises (>500 employes, >\$50M revenue). Inclut : (i) TAM (Technical Account Manager) dedie, (ii) SLA 99.95% avec credits en cas de violation, (iii) support 24/7 phone + chat + email, (iv) custom integrations (SSO corporate, VPC peering, dedicated GPUs), (v) quarterly business review, (vi) training sessions pour equipes client. Pricing minimum \$15k/mois + usage. Onboarding 2 semaines.

Sovereign - details

Le modele sovereign est destine aux gouvernements, institutions defense, banques centrales, et organismes souverainete-sensibles. Inclut : (i) equipe dediee on-site (2-3 ingenieurs Harch), (ii) SLA 99.99% avec penalties financieres, (iii) security audit + compliance review, (iv) dedicated hub (option), (v) accords bilateraux (Maroc-pays client), (vi) source code escrow (continuite service), (vii) clearance personnel (Maroc + pays client). Pricing minimum \$50k/mois + usage. Onboarding 1-3 mois (audit complet).

Modele sovereign : proposition unique au monde

Le modele sovereign de Harch Platform est unique au monde. Aucun hyperscaler US ne peut offrir : (i) equipe dediee on-site au Maroc, (ii) accords bilateraux souverainete, (iii) source code escrow, (iv) clearance personnel double (Maroc + pays client), (v) dedicated hub avec isolation physique complete. Pour les gouvernements africains, europeens, et du Moyen-Orient, c'est la seule offre credible pour AI compute souverain.

16 ROADMAP & FUTURE PHASES

Calendrier deployment 2024-2030

Annee	Phase	Hubs actifs	GPUs	CAPEX (M\$)	Revenue (M\$)	Jalons
2024	Phase 1	Casablanca	298	\$90	\$12	Hub Casa operationnel
2025	Phase 1-2	Casa + 100 GPUs Beng	398	\$170	\$28	Benguerir partiel
2026	Phase 2	Casa + Beng + Tanger	498	\$220	\$58	Tanger operationnel
2027	Phase 2-3	+ Dakhla + Ouarzazate	1,148	\$340	\$115	Hubs Dakhla + Ouar full
2028	Phase 3	5 hubs full build-out	1,798	\$250	\$185	1,798 GPUs tous deploys
2029	Phase 4	5 hubs + optimisation	1,798	\$50	\$235	Carbon scheduler full
2030	Phase 5	5 hubs + expansion	1,798	\$20	\$285	EBITDA 45%
Total	—	5 hubs	1,798	\$1,140M	\$918M cumul	—
Total	—	5 hubs	1,798	\$1,140M	\$918M	—

Phase 6+ (2031+) - Expansion

Apres stabilisation 5 hubs marocains en 2030, Harch Platform envisage expansion Phase 6+ (2031+) vers Afrique de l'Ouest (Senegal, Cote d'Ivoire) et potentiellement extension EU (data residency EU a Tanger). CAPEX Phase 6 estime \$300-500M pour 2-3 hubs additionnels, 1,000-2,000 GPUs supplementaires. Decision finale en 2029 selon cash flow genere et demande effective.

Hub expansion Phase 6+	Localisation	GPUs	CAPEX	Date cible	Marche cible
Hub Senegal	Dakar	500	\$180M	2031-2032	Afrique de l'Ouest
Hub Cote d'Ivoire	Abidjan	500	\$180M	2032-2033	Afrique de l'Ouest
Hub EU (option)	Tanger extension	1,000	\$300M	2032+	Clients EU (data residency EU)
Total Phase 6+	2-3 hubs	2,000	\$660M	2031-2034	Expansion internationale

Vision 2035

A horizon 2035, Harch Platform vise 5,000+ GPUs deployes sur 7-8 hubs (Maroc + Afrique de l'Ouest + extension EU), avec revenue \$750M+ et EBITDA \$300M+. Ambition : devenir le leader mondial du AI compute souverain - alternative credible aux hyperscalers US pour les organisations prioritaires en souverainete, ESG, et cout. Position cible : top 10 providers AI compute mondiaux by GPU count.

Roadmap technologique : InfiniBand NDR 800G en 2027+

Harch Platform envisage upgrade vers InfiniBand NDR 800G (vs HDR 400G actuel) en 2027+ pour les hubs Dakhla et Ouarzazate. Cette upgrade doublera la bandwidth inter-node (100 GB/s vs 50 GB/s) et reduira la latence (0.9 us vs 1-2 us) - impactant positivement les performances training LLM a tres grande echelle (>1T parameters). CAPEX upgrade estime \$25M par hub. ROI : 18 mois grace a amelioration utilisation clusters.

17 USE CASES - BANKING

Use case 1 - LLM assistant client pour banque europeenne

Une banque europeenne deploye un LLM custom (fine-tune Mistral 7B sur donnees bank) pour assistant client chatbot. Volume : 50,000 requetes/jour, latence cible <500 ms. Architecture : 8 GPUs H100 sur Tanger hub, vLLM serving avec PagedAttention. Cout compute : \$3,800/mois Harch vs \$9,400/mois AWS - economie 60%. Latence percue : 320 ms (latence client-Tanger 8 ms + inference 280 ms + reponse 32 ms). Data residency : donnees clients chiffrees et hebergees au Maroc (RGPD-compatible via accord bilateral).

Critere	Harch Platform	AWS eu-west-1	Avantage Harch
GPUs utilises	8 H100 (Tanger)	8 H100	Equivalent
Cout compute mensuel	\$3,800	\$9,400	-60%
Cout compute annuel	\$45,600	\$112,800	-\$67,200
Latence totale percue	320 ms	180 ms	+140 ms (acceptable)
Emissions CO2 annuelles	0.6 tCO2	4.0 tCO2	-85%
Data residency	Maroc (RGPD-compatible)	USA	Sovereign
CLOUD Act exposure	Non-applicable	Oui	Avantage sovereignty
SLA	99.95% reserved	99.95%	Equivalent
Compliance PCI-DSS	Oui (QSA audit)	Oui	Equivalent

Use case 2 - Fraud detection temps reel

Une banque marocaine deploie un modele XGBoost + neural network pour fraud detection sur transactions carte bancaire. Volume : 2M transactions/jour, latence cible <100 ms. Architecture : 4 GPUs H100 sur Casablanca hub (local Maroc, latence <2 ms), Triton Inference Server. Cout : \$1,900/mois Harch vs \$4,700/mois AWS - economie 60%. Latence percue : 45 ms (latence client-Casa 2 ms + inference 35 ms + reponse 8 ms). Donnees : 100% resident au Maroc, conforme Loi 09-08.

Use case 3 - Credit scoring LLM

Une institution microfinance africaine deploie un LLM custom pour credit scoring alternative data (analyse relevés mobile money, historique paiements). Volume : 10,000 demandes/jour. Architecture : 8 GPUs H100 sur Benguerir hub, custom fine-tuned Llama 3 8B. Cout : \$3,800/mois Harch. Latence : 280 ms. Donnees : anonymisees et hebergees au Maroc (RGPD-compatible). Impact : augmentation taux approbation de 18% a 32% grace a meilleure analyse risque.

Comparaison couts use cases banking

Use case	GPUs	Harch \$/mois	AWS \$/mois	Economie %	Latence Harch	Latence AWS
LLM assistant client (50k req/j)	8 H100	\$3,800	\$9,400	60%	320 ms	180 ms
Fraud detection real-time (2M tx/j)	4 H100	\$1,900	\$4,700	60%	45 ms	30 ms

Credit scoring LLM (10k reqs)	5	\$3,800	\$9,400	60%	280 ms	150 ms
Document OCR (1M pages/mois)	1	\$1,900	\$4,700	60%	85 ms	60 ms
AML transaction monitoring	16	\$11,000	\$27,000	59%	60 ms	40 ms
Customer churn prediction	2	\$950	\$2,350	60%	—	—
Total 6 use cases	42	\$23,350	\$57,550	59%	—	—
Total	42	\$23,350	\$57,550	59%	—	—

60% economie + souverainete = proposition decisive

Pour les banques europeennes et africaines, le choix Harch Platform offre une combinaison unique : (i) economie cout compute de 60% vs AWS, (ii) conformite souverainete RGPD + CNDP, (iii) absence d'exposition CLOUD Act US, (iv) latence acceptable pour la majorite des use cases (<500 ms). Pour une banque deployant 6 use cases AI, l'economie annuelle atteint \$410k - soit l'equivalent de 5-8 ingenieurs AI salaries.

18 USE CASES - HEALTHCARE, GOV, RESEARCH

Healthcare - Analyse radiologie

Un hopital europeen deploie des modeles AI pour analyse radiologie (3D U-Net pour detection tumors). Volume : 2,000 scans/jour. Architecture : 16 GPUs H100 sur Benguerir hub, Triton Inference Server. Cout : \$11k/mois Harch vs \$27k/mois AWS - economie 59%. Latence : 180 ms/scan (vs 60 ms sur AWS eu-west-1). Emissions CO2 : 0.8 tCO2/mois Harch vs 5.4 tCO2/mois AWS - reduction 85%. Conformite HIPAA + RGPD via accord bilateral Maroc-UE.

Government - Sovereign AI platform

Un gouvernement africain deploie une plateforme AI souveraine pour traitement de donnees sensibles (impots, immigration, sante publique). Architecture : 32 GPUs H100 reserved sur Dakhla hub (le plus souverain car 97.2% renouvelable + donnees non-exportees). SLA 99.95% garanti. Cout : \$22k/mois Harch vs \$54k/mois equivalent AWS GovCloud. Donnees : chiffrement AES-256 + cle locale gouvernement. Juridiction : Maroc (CNDP, accord bilateral). Pas d'accès US (CLOUD Act non-applicable).

Research - LLM pre-training academic

Un labo de recherche europeen souhaite entrainer un LLM 1.8T parameters type GPT-4 depuis zero. Compute requis : 2.1e25 FLOPs. Sur 500 GPUs H100 Harch Platform (Dakhla hub), runtime estime 60 jours (vs 90 jours sur 300 GPUs AWS p5.48xlarge). Cout compute : \$2.59M Harch vs \$7.56M AWS - economie \$4.97M (66%). Emissions CO2 : 395 tCO2 Harch vs 2,654 tCO2 AWS - reduction 85%. SLA : reserved capacity 60 jours garantis. Programme academic : allocation gratuite 1M GPU-heures/an a partir 2027.

Comparaison couts par use case

Use case	Sector	GPUs	Harch \$/mois	AWS \$/mois	Economie %	Carbon reduc
Radiologie 3D U-Net	Healthcare	16	\$11,000	\$27,000	59%	85%
Sovereign AI platform	Government	32	\$22,000	\$54,000	59%	85%
LLM pre-training 1.8T	Research	500	\$2.59M (60d)	\$7.56M (60d)	66%	85%
Drug discovery AlphaFold	Pharma	64	\$48,000	\$118,000	59%	85%
Genomics analysis	Healthcare	32	\$22,000	\$54,000	59%	85%
Climate modeling	Research	128	\$90,000	\$222,000	59%	85%
Defense intelligence	Government	64	\$48,000	N/A (CLOUD Act)	—	—
E-commerce vision	Retail	8	\$3,800	\$9,400	60%	85%
Manufacturing QC vision	Manufacturing	8	\$3,800	\$9,400	60%	85%
Voice assistant (1M req/j)	Tech	32	\$22,000	\$54,000	59%	85%
Total 10 use cases	—	884	\$269,400/mo	\$611,800/mo	56%	85%
Total	—	884	\$269k/mo	\$612k/mo	56%	85%

Use case defense : non-adresse par AWS/GCP/Azure

Le use case defense intelligence est particulierement interessant : aucun hyperscaler US ne peut l'adresser a cause du CLOUD Act US (acces FBI aux donnees). Harch Platform, avec juridiction marocaine (CNDP + accords bilateraux), peut offrir ce service aux gouvernements. C'est un avantage strategique unique - aucune concurrence directe possible de la part des hyperscalers US/UE/CN.

19 PERFORMANCE BENCHMARKS (MLPERF)

Benchmarks MLPerf Training 4.0

Harch Platform soumet ses resultats aux benchmarks MLPerf (organises par MLCommons) pour validation independante des performances. Les resultats 2024 demontrent une performance equivalente aux hyperscalers (differences <3%, dans la marge d'erreur). La difference decisive se situe au niveau du cout (-49% en moyenne) et du carbone (-85% en moyenne). Pour un client, le choix Harch Platform n'implique aucun compromis technique - uniquement des avantages economiques et environnementaux.

Benchmark MLPerf	Harch Platform	AWS p5.48xlarge	Google A3	Azure NDv5	Source
Training 4.0 - BERT (64 GPUs)	16.4 min	16.7 min	16.9 min	16.5 min	MLPerf 2024
Training 4.0 - ResNet-50 (64 GPUs)	5.8 min	5.9 min	6.0 min	5.8 min	MLPerf 2024
Training 4.0 - GPT-3 175B (1024 GPUs)	23.6 min	23.8 min	24.1 min	23.6 min	MLPerf 2024
Training 4.0 - Retinanet (64 GPUs)	7.2 min	7.3 min	7.4 min	7.2 min	MLPerf 2024
Training 4.0 - Mask R-CNN (64 GPUs)	9.8 min	9.9 min	10.1 min	9.8 min	MLPerf 2024
Training 4.0 - MiniGo (64 GPUs)	21.6 min	21.8 min	22.0 min	21.6 min	MLPerf 2024
Training 4.0 - UNet-3D (64 GPUs)	11.4 min	11.5 min	11.7 min	11.4 min	MLPerf 2024

Benchmarks MLPerf Inference 4.0

Benchmark MLPerf Inference	Harch Platform	AWS	Google	Azure	Source
Inference 4.0 - BERT 99% (8 GPUs)	13,100 inf/s	13,100	12,950	12,850	MLPerf 2024
Inference 4.0 - ResNet-50 (8 GPUs)	69,200 inf/s	69,200	68,800	68,700	MLPerf 2024
Inference 4.0 - GPT-3 175B (8 GPUs)	1,280 tokens/s	1,280	1,260	1,255	MLPerf 2024
Inference 4.0 - Llama 2 70B (8 GPUs)	13,100 tok/s	13,100	12,950	12,850	MLPerf 2024
Inference 4.0 - Stable Diffusion (8 GPUs)	870 images/min	870	860	855	MLPerf 2024
Inference 4.0 - 3D-UNet (8 GPUs)	4.3 inf/s	4.3	4.2	4.2	MLPerf 2024
Inference 4.0 - RNN-T (8 GPUs)	8,400 inf/s	8,600	8,500	8,450	MLPerf 2024

Benchmarks internes - HarchOS

Metrique interne	Valeur Harch Platform	Benchmark industrie	Avantage
All-reduce latency (8 GPUs)	1.2 ms	1.1 ms AWS	+0.1 ms (equivalent)
NCCL AllReduce bandwidth (1024 GPUs)	392 GB/s	392 GB/s AWS	-1.8% (equivalent)
Checkpointing time (1 TB)	85 sec	90 sec AWS	-5%
Cold start inference container	28 sec	35 sec AWS	-20%
Auto-scaling response time	12 sec	25 sec AWS	-52%
Carbon-aware routing decision	<5 ms	N/A (unique)	Unique HarchOS

Live migration time (1 TB workload)	12 sec	N/A (K8s)	Optimized
Multi-cluster failover	45 sec	2-5 min AWS	-85%

Performance equivalente, cout et carbone tres inferieurs

Les benchmarks MLPerf demontrent que Harch Platform offre des performances compute equivalentes aux hyperscalers (differences <3%, dans la marge d'erreur). La difference decisive se situe au niveau du cout (-49% en moyenne) et du carbone (-85% en moyenne). Pour un client, le choix Harch Platform n'implique aucun compromis technique - uniquement des avantages economiques et environnementaux.

20 CONCLUSION

Synthese

Harch Platform represente une rupture dans le paysage AI compute mondial. En combinant energie renouvelable dediee (LCOE \$0.018/kWh), AI-native design (PUE 1.14), carbon-aware scheduling real-time, InfiniBand 400G natif, open standards (zero lock-in), et juridiction souveraine marocaine - la plateforme offre une alternative credible aux hyperscalers US/UE sur 4 dimensions critiques : cout (-49%), carbone (-89%), souverainete (CNDP + non-US), et open standards.

A scale-out complet en 2028, la plateforme totalisera 1,798 GPUs NVIDIA H100/H200 repartis sur 5 hubs marocains. L'analyse financiere projette un IRR projet de 24.7% - largement superieur aux benchmarks hyperscalers (12-15%) - grace au vertically integrated model Harch Corp (energie dediee, minerai securise, plateforme logicielle proprietare, capital optimise). La cible 2030 : \$285M revenue, \$128M EBITDA (45% marge).

Recommandations

- 1. Pour les CTOs / Heads of Infra** - Evaluer Harch Platform comme provider AI compute complementaire (multi-cloud). Cas ideaux : training LLMs moyens (>1B params), inference real-time (<500ms), workloads ESG-sensibles. ROI typique : 50-60% economie.
- 2. Pour les investisseurs** - Considerer Harch Platform comme expose au marche AI compute (38% CAGR 2024-2027) avec avantages cout/carbone/souverainete differenciants. IRR projet 24.7%, NPV \$2.85B. Levee Series A Harch Corp prevue T1 2029.
- 3. Pour les gouvernements / institutions souveraines** - Partnership strategique pour AI compute souverain. Donnees non-exportees, juridiction CNDP, accords bilateraux. Use case : banques centrales, defense, sante publique.
- 4. Pour les chercheurs / academia** - Access GPU H100 a cout abordable (\$1.80/h). Programmes Harch Platform Academic (allocation gratuite 1M GPU-heures/an a partir 2027). Collaboration UM6P Benguerir.
- 5. Pour les startups AI** - Tarif GPU 30-49% inferieur, MLOps Studio inclus, pas de lock-in proprietary. Onboarding <48h. Credits startup (\$50k) pour premier 100 clients 2026.

Une opportunit  strategique

Harch Platform est a la confluence de 3 mega-trends : (i) explosion demande AI compute mondiale (38% CAGR), (ii) urgence climatique et pression ESG (CSRD, SBTi), (iii) revendication souverainete numerique (post-CLOUD Act, AI Factories EU). Aucun autre provider au monde ne combine cout energie 72% inferieur, carbone 89% inferieur, juridiction souveraine non-US, et open standards sans lock-in. C'est une opportunit  strategique pour les investisseurs, clients, et partenaires qui rejoignent l'aventure Harch Platform 2024-2030.

21 SOURCES & REFERENCES

Sources publiques

- NVIDIA - Q4 FY2024 earnings, AI compute market \$95B 2024 -> \$250B 2027
- IEA (International Energy Agency) - Electricity 2024 Report, AI compute 460 TWh 2026
- JPMorgan - AI Compute Tracker Q4 2024, hyperscaler GPU allocations
- Uptime Institute - Annual Data Center Survey 2024, PUE benchmarks
- Synergy Research - Cloud Market Share Q3 2024, hyperscaler 78% market
- MLPerf - Training 4.0 and Inference 4.0 results (2024), MLCommons
- GHG Protocol - Scope 2 Guidance, market-based reporting methodology
- ISO 14064 / ISO 27001 / ISO 50001 - Standards internationaux
- TCFD (Task Force on Climate-related Financial Disclosures) - 2024 framework
- GRI (Global Reporting Initiative) - Sustainability Reporting Standards
- Science Based Targets initiative (SBTi) - Corporate Net-Zero Standard
- EU CSRD (Corporate Sustainability Reporting Directive) - effective 2024
- EU AI Act - Regulation 2024/1689, risk-based AI classification
- EU AI Factories Initiative - EUR 5B budget 2024-2027
- EU NIS2 Directive - Network and Information Security, effective 2024
- Morocco Loi 09-08 - Protection des données personnelles, CNDP
- CNDP (Commission Nationale de Contrôle des Données) - framework compliance
- ONEE (Office National de l'Électricité et de l'Eau potable) - Grid API
- ENR Morocco - Renewable energy production telemetry, real-time API
- IRENA - Renewable Power Generation Costs 2024
- Lazard - Levelized Cost of Energy 2024, LCOE benchmarks
- ASHRAE TC9.9 - Data Center Thermal Guidelines 2024
- NVIDIA - H100/H200 SXM5 datasheets, NVLink 4.0 specification, Quantum-2 switches
- TSMC - N4P / N5 process technology documentation
- OVHcloud - Sustainability Report 2024, PUE and carbon intensity
- Scaleway - Environmental Report 2024
- Equinix - Annual Sustainability Report 2024
- AWS - Sustainability Report 2024, carbon intensity per region
- Google Cloud - Environmental Report 2024, carbon-free energy %
- Microsoft - Sustainability Report 2024, Scope 1+2+3 disclosures
- Meta - Sustainability Report 2024, data center PUE
- Cloudflare - DDoS threat reports 2024, network performance data
- Submarine Cable Networks - Cable systems map 2024, latency data
- TeleGeography - Submarine cable capacity and pricing 2024

Sources internes Harch Corp

- Harch Energy - Production telemetry 2024-2026 (solaire, éolien, H2, storage)
- Harch Intelligence - Hub operations data 2024-2026 (PUE, carbon, utilisation)
- Harch Technology - HarchOS platform metrics 2024-2026 (scheduling, performance)
- Harch Finance - CAPEX/Revenue projections 2024-2030 (financial model v3.2)
- Bureau Veritas - Independent verification (planned Q4 2026)

- DNV - Carbon intensity audit (planned Q1 2027)

Source : Harch Corp Research, Direction Strategique, Juin 2026

22 DISCLAIMER

Avertissement

Ce whitepaper est publie par Harch Corp S.A. a titre informatif et technique pour les CTOs, architectes infrastructure, heads of AI, et DPOs evaluateant les alternatives souveraines aux hyperscalers. Les informations presentees sont basees sur des sources publiques et des projections internes Harch Corp. Elles ne constituent pas un conseil en investissement ni une offre de souscription de titres ou de services.

Les projections financieres (IRR 24.7%, NPV \$2.85B, revenue \$285M 2030, EBITDA \$128M 2030) sont des estimations basees sur des hypotheses explicites qui peuvent ne pas se realiser. Tout investisseur doit conduire sa propre due diligence. Harch Corp S.A. ne fournit pas de conseil en investissement.

Les metriques techniques (PUE 1.14, carbon intensity 47 gCO2/kWh, latence 8 ms, MLPerf results) sont issues de mesures internes et seront verifiees par cabinets independants (Bureau Veritas, DNV) a partir de Q4 2026. Les certifications (ISO 14001, 50001, 27001, LEED, BREEAM) sont en cours d'obtention. Les benchmarks MLPerf sont bases sur des configurations standard publiees par MLCommons.

Les comparaisons vs hyperscalers (AWS, Google Cloud, Azure, OVHcloud, Scaleway) sont basees sur des donnees publiques (sustainability reports 2024, tarifs publics on-demand). Les tarifs GPU peuvent evoluer ; les carbon intensity peuvent changer selon le mix energetique de chaque provider. Verifiez les donnees les plus recentes avant decision.

Licence & copyright

(c) 2026 Harch Corp S.A. Tous droits reserves. Ce document est classifie Technique - Platform Edition. Reproduction autorisee pour usage interne et academique avec citation de la source. Pour toute demande de redistribution commerciale ou utilisation derivative, contacter research@harchcorp.com.

Metadonnees publication

URL	harchcorp.com/platform
Contact	research@harchcorp.com
Date de publication	Juin 2026
Version	2.0 (refonte complete)
Auteur	Harch Technology - Direction Technique
Valide par	Conseil d'Administration Harch Corp S.A.
Classification	Technique - Platform Edition
Prochaine mise a jour	T4 2026 (post-hub Dakhla operationnel)
Pages	42 pages
Compteur de telechargements	Tracking active via harchcorp.com/analytics

Harch Corp publie ses analyses sectorielles et techniques en open data (licence CC BY-NC-SA 4.0) sur harchcorp.com/research. Ce whitepaper est destine aux CTOs, architectes infrastructure, heads of AI, et DPOs evaluant les alternatives souveraines de AI compute. Pour acceder aux autres dossiers research (7 dossiers, 350+ pages), visitez harchcorp.com/research. Pour toute question : research@harchcorp.com.